

Facultade de Informática
UNIVERSIDADE DA CORUÑA

TRABALLO FIN DE GRAO
GRAO EN CIENCIA E ENXEÑARÍA DE DATOS

Aplicación de técnicas de Aprendizaje Automático para la detección temprana del Trastorno del Espectro Autista

Estudante: Ángel Vilariño García

Dirección: Verónica Bolón Canedo

Brais Cancela Barizo

A Coruña, junio de 2026.

A quienes han formado parte de este camino.

Agradecimientos

Este trabajo no habría sido posible sin el apoyo de muchas personas que me han acompañado durante todos estos meses.

En primer lugar, agradecer a mis tutores, Verónica y Brais, su dedicación, su ayuda y sus consejos a lo largo de todo el proyecto. También a Isabel, por cedernos la base de datos que hizo esto posible e iluminarnos en los aspectos más clínicos del trabajo.

A mis padres y mi hermano, por ser el pilar más importante, acompañándome y creyendo en mí en cada etapa de mi vida.

A mis abuelos, por haberme criado, inculcado unos valores y enseñado a que con esfuerzo y constancia todo es posible.

Por último, a mis amigos por hacer este camino más llevadero y siempre estar ahí cuando se les necesita.

Resumen

El Trastorno del Espectro Autista (TEA) es una condición del neurodesarrollo con dificultades en la comunicación social y patrones conductuales restrictivos. Su diagnóstico clínico suele ser complejo y lento, lo que retrasa intervenciones tempranas esenciales. Este trabajo propone y valida un sistema de Aprendizaje Automático para el cribado temprano del TEA, basado en datos clínicos reales de 209 individuos y 216 variables procedentes de los cuestionarios ICAP y GARS-2. Tras un preprocesamiento exhaustivo, se comparan distintos métodos de selección de características y algoritmos de clasificación mediante validación cruzada estratificada. El enfoque prioriza la reducción de dimensionalidad, identificando un subconjunto óptimo de 20 variables, logrando un rendimiento competitivo y un buen equilibrio entre precisión e interpretabilidad clínica.

Abstract

Autism Spectrum Disorder (ASD) is a neurodevelopmental condition characterised by social communication difficulties and restrictive behavioral patterns. Clinical diagnosis is typically complex and time-consuming, delaying essential early interventions. This work proposes and validates a Machine Learning system for early ASD screening using real clinical data from 209 individuals and 216 variables from the ICAP and GARS-2 questionnaires. After thorough preprocessing, different feature selection methods and classification algorithms are evaluated using stratified cross-validation. The approach focuses on dimensionality reduction, identifying an optimal subset of 20 variables, achieving strong performance and a balance between predictive accuracy and clinical interpretability.

Palabras clave:

- Trastorno del Espectro Autista
- ICAP y GARS-2
- Aprendizaje Automático
- Selección de características
- Validación cruzada
- Optimización de hiperparámetros
- Interpretabilidad clínica

Keywords:

- Autism Spectrum Disorder
- ICAP and GARS-2
- Machine Learning
- Feature selection
- Cross-validation
- Hyperparameter optimization
- Clinical interpretability

Índice general

1 Introducción **1**

1.1 Contexto y motivación 1
1.2 Definición del problema 3
1.3 Objetivos 3
1.4 Herramientas y librerías utilizadas 4
1.5 Estructura 5

2 Estado del arte **7**

3 Conjunto de Datos **10**

3.1 Descripción del dataset 11
3.1.1 Variables Clínicas y Sociodemográficas 11
3.1.2 Inventario de Planificación de Servicios y Programación Individual (ICAP) 12
3.1.3 Escala de Evaluación del Autismo de Gilliam (GARS-2) 16
3.2 Análisis Exploratorio de Datos 19
3.2.1 Estructura y dimensión del dataset 19
3.2.2 Caracterización de la muestra respecto a la variable objetivo 19
3.2.3 Análisis de valores ausentes 22
3.2.4 Análisis de correlación y agrupación en bloques funcionales 24
3.2.5 Análisis de los cuestionarios estandarizados 26
3.2.6 Separabilidad entre clases 29

4 Marco Experimental y Desarrollo **32**

4.1 Preprocesamiento 32
4.1.1 Codificación de variables 32
4.1.2 Estrategias de imputación 33
4.1.3 Normalización 35

4.2 Métodos de selección de características . . . 35
4.3 Modelos de clasificación . . . 38
4.4 Diseño experimental . . . 41
4.4.1 Esquema de validación cruzada estratificada . . . 41
4.4.2 Métricas de evaluación . . . 42

5 Análisis de Resultados **44**
5.1 Comparativa de estrategias de preprocesamiento . . . 44
5.1.1 Mejor configuración por valor de k . . . 45
5.1.2 Rendimiento medio por valor de k . . . 45
5.1.3 Impacto sobre la selección de características . . . 46
5.1.4 Estrategia seleccionada . . . 47
5.2 Impacto de la variable *País* . . . 48
5.2.1 Impacto sobre el F1 medio por k . . . 48
5.2.2 Impacto sobre la mejor combinación por k . . . 49
5.2.3 Rendimiento por selector y modelo . . . 50
5.2.4 Evolución del F1 máximo por k . . . 51
5.2.5 Impacto sobre la selección de características . . . 51
5.2.6 Estrategia seleccionada . . . 53
5.3 Análisis de rendimiento por selector, modelo y k . . . 53
5.3.1 Rendimiento por selector . . . 53
5.3.2 Rendimiento por modelo . . . 55
5.3.3 Interacción entre selectores y modelos . . . 57
5.3.4 Evolución del rendimiento en función de k y elección del valor óptimo 59
5.4 Análisis de la selección de características . . . 61
5.4.1 Estabilidad y acuerdo entre selectores . . . 61
5.4.2 Variables robustas entre métodos y valores de k . . . 63
5.4.3 Consenso y selección final de características . . . 65
5.4.4 Separabilidad con las variables de consenso seleccionadas . . . 67
5.5 Interpretación clínica de las características seleccionadas . . . 67
5.6 Optimización y evaluación del modelo final . . . 70
5.6.1 Estrategia de búsqueda exhaustiva: *GridSearchCV* . . . 70
5.6.2 Mejor configuración por modelo . . . 72
5.6.3 Análisis del modelo ganador . . . 74

6 Conclusiones **76**
6.1 Conclusiones principales . . . 76
6.2 Limitaciones del estudio . . . 77

6.3 Trabajo Futuro 78

Bibliografía **80**

Índice de figuras

1.1 Evolución de la prevalencia del TEA en las últimas décadas en EE.UU.[1]. 2

3.1 Distribución de la variable objetivo por diagnóstico global (izquierda), país de procedencia (centro) y sexo (derecha). 20
3.2 Distribución de la edad por grupo diagnóstico. 21
3.3 Diagrama de dispersión altura-peso por grupo diagnóstico. 21
3.4 Distribución del modo de expresión (izquierda) y del nivel de apoyos requeridos (derecha) por grupo diagnóstico. 22
3.5 Matriz de valores ausentes del dataset. Cada columna representa una variable y cada fila un participante. Las franjas blancas indican valores nulos. 23
3.6 Mapa de calor de correlaciones entre todas las variables numéricas del dataset. 24
3.7 Mapa de calor de correlaciones de Spearman entre los 11 índices de bloque funcional. 26
3.8 Boxplots de los índices ICAP por grupo diagnóstico. 27
3.9 Violinplots de los índices ICAP por grupo diagnóstico. 28
3.10 Boxplots de las tres subescalas GARS-2 por grupo diagnóstico. 29
3.11 Violinplots de las subescalas GARS-2. 29
3.12 Proyecciones PCA, t-SNE y UMAP con las 216 variables originales, coloreadas por grupo diagnóstico. 30
3.13 Proyecciones PCA, t-SNE y UMAP con los 11 índices de bloque funcional, coloreadas por grupo diagnóstico. 31

4.1 Esquema del pipeline de entrenamiento y evaluación siguiendo validación cruzada estratificada 42

5.1 Evolución del F1 medio en función de k para las estrategias de preprocesamiento. 46

[1] Gráfica adaptada de The PLAY Project (`https://playproject.org/why-is-autism-increasing-so-much/`) a partir de los datos históricos oficiales de los informes del CDC.

5.2 F1 medio por selector (izquierda) y por modelo (derecha), con y sin la variable *País*. 50
5.3 Evolución del F1 máximo alcanzable en función de k, con y sin la variable *País*. 51
5.4 Distribución del F1-Score por selector de características sobre todas las combinaciones de modelo y k. 53
5.5 Evolución de F1, Accuracy, Precisión, Recall y ROC-AUC en función de k para cada selector. 55
5.6 Distribución del F1-Score por modelo de clasificación sobre todas las combinaciones de selector y k. 56
5.7 F1 medio por combinación selector-modelo, promediado sobre todos los valores de k. Se incluye la fila NO-FS como referencia del baseline. 57
5.8 Selector con mayor F1 medio para cada combinación de modelo y valor de k. . 58
5.9 Evolución del techo de rendimiento, F1 medio y rango de variabilidad en función de k, con ganancia marginal anotada entre valores consecutivos (verde: $\geq$1%, naranja: $<$1%). Línea discontinua: *baseline* NO-FS. 59
5.10 Dispersión del F1-Score entre todas las combinaciones selector-modelo para cada valor de k. 60
5.11 Estabilidad promedio por selector en función de k. 62
5.12 Similitud de Jaccard entre pares de selectores, promediada sobre todos los valores de k. 63
5.13 Variables persistentes en 2 o más selectores ante todos los valores de k. 64
5.14 Número de selectores en acuerdo para las 20 variables de mayor consenso en función de k. 66
5.15 Análisis de sensibilidad a los hiperparámetros por modelo. 74
5.16 Evaluación del modelo ganador (MLP) mediante predicciones *out-of-fold*. . . . 75

Índice de tablas

3.1 Variables ICAP organizadas por secciones y dominios. 14
3.2 Variables GARS-2 – Ítems individuales de evaluación del autismo. 18
3.3 Resumen de variables con alta tasa de valores ausentes (>50%) estratificado por país. 23

4.1 Comparativa de calidad de imputación (distancia de Jensen-Shannon media). . 34

5.1 Combinación selector-modelo con mayor F1 medio (promedio sobre 5 folds de CV) por valor de k, para ambas estrategias de preprocesamiento. 45
5.2 Top-20 variables de mayor consenso ($k = 20$) para cada estrategia de preprocesamiento. Las celdas sombreadas indican variables que aparecen en una estrategia pero no en la otra. 47
5.3 Comparativa de F1 medio global por k, con y sin la variable *País*. La diferencia es F1(Sin *País*) − F1(Con *País*). 49
5.4 Combinación selector-modelo con mayor F1 medio (promedio sobre 5 folds de CV) por valor de k, con y sin la variable *País*. La diferencia es F1(Con *País*) − F1(Sin *País*). 49
5.5 Top-20 de variables de mayor consenso con y sin la variable *País*. Las celdas sombreadas indican variables que aparecen en un ranking pero no en el otro. . 52
5.6 F1 medio por selector en función de k (promedio sobre los 6 modelos y los 5 folds de CV). 54
5.7 F1 medio por modelo en función de k (promedio sobre los 6 selectores y los 5 folds de CV). 56
5.8 Mejor combinación selector-modelo y métricas completas por valor de k. . . . 60
5.9 Variables consistentes para $k = 20$. 64
5.10 Top 20 variables ordenadas por *score* de consenso para $k = 20$. 65
5.11 Hiperparámetros y valores explorados por modelo en la búsqueda *GridSearchCV*. 71
5.12 Mejor configuración por modelo tras la búsqueda *GridSearchCV*. 72

Capítulo 1
Introducción

1.1 Contexto y motivación

El El Trastorno del Espectro Autista (TEA) es un trastorno del neurodesarrollo de origen multifactorial, cuya aparición se relaciona con la interacción de factores genéticos, epigenéticos y ambientales. No se trata de una enfermedad y no tiene cura, se nace con él y acompaña a la persona a lo largo de toda su vida. Comenzando a manifestarse en etapas tempranas, está caracterizada por alteraciones que afectan a varios aspectos de la vida: dificultades en la interacción social, comunicación verbal y no verbal, reciprocidad socio-emocional y la presencia de patrones de comportamientos, actividades o intereses restringidos y repetitivos. La heterogeneidad con la que estas se manifiestan es uno de sus rasgos más característicos, y de ahí el concepto de ”espectro”. Según el DSM-5, existen tres niveles de severidad, que medirán cómo de graves son dichas alteraciones e indicarán qué nivel de apoyo requiere el paciente [1].

Su diagnóstico es esencialmente clínico, ya que no se dispone de biomarcadores que permitan una identificación objetiva como en otras patologías. Este se apoya en la observación de la conducta y entrevistas y cuestionarios a familiares, convirtiendo el proceso en largo, complejo y subjetivo.

A nivel epidemiológico, la Organización Mundial de la Salud (OMS) estima que 1 de cada 100 niños en el mundo tiene autismo [2]. Este dato es un promedio orientativo y algunos estudios en países desarrollados reportan una prevalencia que va desde el 1 al 5% de la población. También cabe destacar que la prevalencia en hombres es cuatro veces mayor que en mujeres, y que en estas el fenotipo es más severo [3].

En los últimos años, se ha producido un incremento en las tasas de prevalencia (como se muestra en la Figura 1.1) que no se debe solamente a factores biológicos, sino también a una mayor concienciación social, las mejoras en la identificación temprana y una definición más amplia de los criterios diagnósticos.

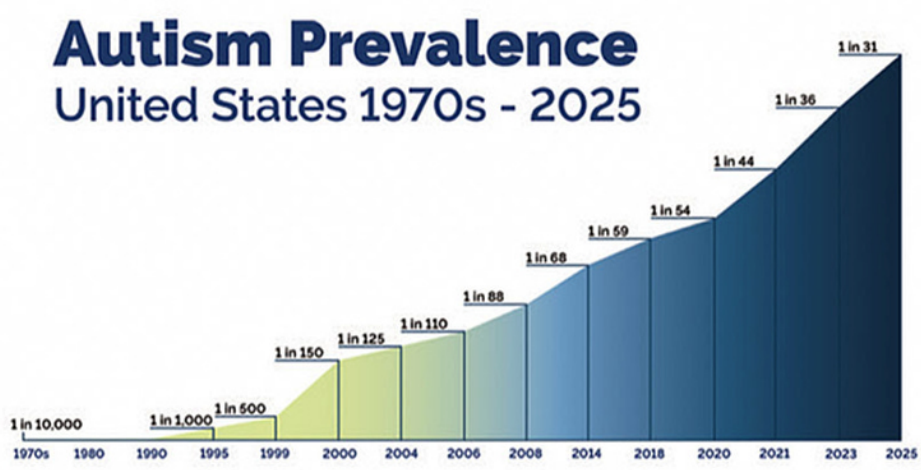


Figura 1.1: Evolución de la prevalencia del TEA en las últimas décadas en EE.UU.[1].

Como consecuencia, los servicios sanitarios públicos se están saturando a nivel mundial, provocando largas listas de espera para la obtención de un diagnóstico final. Este retraso es crítico, ya que cuanto antes se detecte (idealmente entre los 18 y 30 meses de edad), mayor será el impacto de las intervenciones y apoyos de los profesionales para mejorar las habilidades y calidad de vida del individuo y de su familia. En la actualidad, existe una desigualdad en el acceso a dichos apoyos, que requieren de personal y recursos especializados, perjudicando a países o clases sociales con menos recursos [4]. Con todo esto en mente, surge la necesidad de democratizar y agilizar el diagnóstico con herramientas rápidas, objetivas y escalables.

En este escenario, la Inteligencia Artificial y, más en concreto, los métodos de Aprendizaje Automático (*Machine Learning*) aparecen como una solución complementaria al cribado tradicional. La capacidad de estos algoritmos para detectar relaciones no lineales complejas en grandes conjuntos de datos los convierte en herramientas adecuadas para el ámbito sanitario, especialmente en los trastornos del neurodesarrollo. Así lo refrendan estudios recientes, los cuales demuestran que se puede llegar a una alta precisión superando a métodos estadísticos o de cribado tradicionales [5]. Este enfoque permitirá agilizar la identificación de individuos que requieren una evaluación clínica profunda, reduciendo la carga de trabajo de los especialistas.

La motivación principal de este Trabajo de Fin de Grado reside, por tanto, en la oportunidad de aplicar técnicas avanzadas de Ciencia de Datos para democratizar el acceso a un diagnóstico temprano. Con la utilización de métodos de selección de características y modelos de clasificación optimizados, se conseguirá discernir qué variables, de los cientos de las que se disponen (historial médico, cuestionarios, conducta adaptativa, etc), son verdaderamente relevantes. No solo se busca un buen rendimiento predictivo, sino también un sistema rápido, eficiente, escalable y que pueda ser interpretable por pediatras, psicólogos y otros profesionales de la salud.

1.2 Definición del problema

Este trabajo nace de la colaboración con la Dra. Isabel García García, quien ha facilitado una base de datos clínica recopilada a lo largo de los años para su investigación doctoral sobre indicadores tempranos del TEA en la infancia. El problema central se encuentra en la brecha que existe en la información clínica de la que se dispone y su aplicabilidad en modelos de Aprendizaje Automático, agravada por las características de nuestro conjunto de datos.

Los datos proceden de información básica del individuo, historial médico y, principalmente, los cuestionarios ICAP (Inventario de Conducta Adaptativa y Apoyo) y GARS-2 (*Gilliam Autism Rating Scale*). Estos dos últimos generan un escenario de alta complejidad debido a dos factores clave:

- **Alta dimensionalidad:** El dataset cuenta con un total de 216 variables, lo que supone un gran volumen de información, que puede llegar a ser redundante para una tarea de clasificación binaria.
- **Escasez de muestras:** Se dispone únicamente de 209 individuos. Al ser el número de variables superior al de muestras, el riesgo de sobreajuste (*overfitting*) es muy elevado, ya que los modelos tienden a memorizar el ruido en lugar de aprender patrones generales.

Esta disparidad entre características y observaciones, junto con la presencia de datos incompletos, supone una dificultad a la hora de generar un diagnóstico rápido. El reto estará en diseñar un flujo de trabajo que vaya desde el preprocesamiento de dichos extensos inventarios clínicos a la creación de un sistema de cribado que reduzca la complejidad del problema a un conjunto pequeño de indicadores clave, manteniendo una buena capacidad predictiva.

1.3 Objetivos

El objetivo principal de este Trabajo de Fin de Grado es diseñar, implementar y validar un sistema de clasificación basado en Aprendizaje Automático para la detección temprana del Trastorno del Espectro Autista. Se busca transformar la información clínica en un modelo predictivo eficiente, robusto y que se entrene a partir de un subconjunto reducido de variables que permita disminuir la dependencia de cuestionarios extensos.

Con el fin de alcanzar esta meta general, se definen los siguientes objetivos específicos:

- **Análisis Exploratorio de Datos:** Realizar un estudio estadístico descriptivo previo para entender la naturaleza del dataset, analizando la distribución de las clases (según algunas variables como sexo, edad, peso y altura, etc), la correlación entre grupos de características y la presencia de valores ausentes.

- **Preprocesamiento de los datos:** Preparar los datos para su posterior uso en modelos de clasificación mediante la codificación de características categóricas y el uso de técnicas de normalización e imputación para garantizar el correcto entrenamiento de dichos modelos.
- **Selección de características (*Feature Selection*):** Aplicar y evaluar diferentes métodos de reducción de la dimensionalidad como paso previo al entrenamiento de modelos, con el fin de mejorar los resultados mitigando el sobreajuste e identificando las variables más relevantes e informativas.
- **Desarrollo y entrenamiento de modelos de Aprendizaje Automático:** Probar diferentes algoritmos de clasificación y combinarlos con las estrategias de preprocesado y las técnicas de selección de características para evaluar su rendimiento, identificando qué combinaciones y qué número de variables llevan a mejores resultados.
- **Optimización de modelos:** Mejorar el rendimiento de aquellos modelos con mejor desempeño en las métricas definidas, buscando maximizarlas mediante técnicas de ajuste de hiperparámetros.
- **Análisis de las variables seleccionadas e interpretabilidad:** Estudiar el conjunto final de variables detectadas como más determinantes para validar su relevancia desde un punto de vista clínico, asegurando que el sistema sea explicable para los profesionales de la salud.

1.4 Herramientas y librerías utilizadas

Para la implementación técnica de este proyecto se ha utilizado íntegramente el lenguaje de programación ***Python*** [6], debido a su sencillez, sintaxis y formato amigable, y a la amplia variedad de librerías especializadas en Ciencia de Datos y Aprendizaje Automático, consolidándose como el estándar en este ámbito. Todo esto no sería posible sin un entorno de desarrollo (IDE) donde programar, utilizando para ello ***Visual Studio Code*** [7]. Se caracteriza por ser un editor de código altamente extensible y con un diseño que facilita la gestión y depuración de los diferentes archivos. Dentro del entorno, el flujo de trabajo se organizará en varios cuadernos interactivos de Jupyter (***Jupyter Notebooks***) [8]. Esto permite un desarrollo iterativo en cada fase, gracias a la ejecución aislada de bloques de código y a la visualización inmediata de gráficos y resultados.

A continuación, se detallan las librerías más relevantes empleadas a lo largo del trabajo:

- **Pandas [9]:** Librería fundamental para la manipulación y análisis de datos estructurados. Resulta clave para la gestión del *DataFrame* que contiene las observaciones de

cada uno de los individuos para las variables de los cuestionarios. Ha sido útil para las tareas de limpieza, filtrado y transformación previa al entrenamiento de los modelos de clasificación.

- **NumPy [10]:** Empleada para manejar vectores y *arrays* multidimensionales y realizar cálculos matemáticos que no están disponibles de forma nativa en *Python*. Es la base sobre la que se cimentan otras librerías como *Pandas* o *Scikit-learn* para su correcto y eficiente funcionamiento (por ejemplo, el entrenamiento de modelos).

- **Matplotlib [11] y Seaborn [12]:** Librerías especializadas en la visualización de datos. Mientras que *Matplotlib* ofrece gráficos básicos para analizar distribuciones de variables entre otras opciones, *Seaborn* es de más alto nivel y puede generar visualizaciones estadísticas más complejas y estéticas (p. ej. *heatmaps*). Juegan un papel esencial en las etapa de análisis exploratorio inicial o la presentación del rendimiento de los diferentes modelos de clasificación entrenados.

- **Scikit-learn [13]:** Es el eje central de este proyecto, siendo importante en las distintas fases de Aprendizaje Automático. Dispone de submódulos especializados que serán útiles desde el preprocesamiento de los datos (escalado de características e imputación de valores ausentes), hasta la selección de los indicadores más relevantes para reducir la dimensionalidad del problema. De la misma manera, ha permitido el entrenamiento de múltiples algoritmos de clasificación, su combinación con diferentes técnicas de selección de características y distinto número de variables, la optimización de sus hiperparámetros, técnicas de validación cruzada y la evaluación de los modelos a través de métricas de rendimiento.

1.5 Estructura

Esta memoria se organiza en seis capítulos principales que detallan el flujo de trabajo completo y se estructuran de la siguiente manera:

- **Capítulo 1:** Establece el marco general del trabajo, detallando el contexto clínico y social del TEA, y la motivación para emplear técnicas de Aprendizaje Automático en su detección. Se define el problema técnico, se establecen los objetivos a conseguir y se describen las herramientas empleadas durante el desarrollo del proyecto.

- **Capítulo 2:** Se realiza una revisión de la literatura científica actual sobre la aplicación de métodos de Aprendizaje Automático en el diagnóstico clínico, poniendo el foco en los modelos de clasificación más utilizados, las características más determinantes y los

resultados a los que llegan. Así, se contextualiza la metodología propuesta frente a soluciones ya existentes.

- **Capítulo 3:** Se describe el *dataset* original, su número de muestras y se explican detalladamente sus variables y de dónde provienen (cuestionarios ICAP y GARS-2, historial clínico, etc). También incluye el Análisis Exploratorio de Datos (EDA) y las técnicas de preprocesado que se llevan a cabo (normalización, imputación de valores faltantes, etc).
- **Capítulo 4:** Expone la metodología experimental, incluyendo la validación cruzada y las métricas de evaluación seleccionadas. Se describen los algoritmos de selección de características y de clasificación empleados, así como los experimentos específicos para comparar estrategias y el ajuste de hiperparámetros para optimizar el rendimiento.
- **Capítulo 5:** Discute los hallazgos obtenidos tras la experimentación, analizando el rendimiento de los modelos en función del número de variables (k). Además, se identifica el subconjunto óptimo de características y se ofrece una interpretación clínica de estas para asegurar que se ajustan los criterios diagnósticos del TEA.
- **Capítulo 6:** Resume las conclusiones principales del proyecto y valora el cumplimiento de los objetivos. Se remarcan las limitaciones encontradas y se proponen futuras líneas de desarrollo para continuar mejorando la herramienta de cribado.

Capítulo 2

Estado del arte

El diagnóstico temprano del TEA ha vivido una evolución significativa en la última década gracias a su integración con el Aprendizaje Automático. Tradicionalmente, la detección se basaba en la observación clínica del comportamiento y conducta adaptativa, pudiendo llegar a ser subjetivo o alargarse en el tiempo. Actualmente se encuentra en una fase de consolidación técnica donde, ya pasada la experimentación, el foco está ahora en la búsqueda de modelos robustos, explicables y aplicables en el ámbito clínico. La literatura reciente se caracteriza por la combinación de múltiples fuentes de información (historiales médicos, biomarcadores o cuestionarios) con algoritmos de clasificación cada vez más sofisticados, incluyendo técnicas de Aprendizaje Profundo (*Deep Learning*). En este contexto, resulta de interés analizar estas tendencias para compararlas con los retos que aborda este trabajo, especialmente la alta dimensionalidad de las características disponibles.

En primer lugar, el trabajo de **Muñoz-Terol et al. (2026)** aporta una visión general y actualizada mediante la revisión y análisis de 55 estudios publicados entre 2017 y 2023 [14]. Esta investigación identifica las tendencias del sector, donde el enfoque más común es el aprendizaje supervisado (datos etiquetados disponibles), seguido del no supervisado y el semi-supervisado. En cuanto a los algoritmos, los "clásicos": SVM (*Support Vector Machine*), Árboles de Decisión, *Random Forest*, etc.[1], son los más utilizados y se aplican sobre muestras que suelen estar entre los 50-200 individuos cuando los datos son recogidos a mano para el estudio, como ocurre en el caso de nuestro trabajo (209 muestras). Para futuras líneas de investigación, se pone el foco en la privacidad y seguridad de los datos, técnicas como *Deep Learning* o Aprendizaje por Refuerzo sobre datos multimodales (cerebrales, clínicos, sensores, etc), pero sobre todo en la robustez de los modelos y la colaboración entre médicos, psicólogos y científicos de datos.

Con el objetivo de optimizar los recursos, **Rajagopalan et al. (2024)** sitúa el énfasis en

[1] Estos modelos de clasificación, junto con otros empleados en este trabajo, se describen en detalle en la sección 4.3.

alcanzar una gran eficacia en la predicción a partir de un conjunto mínimo de información médica y antecedentes [15]. Partiendo de la base de datos *SPARK* [16] y tras una fase de preprocesado, se llegó a una muestra balanceada de 30660 participantes (15330 con TEA y 15330 sin el trastorno) con 28 variables obtenidas antes de los 24 meses de edad. Con esta dimensionalidad reducida, se entrenaron 4 algoritmos (Regresión Logística, Árbol de Decisión, *XGBoost* y *Random Forest*), que fueron evaluados sobre una cohorte independiente de casi 15000 nuevos participantes, destacando una métrica de AUROC de 0.79 que indica una buena generalización para tratarse de una validación externa. También se identificaron como predictores clave los hitos del desarrollo y el comportamiento alimentario, además del posible efecto de variables demográficas sobre el rendimiento del modelo.

Mientras los trabajos anteriores parten de cuestionarios o registros clínicos, la revisión de avances recientes que realiza **Hatim et al. (2025)** se centra en aquellos basados en EEG (Electroencefalograma) [17]. Se trata de una prueba no invasiva y de bajo coste que registra la actividad eléctrica cerebral, aunque puede ser susceptible al ruido e interferencias. En este artículo, se relata el flujo de trabajo que incluye técnicas de preprocesado (filtro paso bajo, alto, etc), de extracción de características y algoritmos de Aprendizaje Automático empleados. Aparte de los clásicos nombrados anteriormente, los de *Deep Learning* son los que dan un salto cualitativo en rendimiento. Las CNNs (Redes de Neuronas Convolucionales) son las más comunes dentro de una gran variedad: RNNs (Redes de Neuronas Recurrentes), LSTMs (*Long-Short Term Memory*), etc. Por último, también se menciona la posibilidad de combinar métodos de Aprendizaje Automático y Profundo (e.g. SVM + CNN) con los que se llega a resultados mayores al 90% en métricas como *accuracy*, *sensitivity* o *F1-score*.

Otro enfoque distinto que, a priori, podría parecer poco relacionado con este trastorno es el que plantean **Temiz et al. (2025)**: biomarcadores metagenómicos de la microbiota intestinal [18]. Recientemente, se ha demostrado que la salud de estos microorganismos está ligada a trastornos metabólicos y condiciones médicas, haciéndoles útiles para detectar el TEA. Debido a la alta dimensionalidad propia de este dominio, el estudio hace hincapié en la selección de características mediante diversos métodos: SVM-RCE, mRMR (*minimum Redundancy Maximum Relevance*), *Select K Best*, *XGBoost*, etc. Estos dos últimos dieron los mejores resultados de AUC y, tras fijar un umbral de importancia de 0.5, se obtuvo un conjunto final de 17 variables. En este contexto, cabe destacar que, tras una validación cruzada para asegurar robustez, se alcanzaron resultados superiores al 95% en todas las métricas a evaluar (*accuracy*, *sensitivity*, *specificity*, *f-measure* y *AUC*) en la detección del autismo. Por otra parte, se otorga gran relevancia a la explicabilidad e interpretabilidad mostrando qué microorganismos contribuyen más a la predicción (*Prevotella*, *Parabacteroides*) mediante el uso de SHAP (*SHapley Additive exPlanations*).

A diferencia de los anteriores, el trabajo de **Ayub et al. (2024)** demuestra que se puede

llegar a grandes resultados sin biomarcadores ni características complejas [19]. Se parte de un simple *pipeline* en el que se preprocesan las variables (normalización e imputación de valores faltantes, al igual que se hace en nuestro trabajo) y, a continuación, se hace una selección de las mismas mediante el test estadístico de significancia chi-cuadrado. Estas incluyen 10 preguntas realizadas a los padres, edad, género, etnia, historial familiar, etc. En la posterior comparación entre modelos (*Random Forest*, Regresión Logística, *Gradient Boosting* y *Extra Trees*), tras una *10-fold cross validation* debido al limitado número de instancias, se llega a resultados sorprendentemente elevados en todos ellos. A pesar de conseguir métricas en torno al 97%, se hace énfasis en la presencia de posibles sesgos o limitaciones, la necesidad de examinarlos con datasets de mayor tamaño y estando en constante colaboración con clínicos.

Finalmente, **Santana et al. (2022)** realizan un análisis de 55 artículos, publicados entre 2013 y 2019, que se centran en imágenes de rs-fMRI (Resonancia Magnética Funcional en estado de reposo) a partir de las cuales se pueden detectar alteraciones en la conectividad neuronal asociadas al TEA [20]. La gran mayoría de estudios toman sus muestras de la base de datos ABIDE [21], siendo el método de clasificación del trastorno más empleado SVM, seguido de las Redes de Neuronas Artificiales (ANN). Los resultados promedio del 75% obtenidos en *sensitivity* y *specificity* ponen de manifiesto la necesidad de combinar estas imágenes con otro tipo de datos (cuestionarios de comportamiento, otros biomarcadores, etc). Además, se presentan otros obstáculos como el coste y los sesgos (de muestra, género, edad...) que dificultan la robustez y generalización de los modelos sobreajustándolos.

A modo de conclusión, al comparar el panorama científico actual con nuestra propia investigación se observan tanto similitudes en la metodología como diferencias relevantes en la naturaleza y volumen de los datos. Por un lado, este trabajo comparte con estudios como los de Rajagopalan et al. y Ayub et al. el objetivo de reducir la dimensionalidad de los datos para construir modelos de predicción eficientes. En este sentido, en nuestro trabajo se emplean técnicas de selección de características de distinta naturaleza como E2EFS y RFE-SVM con el fin de identificar aquellos indicadores con mayor capacidad discriminativa. Asimismo, se siguen metodologías habituales en la literatura reciente, empleando algoritmos supervisados, métricas estándar y validación cruzada para garantizar la robustez de los modelos. Sin embargo, la diferencia principal reside en el origen y naturaleza de la información. Mientras que gran parte de los estudios dependen de bases de datos de gran tamaño de organizaciones públicas o de biomarcadores complejos y de alto coste (microbiota, EEG, neuroimágenes...), este trabajo nace de la práctica clínica diaria de una psicóloga: una muestra reducida de 209 individuos definida sobre aproximadamente 200 variables extraídas de información clínica y de 2 cuestionarios conductuales. Por tanto, el valor diferencial de este proyecto se encuentra en acercar el Aprendizaje Automático a la realidad de las consultas médicas.

Capítulo 3

Conjunto de Datos

Para la realización de este trabajo, se ha utilizado una base de datos clínica derivada de la investigación doctoral de Isabel García García en la Universidade da Coruña (UDC). En su tesis *"Indicadores tempranos de conducta adaptativa en niños con Autismo"* (2024) [22], se llevaron a cabo evaluaciones conductuales con el fin de identificar predictores del TEA a partir de instrumentos estandarizados como GARS-2 e ICAP, ampliamente utilizados en el ámbito clínico. Estos miden, por un lado, la conducta adaptativa (entendida como el conjunto de habilidades conceptuales, sociales y prácticas que permiten a una persona funcionar de forma autónoma y ajustarse a las exigencias de su entorno en el día a día) y, por otro, la sintomatología específica del paciente, evaluando alteraciones en la comunicación, interacción social y patrones del comportamiento característicos del autismo.

Debido a la naturaleza heterogénea del trastorno, la obtención de una muestra amplia resulta compleja, ya que los diagnósticos clínicos requieren evaluaciones prolongadas y la participación activa de los familiares. El dataset resultante presenta dos problemas principales que condicionan todo el trabajo posterior: una alta dimensionalidad, fruto de toda la información clínica, observaciones y cuestionarios, y un tamaño muestral reducido. En concreto, se dispone de 209 individuos anonimizados (111 diagnosticados con TEA y 98 pertenecientes a un grupo control), con edades comprendidas entre los 2 y 23 años y un total de 217 variables, incluyendo la variable objetivo.

En los siguientes apartados, se detalla la información relativa a la base de datos, la naturaleza de la muestra clínica empleada y la estructura de las variables e inventarios considerados, concluyendo con un Análisis Exploratorio de Datos fundamental para entender las particularidades y la distribución de la información antes de aplicar técnicas de modelado y preprocesamiento.

3.1 Descripción del dataset

3.1.1 Variables Clínicas y Sociodemográficas

En primer lugar, se encuentra un conjunto de 27 características que proporcionan el contexto sociodemográfico, médico y funcional de cada participante, sin pertenecer directamente a los instrumentos estandarizados ICAP o GARS-2. Salvo *Edad*, *Altura* y *Peso*, que son variables numéricas continuas, el resto son variables nominales u ordinales codificadas numéricamente. Estas variables resultan fundamentales para caracterizar a la muestra desde una perspectiva clínica integral y comprender los factores más generales del contexto del individuo que pueden influir en la manifestación del TEA.

Identificación, demografía y contexto. Cada participante se identifica mediante un código alfanumérico único (*Nombre*) que garantiza el anonimato. Las variables demográficas incluyen la edad (en años) y la franja etaria (agrupación en rangos de edad predefinidos), sexo (codificado como 1=hombre, 2=mujer), altura (en centímetros) y peso (en kilogramos). A mayores, se registra el país de procedencia (1=Uruguay, 2=Galicia), el tipo de institución educativa (1=Educación Especial, 2=Educación Ordinaria) y el estado legal del menor que indica si reside con su familia biológica, en acogida o en otra situación.

Diagnósticos. El diagnóstico primario (*Diag_primario*) constituye la variable objetivo del estudio, diferenciando entre individuos del grupo control (1) y con TEA (2). Además, se documentan hasta tres diagnósticos secundarios (*Diag_secundario*, *diag_sec2*, *diag_sec3*), reflejando la frecuente comorbilidad del TEA con condiciones como TDAH, discapacidad intelectual o trastornos del lenguaje.

Salud general y capacidades sensoriales. El estado de salud general se registra mediante la variable *Salud*, que mide en qué grado su estado limita sus actividades diarias. Se registran además la frecuencia con la que sufre epilepsia (*At_epilpticos*), medicación actual (*Medicamentos*), necesidad de atención médica regular (*Atencion_enfermero*) y presencia de enfermedad (*enfermedad*). Las capacidades sensoriales se evalúan con *Visión*, *Audición* y variables derivadas como *vis2c* y *Visaud*, que agrupan los niveles de afectación en dos categorías.

Movilidad, apoyos y comunicación. Se documenta el grado de autonomía motora (*Movilidad*), las ayudas técnicas necesarias (*Ayudas_movilidad*) y el nivel general de apoyos requeridos (*Apoyos*). El modo principal de expresión (*M_expresion*) distingue entre individuos verbales (2) y no verbales (1), mientras que *habla* registra específicamente si el participante tiene habla funcional

3.1.2 Inventario de Planificación de Servicios y Programación Individual (ICAP)

El Inventario para la Planificación de Servicios y Programación Individual (ICAP, por sus siglas en inglés) es un instrumento estandarizado ampliamente utilizado en contextos clínicos y educativos para evaluar la conducta adaptativa y los problemas de conducta en personas con trastornos del desarrollo (no solamente TEA) [23]. En este estudio se emplean 142 variables procedentes de este instrumento, organizadas en distintos bloques según el tipo de información que recogen.

Parte A: Conducta Adaptativa

La conducta adaptativa hace referencia a las habilidades que permiten a una persona desenvolverse de forma autónoma en su día a día, tanto a nivel personal como social. El ICAP evalúa estas habilidades mediante 77 ítems, los cuales son variables ordinales con 4 niveles de respuesta: 1 = nunca o rara vez, 2 = lo realiza aunque no bien, 3 = lo realiza bien, 4 = lo realiza muy bien. Estos se organizan en cuatro dominios fundamentales.

Habilidades Motoras. Evalúa tanto la motricidad gruesa como la fina, incluyendo la manipulación de objetos, el control postural, la locomoción (caminar, correr o saltar) y tareas como dibujar, escribir o utilizar herramientas sencillas.

Habilidades Sociales y Comunicativas. Incluye aspectos relacionados con la interacción social y la comunicación. Se evalúan habilidades como la expresión de emociones, la relación con otras personas, la participación en actividades grupales y el uso del lenguaje, desde palabras sueltas hasta conversaciones sencillas.

Habilidades de Vida Personal. Evalúa el nivel de autonomía del individuo en actividades básicas del día a día. Incluye aspectos como comer de forma independiente, usar cubiertos o comportarse adecuadamente en la mesa. También se tienen en cuenta hábitos de higiene, como lavarse las manos o el uso autónomo del baño. Se evalúa además la capacidad para vestirse sin ayuda. Por último, se consideran otras rutinas personales como la ducha y la toma de medicación sin supervisión.

Habilidades de Vida en Comunidad. Evalúa la capacidad de la persona para desenvolverse de forma autónoma fuera del entorno familiar, en entornos comunitarios. Incluye habilidades como usar el transporte público, manejar dinero, orientarse en el tiempo o realizar tareas domésticas básicas.

Puntuaciones agregadas. A partir de los ítems individuales de la Parte A se calculan ocho puntuaciones que resumen el rendimiento de cada participante en cada dominio adaptativo: *motoras* y *motorq* (habilidades motoras), *sociales* y *socialq* (habilidades sociales y comunicativas), *vitales* y *vitalq* (habilidades de vida personal) y *comunitarias* y *comunq* (habilidades

de vida en la comunidad). En cada caso, la primera variable es numérica continua y recoge la puntuación directa, mientras que la segunda es ordinal representando el cualificador resultante, que permite interpretar el nivel de funcionamiento del individuo respecto a la población de referencia.

Parte B: Problemas de Conducta

Esta sección evalúa ocho tipos de conductas problemáticas, registrando para cada una tanto la presencia (sí/no), la frecuencia de aparición y la gravedad de sus consecuencias, lo que genera 25 variables. Adicionalmente, se dispone de 20 versiones recodificadas de estas mismas variables con distinto número de categorías, generadas para facilitar análisis con diferentes granularidades. Cada conducta se registra mediante una variable nominal dicotómica de presencia (1 = no, 2 = sí) y dos ordinales de frecuencia y gravedad (3 niveles cada una).

Autolesiones. Conductas en las que el individuo se causa daño físico a sí mismo, como golpearse, morderse, arañarse o cualquier forma de agresión autodirigida. La severidad se clasifica según la intensidad y las consecuencias del comportamiento.

Heteroagresividad. Comportamientos agresivos dirigidos hacia otras personas, incluyendo golpes, empujones, mordiscos, pellizcos o cualquier forma de violencia física hacia terceros.

Destrucción de Propiedad. Conductas que dañan intencionalmente objetos, mobiliario, materiales o pertenencias, tanto propias como ajenas.

Conducta Disruptiva. Comportamientos que interfieren significativamente con el funcionamiento del entorno, tales como gritos, rabietas, llantos prolongados o negativa sistemática a seguir instrucciones.

Autoconductas y Hábitos Atípicos. Conductas repetitivas o estereotipadas sin función aparente, como balanceos corporales, movimientos repetitivos de manos, autoestimulación sensorial u otras estereotipias motoras.

Retraimiento y Evitación. Conductas de aislamiento social activo, evitación sistemática de interacciones sociales, falta de respuesta a estímulos sociales o retraimiento emocional marcado.

Conducta Ingestiva Atípica. Comportamientos alimentarios problemáticos que incluyen la ingestión de objetos no comestibles, rechazo alimentario extremo, restricciones alimentarias severas o rituales alimentarios disfuncionales.

Hábitos No Controlados. Conductas relacionadas con falta de control de esfínteres u otros hábitos corporales que interfieren con la adaptación social del individuo.

Variables Complementarias de Servicios y Actividades

Existen 8 variables del ICAP que recogen información contextual sobre la ubicación residencial actual y la recomendada, los servicios de día actuales y recomendados, los servicios de apoyo utilizados y los que convendría estudiar, las actividades sociales y de ocio realizadas el mes anterior y los factores que limitan la participación social.

La Tabla 3.1 presenta en más detalle las variables del ICAP organizadas por secciones y dominios.

Tabla 3.1: Variables ICAP organizadas por secciones y dominios.

Grupo	Variables	Descripción
PUNTUACIONES AGREGADAS (8 variables)		
Motoras* / *Sociales* / *Vida Personal* / *Comunitaria	`motoras, motorq, sociales, socialq, vitales, vitalq, comunitarias, comunq`	Puntuación total y cualificador por dominio adaptativo (motoras, sociales, vida personal y comunitaria).
PARTE A: CONDUCTA ADAPTATIVA — Habilidades Motoras (18 variables)		
Motricidad Global	`coger_objetos, Pasa_objetos, …, sube_y_baja_escaleras, sube_escalera_dos_metros`	Ítems 1.1–1.12: Prensión, transferencia, postura, locomoción y escalada.
Manipulación y Grafomotricidad	`tijera_linea_recta, escribe_nombre, …, sobla_carta_tres, arma_objetos_diez_piesas`	Ítems 1.13–1.18: Tijeras, escritura, manejo de herramientas y ensamblaje de piezas.
PARTE A: CONDUCTA ADAPTATIVA — Habilidades Sociales y Comunicativas (19 variables)		
Reciprocidad Social	`Emite_somidos_gesticula, tiende_brazos, …, esperar_turno, ofrece_ayuda`	Ítems 2.1–2.12: Contacto social, imitación, entrega de objetos, turnos y ayuda a otros.
Comunicación	`comporta_adecuadamente, …, Escribe_a_mano, Llama_servicio`	Ítems 2.13–2.19: Conducta pública, señales, narración, comunicación escrita y telefónica.
PARTE A: CONDUCTA ADAPTATIVA — Habilidades de Vida Personal (21 variables)		
Alimentación e Higiene	`traga_alimentos, …, enjabona_pelo, friega_seca_paltos`	Ítems 3.1–3.15: Ingesta, higiene personal, uso autónomo del baño, lavado y secado.

Continúa en la siguiente página...

Tabla 3.1 – *Continuación de la página anterior*

Grupo	Variables	Descripción
Vestido y Hogar	`prepara_comida`, `arregla_dormitorio`, …, `planifica_comida`, `repara_su_ropa`	Ítems 3.16–3.21: Preparación de comidas, mantenimiento del hogar y reparaciones.
PARTE A: CONDUCTA ADAPTATIVA — Habilidades Vida Comunitaria (19 variables)		
Orientación y Autonomía	`Encuentra_juguetes`, `va_solo_cuarto`, …, `barrio_curza_calles`, `recados_bien`	Ítems 4.1–4.9: Localización de objetos, instrucciones y desplazamiento autónomo.
Gestión y Responsabilidad	`fecha_nacimiento`, `Utiliza_reloj`, …, `recibe_facturas_paga`, `hace_balance_mensual`	Ítems 4.10–4.19: Datos personales, reloj, dinero, formularios y gestión económica.
PARTE B: PROBLEMAS DE CONDUCTA (25 variables)		
Daño físico y Entorno	`comportamineto_autolesivo`, …, `heteroagresividad_a_otros`, …, `destruccion_objetos`, …, `conducta_disruptiva`, …	12 variables: presencia, frecuencia y gravedad de autolesiones, heteroagresividad, destrucción de objetos y conducta disruptiva.
Hábitos, Aislamiento y Social	`habitos_atipicos`, …, `Retraimiento_atencion`, …, `conducta_ofensiva`, …, `conductas_no_colaboradoras`, …	13 variables: hábitos atípicos, retraimiento, conducta ofensiva, no colaboración y reacción del entorno.
PARTE B: RECODIFICACIONES (20 variables)		
Frecuencia y Gravedad	`Frec_autoles3`, `grav_autoles2`, `grav_autoles3`, `frec_hetragrs3`, …, `Frec_nocol2`, `grav_nocol2`, `reac_condprb3`	Versiones recodificadas de frecuencia (11 var., 2–4 niveles) y gravedad (9 var., 2–3 niveles).
COMPLEMENTARIAS: SERVICIOS Y ACTIVIDADES (8 variables)		
Residencia y Servicios	`Ubicación_residencia`, …, `servicios_apoyo_a_estudiar`, `serv_act2`, `serv_apoyact3`	Ubicación residencial, servicios de día y de apoyo actuales y recomendados.
Actividades	`actividades_mes_pasado`, …, `actsococ2`, `act_sococ3`, `act_lim3`	Participación en actividades sociales y de ocio y factores limitantes.

3.1.3 Escala de Evaluación del Autismo de Gilliam (GARS-2)

La Escala de Evaluación del Autismo de Gilliam, Segunda Edición (GARS-2) es un instrumento estandarizado diseñado específicamente para identificar y evaluar la sintomatología característica del Trastorno del Espectro Autista [24]. Consta de 42 ítems distribuidos en tres subescalas que corresponden a las áreas principales de afectación en el TEA según los criterios diagnósticos establecidos: conductas estereotipadas, alteraciones en la comunicación y déficits en la interacción social.

Cada ítem se puntúa en función de la frecuencia de aparición de la conducta observada en un período de observación de 6 horas en contextos naturales. La escala de respuesta comprende cuatro opciones: 1 = no se ha observado nunca, 2 = se ha observado rara vez (1–2 veces en 6 horas), 3 = se ha observado algunas veces (3–4 veces en 6 horas), y 4 = se ha observado frecuentemente (al menos 5–6 veces en 6 horas). Las puntuaciones se pueden combinan tanto por subescala como en un Índice de Autismo global que facilita la interpretación diagnóstica.

Aunque la validez de algunas subescalas del GARS-2 ha sido cuestionada, diversos estudios respaldan su utilidad cuando se emplea junto a otras herramientas de evaluación. En este sentido, en su tesis doctoral, García-García [22] observó que la combinación del GARS y el ICAP permitió clasificar correctamente el 75.1% de los casos analizados, lo que refuerza su interés como instrumentos complementarios en la valoración del TEA.

Subescala 1: Conductas Estereotipadas

Esta subescala evalúa patrones de comportamiento restrictivos y repetitivos. Incluye 14 ítems que abarcan estereotipias motoras, sensoriales y conductuales.

Se incluyen conductas como evitar el contacto visual o fijar la mirada en objetos de forma prolongada, así como movimientos repetitivos relacionados con la autoestimulación. También se recogen hábitos poco habituales, como oler objetos de forma repetida o presentar conductas alimentarias atípicas, desde una alta selectividad hasta el intento de ingerir elementos no comestibles. En el plano motor, se observan comportamientos como girar sobre uno mismo, balancearse, manipular objetos de forma repetitiva, caminar de puntillas o agitar las manos. Finalmente, se evalúan vocalizaciones repetitivas sin función comunicativa y conductas autolesivas como golpearse o morderse.

Subescala 2: Comunicación

Evalúa 14 alteraciones características en la comunicación verbal y no verbal presentes en el TEA. Este dominio es particularmente relevante dada la heterogeneidad comunicativa del espectro, que incluye desde individuos no verbales hasta aquellos con lenguaje fluido pero pragmáticamente alterado.

La ecolalia, tanto inmediata como diferida, aparece con frecuencia junto a la repetición insistente de palabras o frases. También se tienen en cuenta aspectos del habla como el tono, el ritmo y la entonación. En cuanto al uso del lenguaje en situaciones sociales, se observan dificultades como responder de forma inadecuada a órdenes sencillas, no reaccionar al nombre, no pedir cosas de manera espontánea o mostrar poca iniciativa para comunicarse. Además, pueden aparecer errores en el uso del lenguaje, como confundir afirmaciones y negaciones, invertir pronombres o utilizar de forma incorrecta el pronombre "yo", así como emitir balbuceos ininteligibles. Por último, se registra también la preferencia por gestos sobre el lenguaje oral y las dificultades en la comprensión de narraciones breves.

Subescala 3: Interacción Social

Esta subescala evalúa 14 dificultades relacionadas con la interacción social y la forma en que la persona se relaciona con los demás, aspectos clave en el TEA.

Se observa, por ejemplo, la evitación del contacto visual y la falta de expresiones emocionales adecuadas cuando se recibe atención. También se tienen en cuenta conductas como el rechazo al contacto físico, la escasa imitación de otras personas o una tendencia al aislamiento social. En el plano emocional, pueden aparecer miedos excesivos, poca reciprocidad afectiva o dificultades para reconocer la presencia de otros. Asimismo, se incluyen comportamientos socialmente poco adecuados, como reír o gritar sin motivo aparente o utilizar objetos de forma inusual. Se completa la subescala evaluando la rigidez en la conducta, que se manifiesta en rutinas repetitivas, resistencia a los cambios, respuestas negativas ante indicaciones y la necesidad de mantener el orden de los objetos de forma estricta.

Puntuaciones agregadas

A partir de los ítems individuales se calculan seis variables resumen: *estereotip* y *estereotipq* (puntuación total y cualificador de conductas estereotipadas), *comunic* y *comunicq* (puntuación total y cualificador de comunicación), e *intsoc* e *intsocq* (puntuación total y cualificador de interacción social). Los cualificadores permiten interpretar el nivel de afectación del individuo en cada dominio respecto a la población de referencia. Mientras que los ítems individuales y los cualificadores son variables ordinales, las puntuaciones agregadas son numéricas continuas.

La Tabla 3.2 detalla los 42 ítems del GARS-2 organizados por subescalas, así como las puntuaciones agregadas.

Tabla 3.2: Variables GARS-2 – Ítems individuales de evaluación del autismo.

Grupo	Variables	Descripción
PUNTUACIONES AGREGADAS (6 variables)		
Estereotipias / Comunicación / Interacción	`estereotip, estereotipq, comunic, comunicq, intsoc, intsocq`	Puntuación total y cualificador de cada subescala (estereotipias, comunicación e interacción social).
SUBESCALA 1: CONDUCTAS ESTEREOTIPADAS (14 ítems)		
Estímulos visuales y olfativos	`evita_contacto_ocular, mirar_manos, Chasquea_dedos, huele_objetos`	Ítems 1.1–1.3, 1.6: Evitación visual, fijación en objetos, chasqueo de dedos y conducta olfativa.
Conducta alimentaria y estereotipias motoras	`Come_alimentos_especificos, …, gira_vuelta_circulos, …, agita_manos`	Ítems 1.4–1.5, 1.7–1.12: Selectividad alimentaria, ingesta atípica y estereotipias motoras.
Vocalizaciones y autolesiones	`Sonidos_repetitivos, se_golpea`	Ítems 1.13–1.14: Vocalizaciones autoestimulatorias y conductas autolesivas.
SUBESCALA 2: COMUNICACIÓN (14 ítems)		
Ecolalia y prosodia	`repite_palabras_eco, …, Repita_frases, habla_señala_tono_apagado`	Ítems 2.15–2.18: Ecolalia inmediata, diferida, perseveración verbal y alteraciones prosódicas.
Déficits pragmáticos	`responde_inapropiadamente, …, no_pregunta, no_inicia_conversaciones`	Ítems 2.19–2.22: Respuesta a órdenes, atención al nombre, peticiones e iniciativa comunicativa.
Alteraciones gramaticales y no verbales	`utiliza_inapropiadamente_palabras …, utiliza_gesto_no_habla, …`	Ítems 2.23–2.28: Sí/no, pronombres, balbuceo, comunicación gestual y comprensión narrativa.
SUBESCALA 3: INTERACCIÓN SOCIAL (14 ítems)		
Contacto, imitación y aislamiento	`mira_lejos_cuando_se_lo_mira, …, no_imita_otros, permanece_apartado`	Ítems 3.29–3.33: Evitación visual, contacto físico, imitación y aislamiento grupal.
Respuesta emocional, conductas inapropiadas y rigidez	`comporta_manera_irrazonable, poco_afectuoso, …, hacer_cosas_repetidamente, altera_cambio_rutinas, …, ordena_objetos_lineas`	Ítems 3.34–3.42: Reacciones emocionales, falta de reciprocidad afectiva, conductas inapropiadas, rituales, resistencia a cambios de rutina, oposición a órdenes y necesidad de orden exacto.

3.2 Análisis Exploratorio de Datos

El Análisis Exploratorio de Datos tiene como objetivo comprender la estructura del conjunto de datos, identificar patrones y relaciones entre variables, y detectar problemas potenciales (valores ausentes, desbalanceo de clases o redundancia entre variables) que se abordarán en la fase posterior de preprocesamiento. Todos estos aspectos que se tratarán en detalle a continuación cobran aún más importancia cuando se conoce que el dataset proviene de 2 cuestionarios diferentes, que han sido recogidos en dos países distintos (Uruguay y Galicia).

3.2.1 Estructura y dimensión del dataset

El conjunto de datos está formado por **209 participantes** y **217 variables**, incluyendo la variable objetivo. Esta relación de aproximadamente una variable por individuo implica una alta dimensionalidad que, combinada con el tamaño muestral reducido, llevará a decisiones específicas de selección de características en fases posteriores.

Desde el punto de vista del tipo de dato, 213 variables son numéricas codificadas: la gran mayoría son escalas ordinales procedentes de los instrumentos ICAP y GARS-2 (con respuestas del 1 al 4), mientras que el resto son variables categóricas con etiquetas de valor o puntuaciones agregadas. Las únicas variables continuas son *Edad*, *Altura* y *Peso*. La variable *Nombre* actúa como identificador alfanumérico anónimo y se excluirá de nuestro trabajo ya que no es útil para el análisis o la clasificación.

En cuanto a la composición, las 216 variables predictoras se distribuyen entre los bloques del ICAP (142 variables), el GARS-2 (48 variables) y las variables clínicas y sociodemográficas (26 variables) descritas en la sección anterior 3.1.

3.2.2 Caracterización de la muestra respecto a la variable objetivo

Distribución de clases

La variable objetivo *Diag_primario* distingue entre dos grupos: individuos con diagnóstico de TEA (111 casos, 53.1%) y participantes del grupo control (98 casos, 46.9%), con un ratio de 1.13. El desbalanceo es leve —una diferencia de 6.2 puntos porcentuales— y no hace necesario el uso de técnicas de remuestreo. Sin embargo, a la hora de seleccionar las métricas de evaluación de los modelos se priorizan medidas como el F1-score o el área bajo la curva ROC frente a la *accuracy* simple, poco representativa en escenarios desbalanceados.

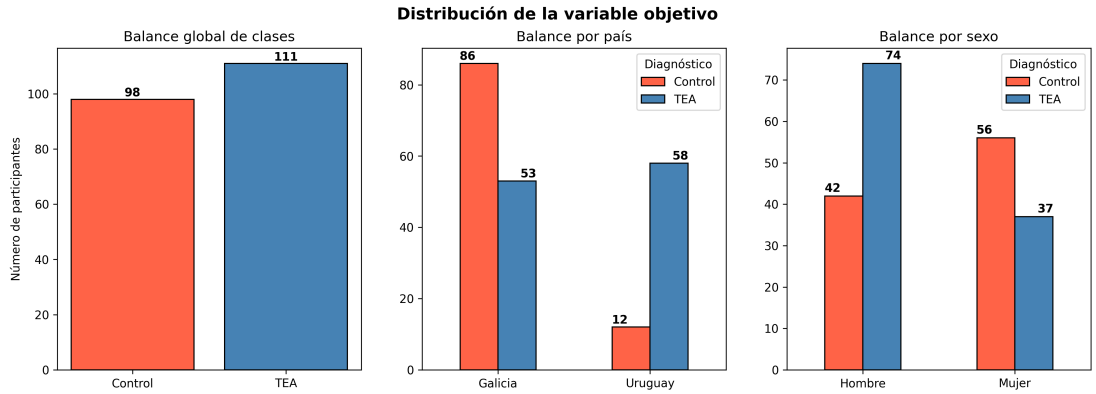


Figura 3.1: Distribución de la variable objetivo por diagnóstico global (izquierda), país de procedencia (centro) y sexo (derecha).

Distribución por país

La muestra proviene de dos contextos geográficos distintos: 139 participantes de Galicia (66.5%) y 70 de Uruguay (33.5%). La distribución de diagnósticos es notablemente distinta entre ambas submuestras: mientras que en Galicia el grupo control es el predominante con 86 controles frente a 53 casos de TEA, en Uruguay ocurre la situación opuesta, con 58 casos TEA frente a tan solo 12 controles. Esta diferencia se debe a un sesgo en la recogida: la submuestra uruguaya se obtuvo en su mayor parte en centros de educación especial (60 frente a 10 de educación ordinaria), donde la proporción de individuos que presentan el trastorno es naturalmente más elevada, mientras que la gallega incluye más casos de centros de educación ordinaria (94 de educación especial y 45 de ordinaria).

Distribución por sexo

La distribución por sexo es de 116 hombres (55.5%) y 93 mujeres (44.5%). La proporción de diagnósticos difiere notablemente entre sexos: entre el sexo masculino hay 74 casos TEA frente a 42 controles (63.8%), mientras que entre el femenino ocurre lo contrario, con 56 controles y 37 TEA (39.8%). El diagnóstico de TEA resulta por tanto más frecuente en hombres en esta muestra, lo que concuerda con la mayor prevalencia masculina habitualmente descrita en la literatura epidemiológica [25].

Distribución por edad

La muestra presenta una marcada concentración en las franjas de edad más jóvenes, con la mayoría de los participantes entre los 5 y 11 años, como se observa en la Figura 3.2. El diagnóstico de TEA es más frecuente en edades tempranas, lo que es coherente con la literatura

clínica, que indica que la detección suele producirse durante los primeros años de escolarización. La variable *franja_etaria* —que agrupa la edad en categorías predefinidas— presenta 100 valores nulos de 209 (47.8%), todos ellos situados en la submuestra gallega según el análisis del apartado 3.2.3, por lo que se trabaja exclusivamente con la edad continua.

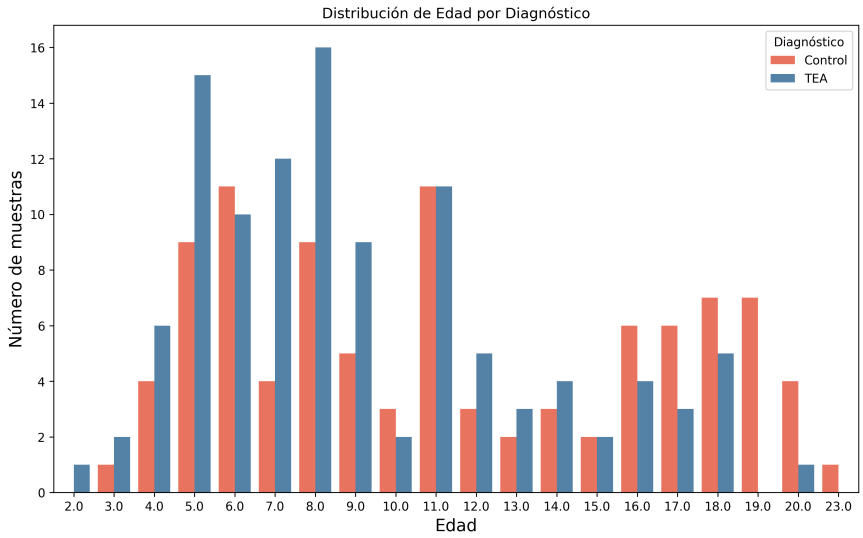


Figura 3.2: Distribución de la edad por grupo diagnóstico.

Distribución por altura y peso

La Figura 3.3 muestra la relación entre altura y peso coloreada por diagnóstico. No se aprecian diferencias sistemáticas entre grupos, lo que resulta esperable dado que ambas variables dependen principalmente de la edad del participante y no del diagnóstico.

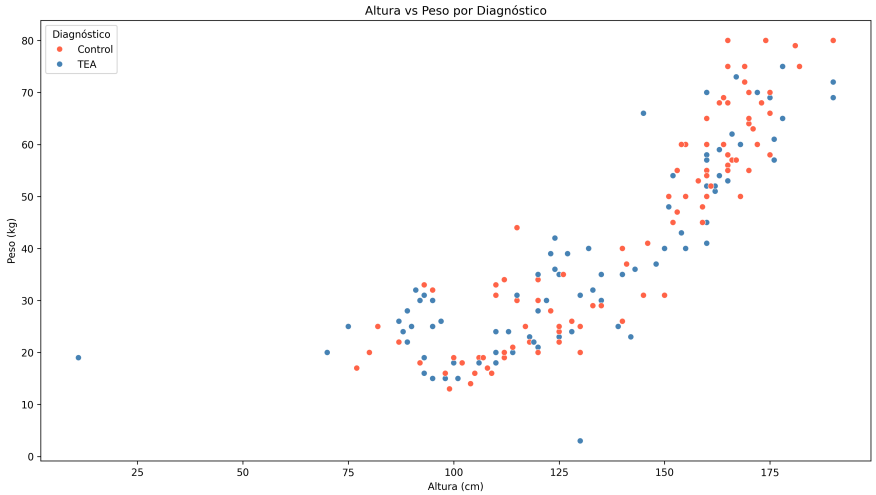


Figura 3.3: Diagrama de dispersión altura-peso por grupo diagnóstico.

Distribución por modo de expresión y nivel de apoyos

Dentro de las características funcionales que pueden diferenciar a los dos grupos de participantes existen dos especialmente relevantes, cuya distribución se visualiza en la Figura 3.4. En cuanto al modo de expresión, una proporción considerablemente mayor de individuos con TEA se comunica de forma no verbal respecto al grupo control: aproximadamente el 25% frente al 6% del grupo control. En cuanto al nivel de apoyos requeridos, se observa que el grupo TEA requiere apoyos con mayor frecuencia, aunque la diferencia es moderada. Sin embargo, en ambos grupos esto resulta muy poco frecuente en comparación con la cantidad de participantes que no necesitan apoyos.

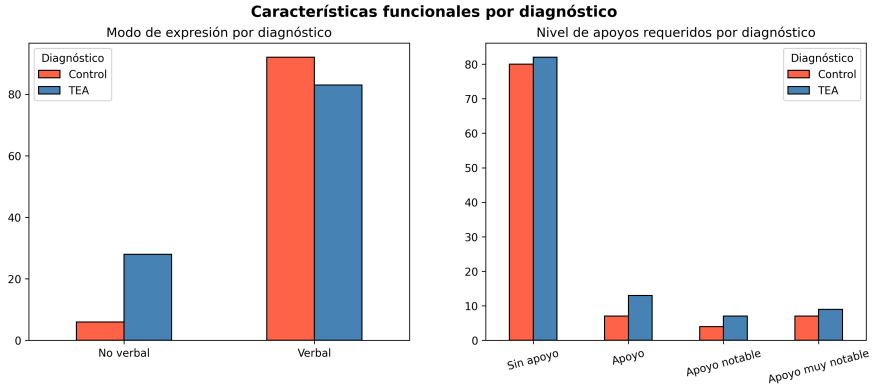


Figura 3.4: Distribución del modo de expresión (izquierda) y del nivel de apoyos requeridos (derecha) por grupo diagnóstico.

3.2.3 Análisis de valores ausentes

En total, 48 de las 217 variables presentan algún valor ausente. De ellas, 25 superan el 50% de valores nulos y otras 20 presentan una tasa de ausencia ligeramente inferior al 50%. Entre estas últimas se encuentran las puntuaciones agregadas oficiales que proporcionan el ICAP y el GARS-2 —como *motoras*, *sociales*, *estereotip* o *comunic*—, con valores en torno al 48–50% de nulos. Esta limitación se retoma en el apartado 3.2.4, donde se justifica la decisión de calcular índices propios en lugar de usar estas puntuaciones directamente.

Como se aprecia en la Figura 3.5, la distribución de los valores ausentes no es aleatoria: la matriz de ausencias muestra un patrón en bloques claramente definido que apunta a un origen de los datos desigual.

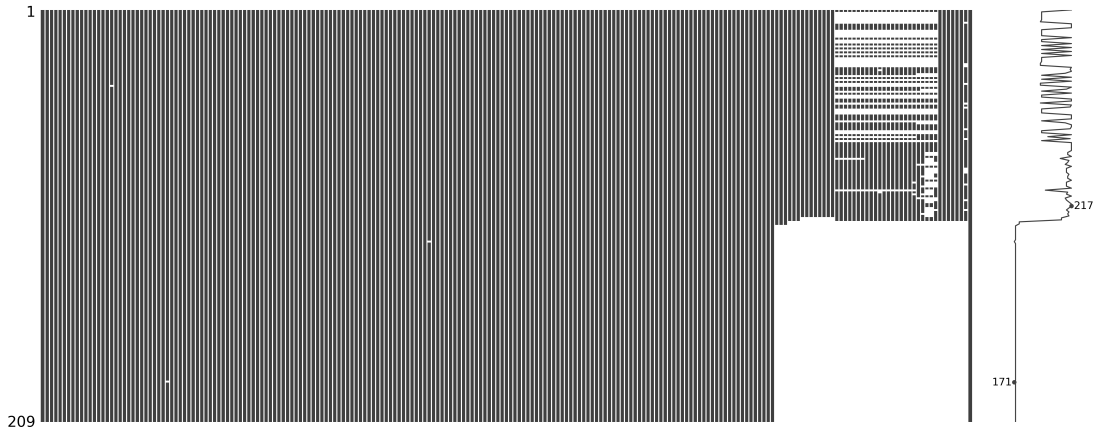


Figura 3.5: Matriz de valores ausentes del dataset. Cada columna representa una variable y cada fila un participante. Las franjas blancas indican valores nulos.

El análisis estratificado por país revela el origen de este patrón: prácticamente la totalidad de las variables con más del 50% de nulos presentan un 98.6% de ausencias en la submuestra gallega frente a menos de un 5% en la uruguaya, lo que indica que estas variables solo fueron tomadas sistemáticamente en Uruguay. Además, las puntuaciones agregadas del ICAP y del GARS-2 son exclusivas de la submuestra gallega y están completamente ausentes en la uruguaya. La Tabla 3.3 detalla los porcentajes para las variables más representativas.

Tabla 3.3: Resumen de variables con alta tasa de valores ausentes (>50%) estratificado por país.

Grupo	**Variables**	**Galicia (%)**	**Uruguay (%)**
Recodif. ICAP Parte B	`Frec_autoles3`, `grav_autoles3`, `grav_autoles2`, `frec_hetragrs3`, `grav_hetragr2`, `frec_destr3`, `frec_destr2`, `frec_disr3`, `grav_disr3`, `grav_disr2`, `frec_rep3`, `frec_ofens4`, `grav_ofens2`, `frec_retrm3`, `grav_retrm3`, `Frec_nocol3`, `Frec_nocol2`, `grav_nocol2`, `reac_condprb3`	98.6	2.9–5.7
Compl. servicios ICAP	`serv_act2`, `serv_apoyact3`, `act_sococ3`, `actsococ2`, `act_lim3`	98.6	5.7–41.4
Comunicación	`habla`	77.0	12.9

Este patrón corresponde a lo que en la literatura estadística se denomina *Missing Not At Random* (MNAR) [26]. En él, la probabilidad de que un dato esté ausente está relacionada directamente con el propio valor de la variable que presenta los datos faltantes, y no puede explicarse únicamente a partir del resto de variables observadas en el dataset. Este tipo de ausencia es el más problemático desde el punto de vista del modelado, ya que la imputación basada únicamente en los valores observados puede introducir sesgos si no se tiene en cuenta el mecanismo subyacente. Por ello, en la fase de preprocesamiento se evaluará la posibilidad de excluir las variables con un porcentaje de nulos elevado, así como el uso de estrategias de imputación que respeten la estructura dual de la muestra.

3.2.4 Análisis de correlación y agrupación en bloques funcionales

Correlación global

El mapa de calor de la Figura 3.6 muestra la correlación entre todas las variables numéricas del dataset. Se aprecian con claridad varios bloques diagonales de correlación elevada, que corresponden a los grupos de ítems pertenecientes a un mismo dominio del ICAP o del GARS-2. Este patrón evidencia un alto grado de redundancia interna que motiva la reducción de dimensionalidad en fases posteriores, a la vez que la posibilidad de resumir cada dominio mediante un único índice representativo sin perder información sustancial.

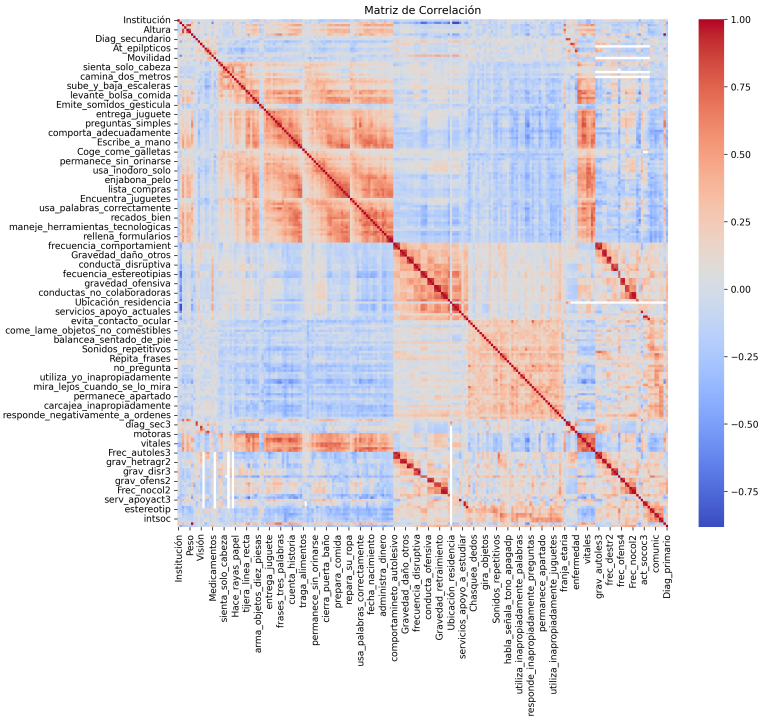


Figura 3.6: Mapa de calor de correlaciones entre todas las variables numéricas del dataset.

Agrupación en bloques funcionales

Este patrón de correlación interna, combinado con el problema de valores ausentes descrito en el apartado 3.2.3, motiva la creación de 11 índices calculados a partir del promedio de los ítems individuales de un dominio. Como se señaló anteriormente, el ICAP y el GARS-2 ya proporcionan puntuaciones agregadas oficiales por dominio (*motoras*, *sociales*, *comunic*, *estereotip*...), pero estas presentan aproximadamente un 48–50% de valores nulos concentrados en una sola de las submuestras, lo que limita su utilidad para el análisis conjunto. Los índices propios, calculados directamente desde los ítems individuales disponibles para la totalidad de la muestra, resuelven este problema.

Los bloques resultantes son: cuatro dominios de conducta adaptativa del ICAP-A (*icap_motoras*, *icap_sociales*, *icap_vida_personal*, *icap_comunidad*), tres bloques de conductas problemáticas del ICAP-B (*icap_conducta_daño*, *icap_conducta_entorno*, *icap_conducta_habitos*), las tres subescalas del GARS-2 (*gars2_estereotipias*, *gars2_comunicacion*, *gars2_interaccion*) y un índice clínico-funcional de apoyo. Cada índice se obtiene como la media aritmética de los ítems del bloque correspondiente.

Correlación entre bloques funcionales

La Figura 3.7 muestra el mapa de calor de correlaciones de Spearman entre los 11 índices de bloque. Se distinguen con claridad dos grandes grupos: los cuatro dominios de conducta adaptativa del ICAP-A presentan correlaciones positivas altas entre sí, lo que indica que los participantes con mayor autonomía en un dominio tienden a tenerla también en los demás. Los bloques de conducta problemática del ICAP-B y las subescalas del GARS-2 forman un segundo cluster, también con correlaciones positivas internas. Entre ambos clusters la correlación es negativa: a mayor nivel adaptativo, menor presencia de conductas problemáticas y síntomas TEA, patrón clínicamente coherente que confirma que la división por bloques es adecuada.

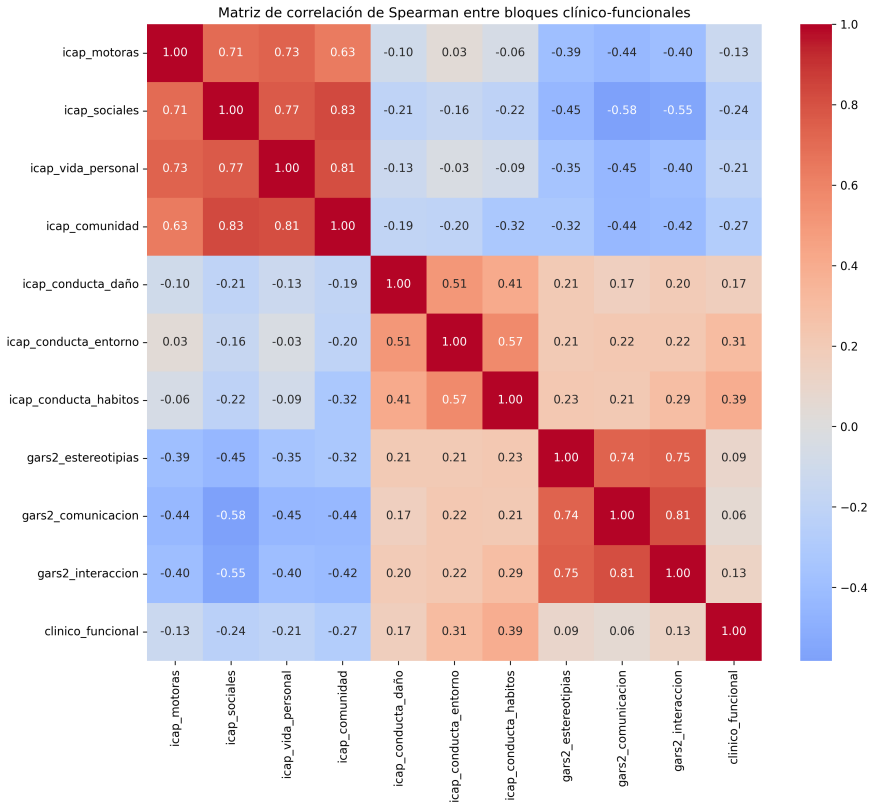


Figura 3.7: Mapa de calor de correlaciones de Spearman entre los 11 índices de bloque funcional.

3.2.5 Análisis de los cuestionarios estandarizados

ICAP: comparación TEA vs. Control

La Figura 3.8 muestra los boxplots de los siete índices ICAP por grupo diagnóstico. En los cuatro dominios de conducta adaptativa (motoras, sociales, vida personal y vida comunitaria) el grupo TEA obtiene puntuaciones medias más bajas que el grupo control, lo que refleja un menor nivel de autonomía e independencia funcional. La diferencia es especialmente pronunciada en las habilidades sociales y comunitarias, dominios directamente relacionados con aspectos centrales donde se manifiesta el trastorno. En los bloques de conductas problemáticas ocurre el patrón contrario: el grupo TEA presenta puntuaciones más elevadas, indicando una mayor frecuencia y gravedad de conductas como autolesiones, conductas disruptivas o estereotipias.

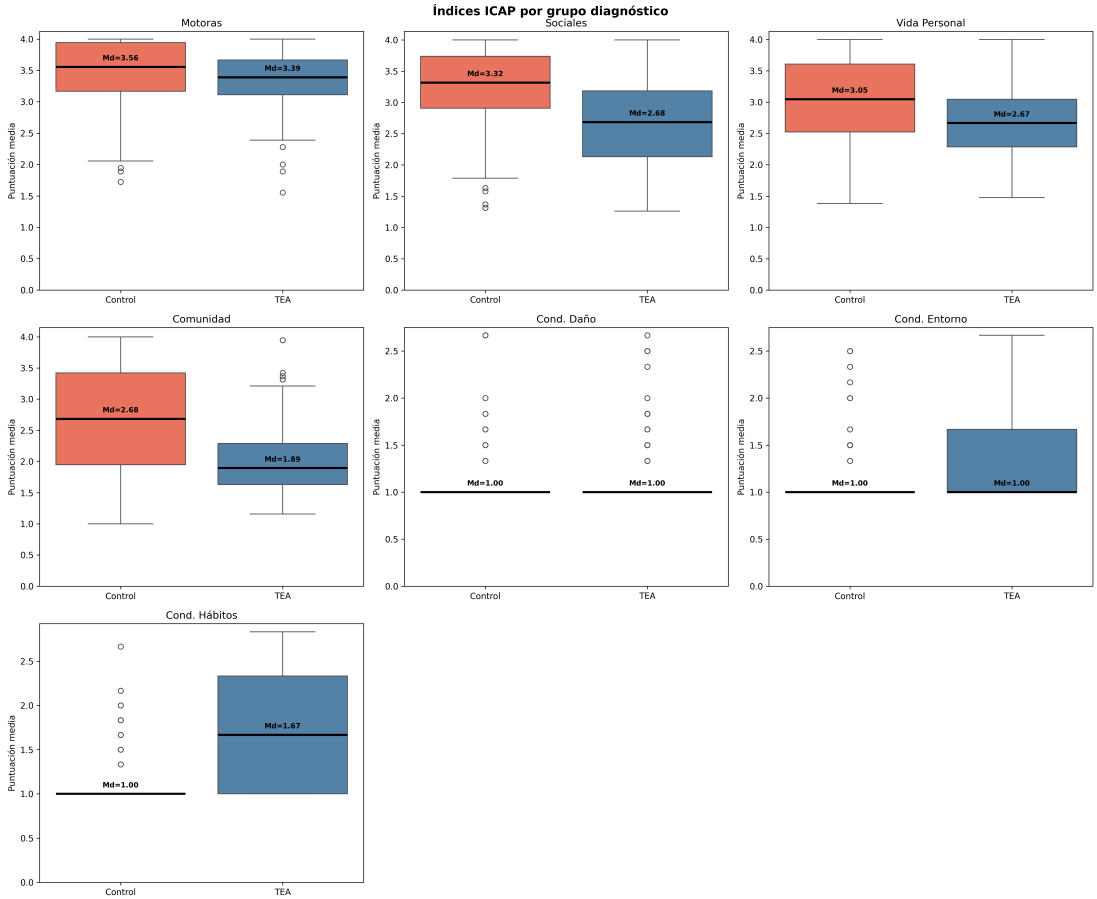


Figura 3.8: Boxplots de los índices ICAP por grupo diagnóstico.

Los violinplots de la Figura 3.9 complementan esta visión mostrando la forma completa de cada distribución, donde destaca la mayor dispersión interna del grupo TEA en los bloques de conducta adaptativa, coherente con la heterogeneidad característica del trastorno.

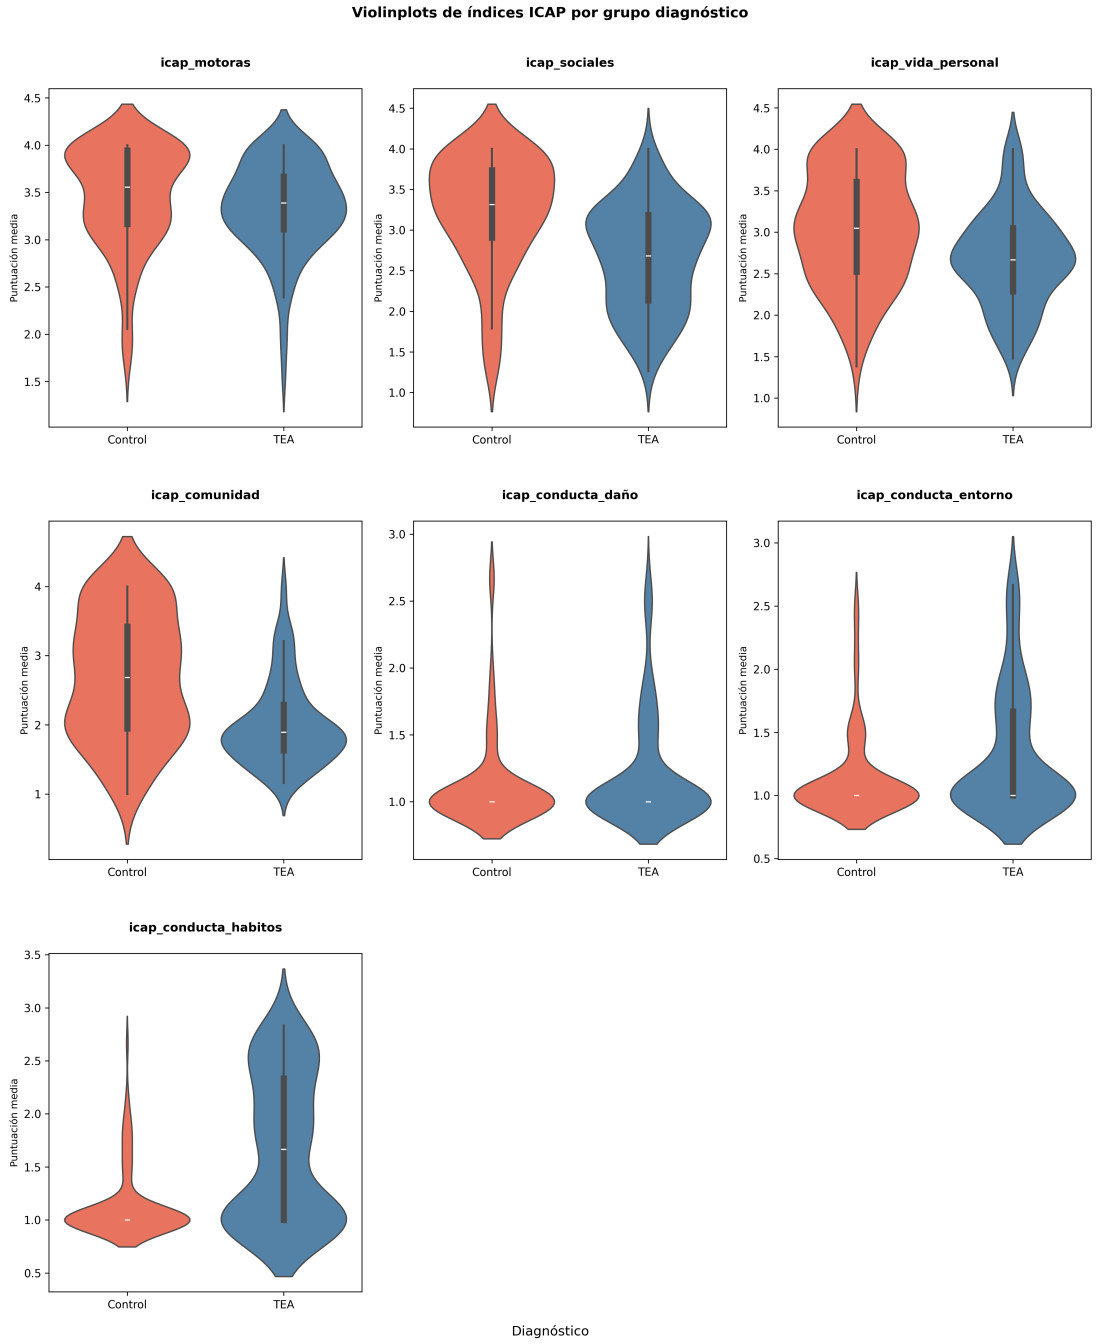


Figura 3.9: Violinplots de los índices ICAP por grupo diagnóstico.

GARS-2: comparación TEA vs. Control

La Figura 3.10 muestra los boxplots de las tres subescalas del GARS-2. En las tres dimensiones —conductas estereotipadas, comunicación e interacción social— el grupo TEA obtiene

puntuaciones notablemente más altas que el grupo control, lo cual es coherente con la naturaleza del instrumento: evaluar la sintomatología nuclear del trastorno, siendo esperable que discrimine bien entre ambos grupos. La diferencia más pronunciada se observa en las subescalas de comunicación e interacción social, al igual que ocurre en el ICAP. Los violinplots de la Figura 3.11 confirman que la separación entre grupos es más nítida en GARS-2 que en los bloques ICAP, lo que anticipa que estas variables tendrán un mayor peso discriminativo en los modelos de clasificación.

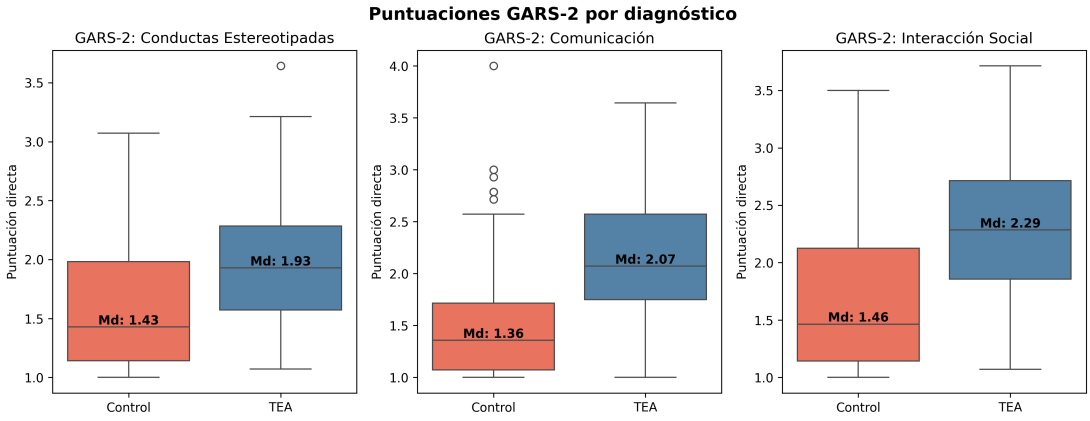


Figura 3.10: Boxplots de las tres subescalas GARS-2 por grupo diagnóstico.

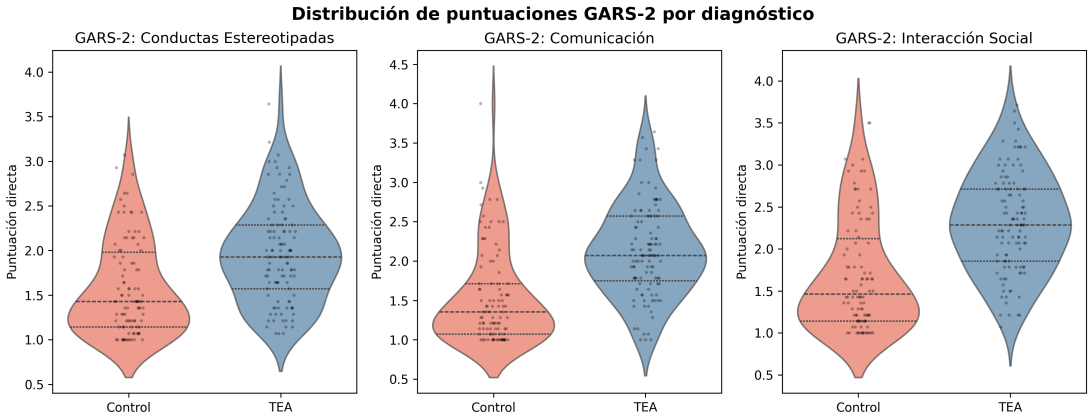


Figura 3.11: Violinplots de las subescalas GARS-2.

3.2.6 Separabilidad entre clases

Para evaluar si los dos grupos diagnósticos son visualmente separables en el espacio de características, se aplican tres técnicas de reducción de dimensionalidad a dos dimensiones. El análisis se realiza en dos condiciones: con las 216 variables originales (Figura 3.12) y con los 11 índices de bloque funcional (Figura 3.13).

- **Análisis de Componentes Principales (PCA)** [27]. Transforma el espacio original en un nuevo conjunto de ejes ortogonales —las componentes principales— ordenados de mayor a menor varianza explicada. Cada componente es una combinación lineal de las variables originales y la proyección sobre las dos primeras permite visualizar la mayor parte de la variabilidad del dataset en un plano 2D. Al ser una técnica determinista y lineal, PCA es sensible a la estructura global de los datos pero no captura relaciones no lineales entre variables. Para visualización, basta con fijar a 2 el número de componentes principales sin requerir el ajuste de más hiperparámetros.

- **t-SNE** [28] (*t-distributed Stochastic Neighbor Embedding*). Modela las similitudes entre puntos como probabilidades y busca una proyección 2D que preserve las relaciones de vecindad local, minimizando la divergencia KL entre la distribución de similitudes en el espacio original y en el espacio reducido. Para este análisis se han utilizado los valores por defecto de la librería *scikit-learn*: una perplejidad (*perplexity*) de 30, una tasa de aprendizaje (*learning_rate*) de 200 y el uso de la distancia euclídea como métrica. Es especialmente eficaz para detectar agrupaciones locales, aunque las distancias entre grupos distintos no son directamente interpretables.

- **UMAP** [29] (*Uniform Manifold Approximation and Projection*). Parte de la teoría de variedades topológicas: asume que los datos de alta dimensión residen en una variedad de baja dimensión y construye una aproximación de esa estructura mediante un grafo ponderado de vecindades. Se han empleado los parámetros estándar de la implementación *umap-learn*: un número de vecinos ($n_neighbors$) de 15, una distancia mínima (min_dist) de 0,1 y distancia euclídea. Equilibra la preservación de la estructura local —como t-SNE— y la estructura global de la distribución, produciendo proyecciones más estables e interpretables.

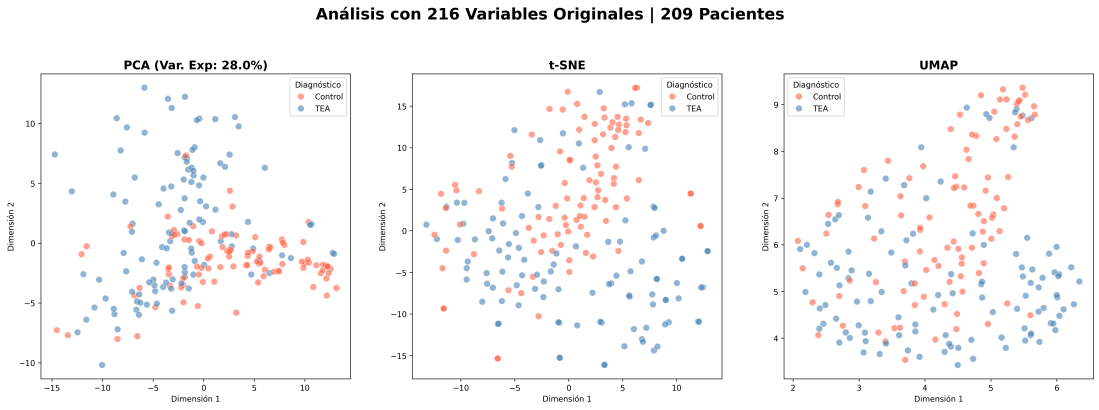


Figura 3.12: Proyecciones PCA, t-SNE y UMAP con las 216 variables originales, coloreadas por grupo diagnóstico.

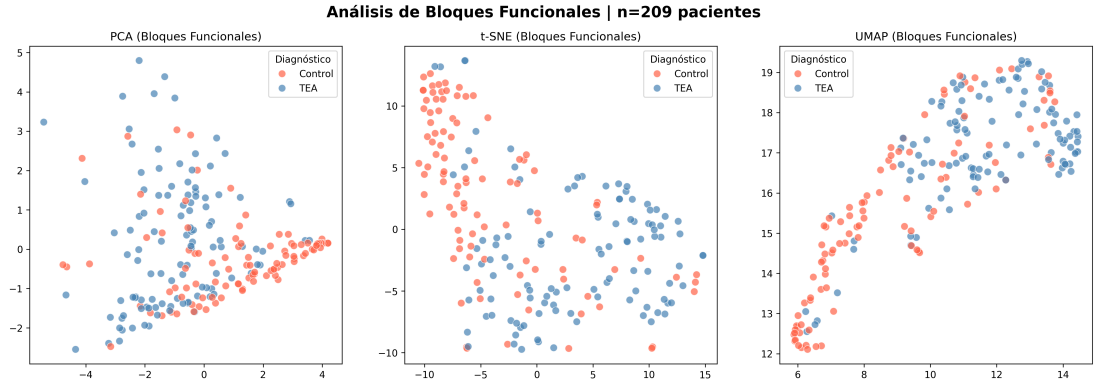


Figura 3.13: Proyecciones PCA, t-SNE y UMAP con los 11 índices de bloque funcional, coloreadas por grupo diagnóstico.

En ninguna de las seis proyecciones se observa una separación nítida entre los grupos TEA y Control: los puntos de ambas clases aparecen entremezclados sin fronteras claras, tanto con las variables originales como con los bloques funcionales. Esto indica que el problema de clasificación no es linealmente separable en el espacio de representación actual y que las diferencias entre grupos, aunque existentes como se ha visto en los apartados anteriores, están distribuidas de forma compleja entre múltiples variables. Esta conclusión refuerza la necesidad de recurrir a modelos de clasificación no lineales y justifica la exploración de técnicas de selección y transformación de características en la fase de preprocesamiento.

Capítulo 4

Marco Experimental y Desarrollo

En este capítulo se describen las fases metodológicas seguidas, desde la obtención del dataset en bruto hasta la evaluación de los modelos de clasificación. En primer lugar, se detalla el preprocesamiento aplicado, incluyendo la codificación de variables, las estrategias de imputación consideradas y la normalización. A continuación, se presentan los métodos de selección de características y los modelos de clasificación empleados, y se describe el diseño experimental que rige la evaluación, incluyendo la validación cruzada y las métricas utilizadas.

4.1 Preprocesamiento

El preprocesamiento constituye una etapa fundamental en cualquier flujo de trabajo de aprendizaje automático, especialmente cuando se trabaja con datos clínicos que presentan variables de distinta naturaleza y que pueden contar con valores ausentes. En este caso, el dataset combina variables continuas, ordinales codificadas numéricamente y variables de texto, que además proceden de dos contextos geográficos y de recogida distintos. Las decisiones tomadas en esta fase condicionarán directamente la calidad de la información que reciben los modelos y, por tanto, sus resultados.

4.1.1 Codificación de variables

El dataset original contiene variables de distinto tipo que deben homogeneizarse antes de cualquier procesamiento numérico. Primeramente, se elimina la variable *Nombre*, que actúa como identificador alfanumérico anónimo y no aporta información útil para la predicción. A continuación, todas las variables que no son estrictamente continuas —es decir, todas salvo *Edad*, *Altura* y *Peso*— se convierten de *float64* a *int64*, ya que son variables ordinales y categóricas. Además, los valores ausentes se codifican como -1 para distinguirlos de las categorías válidas. Esta representación es la que consume el *pipeline* de entrenamiento.

4.1.2 Estrategias de imputación

Dado que el 12.39% de las celdas del dataset contienen valores ausentes —con un patrón MNAR descrito en el apartado 3.2.3—, es necesario aplicar una estrategia de imputación antes del entrenamiento. Se evalúan tres alternativas con el objetivo de seleccionar la que mejor preserva la distribución original de las variables:

- **Imputación por moda**: Es el método más simple, aplicado principalmente a atributos categóricos: cada valor ausente se sustituye por el valor más frecuente (moda) de esa variable calculado sobre el conjunto completo de observaciones disponibles [26]. Dado un vector de observaciones $\mathbf{x} = (x_1, x_2, \ldots, x_n)$ con valores ausentes en un subconjunto de posiciones $\mathcal{M}$, el valor imputado para cada posición $i \in \mathcal{M}$ es:

$$\hat{x}_i = \text{Moda}(\mathbf{x}_{\text{obs}}) = \arg\max_{v \in \mathcal{V}} \sum_{j \notin \mathcal{M}} \mathbf{1}[x_j = v] \tag{4.1}$$

  donde $\mathcal{V}$ representa el conjunto de categorías posibles del atributo, $\mathbf{x}_{\text{obs}}$ denota el subconjunto de observaciones conocidas y $\mathbf{1}[\cdot]$ es la función indicadora. Su principal ventaja es la simplicidad y un bajo coste computacional, pero no tiene en cuenta las relaciones entre variables ni el contexto de cada individuo, lo que puede distorsionar las distribuciones cuando el porcentaje de nulos es elevado.

- **Imputación por KNN**: La imputación por k vecinos más cercanos [30] sustituye cada valor ausente por una combinación ponderada de los valores correspondientes en los k individuos más similares al individuo con el dato faltante. Dado que el *KNNImputer* opera sobre datos numéricos, las variables categóricas se habían convertido previamente a sus códigos enteros mediante *label encoding* (con los valores ausentes codificados como -1). La similitud entre individuos se mide mediante la distancia euclídea calculada exclusivamente sobre las variables observadas en ambos individuos. Para un individuo i con valor ausente en la variable j, el valor imputado es:

$$\hat{x}_{ij} = \frac{\sum_{l \in \mathcal{N}_k(i)} w_{il} \cdot x_{lj}}{\sum_{l \in \mathcal{N}_k(i)} w_{il}}, \quad w_{il} = \frac{1}{d(i,l)} \tag{4.2}$$

  donde $\mathcal{N}_k(i)$ es el conjunto de los k vecinos más cercanos al individuo i entre aquellos que tienen el valor j observado, $d(i,l)$ es la distancia euclídea entre i y l, y w_{il} es el peso inversamente proporcional a dicha distancia. En este trabajo se emplean $k = 5$ vecinos, valor por defecto en *scikit-learn* y el estándar para datasets de tamaño similar. Dado que el resultado devuelve valores decimales, estos se redondean al entero más cercano dentro del rango de categorías válidas.

- **Imputación por grupos**: Combina la imputación por moda con una estratificación jerárquica basada en variables clínicamente relevantes [31]. Se aplica en tres etapas: primero se imputa según grupos definidos por *Edad* y *Diag_primario*; después solo por *Diag_primario*; y finalmente mediante la moda global, si todavía quedan valores por imputar. Esta estrategia aprovecha la información contextual del individuo y es especialmente adecuada cuando las distribuciones de las variables difieren entre grupos clínicos, corrigiendo posibles sesgos de selección.

Comparativa de calidad: divergencia de Jensen-Shannon

Para seleccionar la estrategia de imputación más adecuada se emplea la divergencia de Jensen-Shannon (JS) [32] como medida de la distorsión introducida en cada variable respecto a su distribución original. La divergencia JS es una versión simétrica y acotada de la divergencia de Kullback-Leibler [33], especialmente adecuada para comparar distribuciones categóricas porque es finita incluso cuando alguna de las distribuciones asigna probabilidad cero a ciertos valores. Dadas dos distribuciones de probabilidad P y Q sobre el mismo soporte, se define como:

$$\mathrm{JS}(P\|Q) = \frac{1}{2}D_{\mathrm{KL}}(P\|M) + \frac{1}{2}D_{\mathrm{KL}}(Q\|M), \quad M = \frac{P+Q}{2} \tag{4.3}$$

donde $D_{\mathrm{KL}}(P\|M) = \sum_x P(x) \log \frac{P(x)}{M(x)}$ es la divergencia de Kullback-Leibler. El valor de JS se encuentra en el intervalo $[0, \log 2]$, siendo 0 cuando las distribuciones son idénticas. En la práctica se usa su raíz cuadrada, que constituye una distancia métrica válida [34].

Para cada método de imputación, se calcula la distancia JS media entre la distribución original de cada variable categórica (sobre las observaciones no ausentes) y la distribución resultante tras la imputación. Los resultados obtenidos se recogen en la Tabla 4.1.

Tabla 4.1: Comparativa de calidad de imputación (distancia de Jensen-Shannon media).

Estrategia	JS Global	JS (>50% nulos)	JS (<50% nulos)
Moda	0.0494	0.2337	0.0000
Por grupos	0.0321	0.1517	0.0000
KNN ($k = 5$)	**0.0276**	**0.1306**	**0.0000**

Los resultados muestran que la imputación por KNN es la que menor distorsión introduce en las distribuciones originales, especialmente en las variables con mayor porcentaje de nulos, que son precisamente las más problemáticas. En cuanto a la imputación por moda, es la que

produce mayor distorsión al inflar artificialmente la categoría más frecuente, siendo mejorada por la imputación por grupos, que contextualiza la sustitución. Por todo ello, se selecciona la imputación por KNN ($k = 5$ vecinos) como estrategia definitiva, que se aplica dentro del *pipeline* de entrenamiento sobre los datos ya codificados numéricamente.

4.1.3 Normalización

Una vez imputados los valores ausentes, todas las variables —tanto las continuas como las categóricas en su formato de código numérico entero— se estandarizan mediante el *StandardScaler* de *scikit-learn* [13], que transforma cada variable para que tenga media cero y desviación típica unitaria:

$$z = \frac{x - \mu}{\sigma} \tag{4.4}$$

donde μ es la media de la variable calculada sobre el conjunto de entrenamiento y σ su desviación típica. Esta transformación es necesaria por dos razones: por un lado, los modelos de clasificación basados en distancias o en gradiente (SVM, MLP, regresión logística) son sensibles a la escala de las variables y producen resultados incorrectos si estas no están en rangos comparables; por otro lado, las variables del dataset presentan rangos muy dispares —desde ítems ordinales con valores entre 1 y 4 hasta variables como *Altura* o *Peso* en decenas o centenas— que harían que ciertas variables dominen artificialmente el cálculo de distancias o el ajuste de pesos. Los parámetros μ y σ se estiman exclusivamente sobre el conjunto de entrenamiento de cada fold y se aplican tanto al conjunto de entrenamiento como al de test.

4.2 Métodos de selección de características

La selección de características es el proceso de identificar el subconjunto de variables más relevantes para el problema de clasificación, descartando aquellas que son redundantes, ruidosas o irrelevantes. En un dataset de alta dimensionalidad como el empleado en este trabajo, donde el número de variables es comparable al número de muestras, esta etapa resulta especialmente crítica: reducir la dimensionalidad no solo mejora la interpretabilidad del modelo y la eficiencia computacional, sino que también puede mejorar su generalización al eliminar el ruido asociado a variables poco informativas [35].

Los métodos de selección de características se clasifican en tres grandes familias según cómo interactúan con el proceso de aprendizaje:

- Los métodos de **filtro** evalúan la relevancia de cada variable de forma independiente al clasificador, mediante criterios estadísticos aplicados directamente sobre los datos; son

computacionalmente eficientes pero ignoran las interacciones entre variables y con el modelo de clasificación.

- Los métodos **envolventes** (*wrappers*) utilizan un clasificador como caja negra para evaluar subconjuntos de variables, lo que los hace más precisos al capturar las interacciones con el modelo. Sin embargo, tienen un coste computacional considerablemente mayor, derivado de los múltiples entrenamientos del modelo.
- Los métodos **embebidos** integran la selección dentro del propio proceso de entrenamiento del modelo, optimizando ambas tareas de forma conjunta y equilibrando coste y precisión.

En este trabajo se emplean cuatro métodos de filtro (MI, ANOVA, ReliefF y mRMR), un método envolvente (SVM-RFE) y un método embebido (E2EFS).

Información Mutua (MI): La Información Mutua [36], como método de filtro, calcula la dependencia estadística entre una variable X_j y la variable objetivo Y, midiendo cuánta información sobre Y se obtiene al conocer X_j. Su principal ventaja frente a medidas lineales es que no asume ninguna forma funcional de la relación entre ambas variables, por lo que captura dependencias tanto lineales como no lineales (comunes en cuestionarios clínicos). Se define como:

$$I(X_j; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log \frac{p(x, y)}{p(x)\, p(y)} \tag{4.5}$$

donde $p(x, y)$ es la distribución de probabilidad conjunta de X_j e Y, y $p(x)$ y $p(y)$ son sus distribuciones marginales. Un valor $I(X_j; Y) = 0$ indica independencia estadística, mientras que valores mayores indican mayor dependencia. Las k variables con mayor información mutua respecto a la clase son seleccionadas. En nuestra implementación se emplea la función *mutual_info_classif* de la clase *SelectKBest* de *scikit-learn* [13].

ANOVA (*Analysis Of Variance*) F-test: Propuesto por Fisher et al. [37], este método de filtro evalúa la relevancia de cada variable respecto a la variable de clase mediante el estadístico F, que mide el ratio entre la varianza entre grupos (inter-clase) y la varianza dentro de los grupos (intra-clase):

$$F_j = \frac{\text{varianza entre grupos}}{\text{varianza intra-grupo}} = \frac{\sum_c n_c (\bar{x}_{jc} - \bar{x}_j)^2 / (C - 1)}{\sum_c \sum_{i \in c} (x_{ij} - \bar{x}_{jc})^2 / (N - C)} \tag{4.6}$$

donde C es el número de clases, N el número total de muestras, n_c el número de muestras de la clase c, $\bar{x}_{jc}$ la media de la variable j en la clase c y $\bar{x}_j$ la media global. Un F_j elevado indica

que la variable j presenta distribuciones claramente distintas entre clases, lo que la convierte en un buen discriminador. Al asumir normalidad e independencia entre grupos, ANOVA es más adecuado para variables continuas y puede no ser tan efectivo para escalas ordinales, limitando su aplicabilidad en nuestro dataset, compuesto mayoritariamente por dicho tipo de variables. Se implementa con *f_classif*, también de la clase *SelectKBest*.

ReliefF: Es una extensión del algoritmo Relief original [38], diseñado para clasificación binaria, que ReliefF [39] generaliza a problemas multiclase considerando múltiples vecinos en lugar de uno solo, haciéndolo más robusto frente a ruido y distribuciones desequilibradas. Este método de filtro estima la relevancia de cada variable en función de su capacidad para distinguir entre muestras de la misma clase (*nearest hit*, H) y de clases distintas (*nearest miss*, $M(C)$). Para cada instancia R muestreada aleatoriamente, la puntuación del atributo A se actualiza como:

$$W[A] := W[A] - \frac{\text{diff}(A,\, R,\, H)}{m} + \sum_{C \neq \text{class}(R)} \left[P(C) \cdot \frac{\text{diff}(A,\, R,\, M(C))}{m} \right] \tag{4.7}$$

donde m es el número de iteraciones, $P(C)$ es la probabilidad a priori de la clase C, y $\text{diff}(A, R, X)$ es la diferencia normalizada del atributo A entre R y X, que puede ser el *nearest hit* H o el *nearest miss* $M(C)$ de la clase C. Una variable recibe una puntuación alta si sus valores son similares dentro de la misma clase y distintos entre clases diferentes. ReliefF no asume ninguna distribución específica y es especialmente adecuado para datos con interacciones entre variables. Se implementa mediante la librería *skrebate*.

mRMR (*Minimum Redundancy Maximum Relevance*): Este método de filtro propuesto por Peng et al. [40], selecciona variables que sean a la vez relevantes para la clase y no redundantes entre sí. Dado un subconjunto de variables ya seleccionadas $\mathcal{S}$, la siguiente variable X_j que maximiza el criterio mRMR es aquella que maximiza:

$$\phi(X_j) = I(X_j; Y) - \frac{1}{|\mathcal{S}|} \sum_{X_s \in \mathcal{S}} I(X_j; X_s) \tag{4.8}$$

donde $I(X_j; Y)$ es la información mutua entre X_j y la clase — definida en la Ecuación 4.5 y que mide la relevancia— y $\frac{1}{|\mathcal{S}|} \sum_{X_s \in \mathcal{S}} I(X_j; X_s)$ es la información mutua media entre X_j y las variables ya seleccionadas —que penaliza la redundancia—. De esta manera, mRMR no solo busca variables individualmente informativas, sino que construye un subconjunto complementario, lo que lo hace especialmente útil cuando existen grupos de variables altamente correlacionadas como por ejemplo los dominios del ICAP. Se implementa mediante *mrmr* [41].

SVM-RFE: La Eliminación Recursiva de Características con SVM (*Recursive Feature Elimination*, RFE) [42] es un método que está a medio camino entre ser envolvente y embebido, que selecciona características de forma iterativa apoyándose en una SVM lineal como clasificador base —descrita en detalle en el apartado 4.3—. En cada iteración, se entrena la SVM sobre el conjunto de variables actual y se elimina la variable con menor peso en el hiperplano de decisión aprendido (es decir, la que contribuye menos a la separación entre clases), repitiendo el proceso hasta alcanzar las k variables deseadas. El criterio de eliminación en cada paso es:

$$j^* = \arg\min_j \ w_j^2 \tag{4.9}$$

donde w_j es el coeficiente asociado a la variable j. Al reentrenar el modelo en cada iteración, SVM-RFE tiene en cuenta las interacciones entre variables, a diferencia de los métodos de filtro, aunque ello implica un coste computacional considerablemente mayor. Se implementa con *RFE* y *LinearSVC* ($C = 0.1$) de *scikit-learn*, ya que proporciona un mayor grado de regularización y mejora la estabilidad del modelo en problemas de alta dimensionalidad..

E2EFS: E2EFS (*End-to-End Feature Selection*) [43] es un método embebido basado en redes neuronales que integra la selección de características dentro del propio proceso de entrenamiento, optimizando ambos de forma conjunta. De esta forma, la complejidad computacional es solamente la resultante de entrenar dicha red. La principal diferencia respecto al resto de métodos es que no separa la selección de características del entrenamiento del modelo, sino que incorpora una capa de selección diferenciable al inicio de la red. Esta capa aprende un vector de pesos continuos $\mathbf{r} \in [0,1]^d$ que pondera cada variable de entrada, donde $r_j \approx 1$ indica relevancia y $r_j \approx 0$ irrelevancia. La entrada efectiva a la red es: $\tilde{\mathbf{x}} = \mathbf{r} \odot \mathbf{x}$ donde $\odot$ denota el producto elemento a elemento. El vector $\mathbf{r}$ se optimiza conjuntamente con los pesos de la red mediante retropropagación, incorporando un término de regularización que fuerza la selección de exactamente k características. En su variante *soft* (E2EFSSoft), empleada en este trabajo, los pesos de selección varían de forma continua durante el entrenamiento y se discretizan al finalizar, permitiendo que el gradiente fluya a través de la capa de selección.

4.3 Modelos de clasificación

Los modelos de clasificación son los algoritmos encargados de aprender una función que mapea el espacio de características hacia la variable objetivo. En este trabajo se evalúan seis modelos que representan distintos paradigmas del aprendizaje automático supervisado —desde métodos lineales hasta conjuntos de árboles y redes neuronales— con el fin de identificar el más adecuado para el problema de detección de TEA. Todos ellos se implementan a través de la librería *scikit-learn* [13], usando hiperparámetros fijos en esta fase.

Máquinas de Vectores de Soporte (SVM): Las SVM [44] buscan el hiperplano de separación de máximo margen entre clases en el espacio de características. Dado un conjunto de entrenamiento $\{(\mathbf{x}_i, y_i)\}$ con $y_i \in \{-1, +1\}$, el problema de optimización consiste en encontrar el vector de pesos $\mathbf{w}$ y el sesgo b que maximizan el margen $\frac{2}{\|\mathbf{w}\|}$ sujeto a que todas las muestras sean correctamente clasificadas:

$$\min_{\mathbf{w},\, b} \frac{1}{2}\|\mathbf{w}\|^2 \quad \text{s.a.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad \forall i \tag{4.10}$$

Para datos no linealmente separables, se introducen variables de holgura $\xi_i \geq 0$ y un parámetro de regularización C que controla el equilibrio entre maximizar el margen y minimizar los errores de clasificación. Además, mediante el truco del kernel se pueden proyectar datos a espacios de mayor dimensión sin calcularlos explícitamente, permitiendo separar clases no linealmente separables en el espacio original. En este trabajo se emplea *SVC* con kernel RBF y estimación de probabilidades activada.

Perceptrón Multicapa (MLP): Las redes neuronales de tipo Perceptrón Multicapa [45] están formadas por capas de neuronas artificiales completamente conectadas. En cada neurona de una capa l se calcula una combinación lineal ponderada de las salidas de la capa anterior y se aplica una función de activación no lineal σ:

$$\mathbf{h}^{(l)} = \sigma\Big(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}\Big) \tag{4.11}$$

donde $\mathbf{W}^{(l)}$ y $\mathbf{b}^{(l)}$ son los pesos y sesgos de la capa l, optimizados mediante retropropagación del error y descenso de gradiente. La capacidad de las MLP para aprender representaciones jerárquicas y no lineales las hace especialmente adecuadas para problemas donde las variables pueden ser de distinto tipo y presentan relaciones complejas entre ellas. Sin embargo, requiere mayor coste computacional que otros métodos y su naturaleza de caja negra dificulta su interpretabilidad. En la fase de exploración se emplea una arquitectura de dos capas ocultas de 100 y 50 neuronas respectivamente, con un máximo de 1000 iteraciones para garantizar la convergencia. Para ello se usa *MLPClassifier*.

Árbol de Decisión (*Decision Tree*): Los árboles de decisión [46] construyen un modelo de clasificación en forma de árbol binario que particiona recursivamente el espacio de características. Cada nodo interno representa una condición sobre el valor de una variable ($x_j \leq \theta$), cada rama corresponde a la respuesta posible a dicha condición y cada hoja contiene la predicción final para las muestras que llegan a ella, asignándoles la clase mayoritaria de ese subconjunto. En cada nodo se selecciona la variable j y el umbral θ que maximizan la pureza de los subconjuntos resultantes, medida mediante la impureza de Gini:

$$\text{Gini}(\mathcal{D}) = 1 - \sum_{c=1}^{C} p_c^2 \tag{4.12}$$

donde p_c es la proporción de muestras de la clase c en el nodo. La impureza de Gini vale 0 cuando el nodo es completamente puro (todas las muestras pertenecen a la misma clase) y alcanza su valor máximo cuando las clases están distribuidas de forma uniforme, indicando máxima entropía. Su principal ventaja es la interpretabilidad directa de las reglas aprendidas, aunque tiende al sobreajuste si no se controla la profundidad máxima del árbol o el tamaño mínimo de las hojas. En este trabajo se emplea *DecisionTreeClassifier* con una profundidad máxima de 10.

Bosque Aleatorio (*Random Forest*): El Bosque Aleatorio [47] es un método de *ensemble* que construye un conjunto de B árboles de decisión entrenados cada uno sobre una muestra aleatoria con reemplazo (*bootstrap*) del conjunto de entrenamiento, y con un subconjunto aleatorio de variables disponibles en cada división. La predicción final se obtiene por votación mayoritaria:

$$\hat{y} = \text{Moda}\big(\{T_b(\mathbf{x})\}_{b=1}^{B}\big) \tag{4.13}$$

donde $T_b(\mathbf{x})$ es la predicción del b-ésimo árbol. El componente aleatorio reduce la correlación entre árboles y, con ello, la varianza del modelo conjunto sin aumentar el sesgo, lo que lo hace más robusto que un único árbol frente al sobreajuste. Se emplea *RandomForestClassifier* con 100 árboles y una profundidad máxima de 10.

Gradient Boosting (GB): El *Gradient Boosting* [48] es otro método de *ensemble* que, a diferencia del Bosque Aleatorio, construye los árboles de forma secuencial: cada nuevo árbol es entrenado con el fin de corregir los errores residuales del conjunto de árboles anteriores, siguiendo el descenso del gradiente de una función de pérdida $\mathcal{L}$. La predicción del modelo tras M iteraciones es:

$$F_M(\mathbf{x}) = F_0(\mathbf{x}) + \sum_{m=1}^{M} \eta \cdot T_m(\mathbf{x}) \tag{4.14}$$

donde $F_0(\mathbf{x})$ es una predicción inicial, $T_m(\mathbf{x})$ es el m-ésimo árbol ajustado al gradiente negativo de $\mathcal{L}$ y η es la tasa de aprendizaje que controla la contribución de cada árbol. El Gradient Boosting suele obtener resultados muy competitivos requiriendo menos árboles que el Bosque Aleatorio, aunque es más sensible a los hiperparámetros, pudiendo caer fácilmente en el sobreajuste. Se emplea *GradientBoostingClassifier* con los hiperparámetros por defecto en la fase exploratoria.

Regresión Logística (LR): La Regresión Logística [49] es un modelo lineal que estima la probabilidad de pertenencia a cada clase mediante la función sigmoide aplicada a una combinación lineal de las variables de entrada:

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}} \tag{4.15}$$

Los parámetros $\mathbf{w}$ y b se estiman maximizando la verosimilitud del conjunto de entrenamiento, equivalente a minimizar la entropía cruzada binaria. Pese a su simplicidad, la Regresión Logística es un modelo de referencia robusto, interpretable y computacionalmente eficiente, cuyo rendimiento en problemas con separación aproximadamente lineal puede ser competitivo con modelos más complejos. Se emplea *LogisticRegression* con un máximo de 1000 iteraciones.

4.4 Diseño experimental

En esta sección se describe el protocolo experimental seguido para evaluar de forma rigurosa y reproducible las distintas combinaciones de métodos de selección de características y modelos de clasificación. El diseño busca obtener estimaciones fiables del rendimiento generalizado de cada configuración.

4.4.1 Esquema de validación cruzada estratificada

Dado el tamaño reducido del dataset (209 muestras), una división simple en entrenamiento y test, como por ejemplo 80%-20%, produciría estimaciones de rendimiento con alta varianza, fuertemente dependientes de la partición concreta elegida. Por ello se emplea validación cruzada estratificada con $k = 5$ folds (*Stratified K-Fold Cross-Validation*) [50], que divide el conjunto de datos en 5 subconjuntos de tamaños aproximadamente iguales, manteniendo en cada uno de ellos la misma proporción de clases que en el conjunto completo. El proceso se repite 5 veces: en cada iteración, uno de los folds actúa como conjunto de test y los cuatro restantes como conjunto de entrenamiento, de forma que cada muestra es evaluada exactamente una vez.

Para evitar la fuga de información (*data leakage*), la imputación KNN y el *StandardScaler* se ajustan sobre los folds de entrenamiento, y se aplican sobre ellos y el de test. De la misma forma, la selección de características se realiza dentro de cada fold, de forma que las variables seleccionadas en un fold no influyen en el entrenamiento de otro. Por último, la métrica final reportada es la media sobre los 5 folds. La Figura 4.1 ilustra el esquema completo del pipeline.



Figura 4.1: Esquema del pipeline de entrenamiento y evaluación siguiendo validación cruzada estratificada

A mayores, este flujo se repite para distintos valores del número de características seleccionadas $k \in \{5, 10, 20, 30, 50\}$, con el fin de estudiar cómo varía el rendimiento en función del tamaño del subconjunto y determinar el valor de k óptimo. Para cada combinación de k, selector y modelo se ejecuta el esquema de validación cruzada completo, dando lugar a un total de $5 \times 6 \times 6 = 180$ configuraciones evaluadas por valor de k.

4.4.2 Métricas de evaluación

La evaluación del rendimiento de los modelos de clasificación se realiza mediante cinco métricas complementarias, calculadas sobre el conjunto de test de cada fold a partir de la matriz de confusión, que recoge el número de verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP) y falsos negativos (FN). Todas las métricas se calculan en su versión *weighted*, que pondera cada clase por su frecuencia. Dado el leve desbalance (53/47), las diferencias respecto a la versión *macro* son mínimas, pero la versión ponderada es más robusta ante variaciones de distribución entre folds.

Exactitud (*Accuracy*): Mide la proporción de muestras correctamente clasificadas sobre el total:

$$\text{Accuracy} = \frac{\text{VP} + \text{VN}}{\text{VP} + \text{VN} + \text{FP} + \text{FN}} \tag{4.16}$$

Es la métrica más intuitiva pero también la más sensible al desbalanceo de clases, por lo que se complementa con las siguientes.

Precisión (*Precision*): Mide qué proporción de las muestras clasificadas como positivas (TEA) son realmente positivas:

$$\text{Precision} = \frac{\text{VP}}{\text{VP} + \text{FP}} \tag{4.17}$$

Una precisión baja implica un alto número de falsos positivos, es decir, individuos del grupo control clasificados erróneamente como TEA.

Sensibilidad (*Recall*): Mide qué proporción de los casos positivos reales (TEA) son correctamente identificados:

$$\text{Recall} = \frac{\text{VP}}{\text{VP} + \text{FN}} \tag{4.18}$$

En el contexto clínico, un recall bajo es especialmente problemático porque implica un alto número de falsos negativos: individuos con TEA que no son detectados y, por tanto, no reciben intervención temprana.

F1-Score: Es la media armónica de la *precision* y el *recall*, proporcionando un único valor que equilibra ambas:

$$\text{F1} = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \tag{4.19}$$

Al ser la media armónica, penaliza fuertemente los casos en que una de las dos métricas es muy baja. Es la métrica principal empleada para comparar y ordenar las distintas configuraciones experimentales.

Área bajo la curva ROC (ROC-AUC): La curva ROC representa la tasa de verdaderos positivos (*recall*) frente a la tasa de falsos positivos para distintos umbrales de clasificación. El área bajo dicha curva (AUC) resume el rendimiento discriminativo del modelo en un único valor en el intervalo $[0, 1]$, donde 0.5 corresponde a la clasificación aleatoria y 1.0 a la discriminación perfecta:

$$\text{AUC} = \int_0^1 \text{TPR}(\text{FPR})\, \text{d}(\text{FPR}) \tag{4.20}$$

A diferencia del F1-Score, el AUC es independiente del umbral de decisión, lo que lo hace especialmente útil cuando se desea evaluar la capacidad discriminativa del modelo de forma global [51].

Capítulo 5

Análisis de Resultados

Este capítulo presenta y discute los resultados obtenidos siguiendo el diseño experimental descrito en el capítulo anterior. El análisis sigue un orden progresivo: se comienza evaluando las decisiones de preprocesamiento (estrategia de imputación frente a eliminación de variables con alta tasa de nulos) y el impacto de la variable *País*, para a continuación determinar el número óptimo de características y comparar el rendimiento de los distintos selectores y modelos. Finalmente, se analiza la estabilidad de las características seleccionadas y se ofrece una interpretación clínica de las más relevantes, concluyendo con la optimización y evaluación del modelo final.

Salvo que se indique lo contrario, todos los resultados de este capítulo corresponden a la estrategia de eliminación de variables con más del 50% de valores nulos sin la variable *País*, la cual se justifica en los apartados 5.1 y 5.2 y constituye la configuración de preprocesamiento adoptada. A lo largo de todo el capítulo, la métrica principal de comparación es el F1-Score, por ser la más robusta ante el leve desbalanceo de clases existente. Las restantes métricas —*Accuracy*, *Precision*, *Recall* y ROC-AUC— se reportan de forma complementaria cuando aportan información adicional relevante.

5.1 Comparativa de estrategias de preprocesamiento

Como se describió en el apartado 3.2.3, el dataset presenta 25 variables con más del 50% de valores nulos, todas ellas concentradas en la submuestra gallega debido al proceso de recogida. Frente a esta situación existen dos estrategias naturales: imputar los valores ausentes, manteniendo todas las variables disponibles, o eliminar directamente las variables con una tasa de nulos elevada, reduciendo la dimensionalidad del problema a costa de poder perder información útil. El objetivo de este apartado es determinar qué estrategia produce mejores resultados de clasificación, con el objetivo de llegar a una decisión definitiva de preprocesamiento fundamentada en datos.

Ambas estrategias se evalúan bajo el mismo protocolo experimental: validación cruzada estratificada de 5 folds, con los seis selectores de características y los seis modelos de clasificación descritos en el capítulo anterior, para $k \in \{5, 10, 20, 30, 50\}$ variables seleccionadas.

5.1.1 Mejor configuración por valor de k

Los resultados mostrados en la Tabla 5.1 reflejan un panorama sin un ganador claro. Para cada valor de k, se identifica la combinación selector-modelo cuyo F1 medio —promediado sobre los 5 folds de validación cruzada— es máximo. La estrategia de eliminación supera a la imputación en cuatro de los cinco valores de k analizados, pero las diferencias son pequeñas —en ningún caso superan los 2 puntos porcentuales— y no son consistentes en cuanto a qué selector o modelo resulta ganador. La única excepción es $k = 20$, donde la imputación obtiene un F1 ligeramente superior (0.8163 frente a 0.8078).

Tabla 5.1: Combinación selector-modelo con mayor F1 medio (promedio sobre 5 folds de CV) por valor de k, para ambas estrategias de preprocesamiento.

k	**Mejor comb. (Imputación)**	**F1-Score**	**Mejor comb. (Eliminación)**	**F1-Score**	**Diferencia** F1(Imp) − F1(Elim)
5	RFE-SVM + LR	0.7777	RFE-SVM + RF	**0.7976**	−0.0199
10	E2EFS + RF	0.8030	RFE-SVM + LR	**0.8209**	−0.0179
20	mRMR + MLP	**0.8163**	mRMR + LR	0.8078	+0.0085
30	RFE-SVM + SVM	0.8189	mRMR + LR	**0.8272**	−0.0083
50	E2EFS + MLP	0.8309	RFE-SVM + GB	**0.8359**	−0.0050

Negrita: mayor F1-Score entre ambas estrategias para cada valor de k.

5.1.2 Rendimiento medio por valor de k

La Figura 5.1 muestra la evolución del F1 medio —promediado sobre todos los selectores y modelos— en función de k para ambas estrategias, junto con una línea de referencia del *baseline* sin selección de características (NO-FS).

Ambas curvas, sin grandes diferencias de F1 promedio, siguen una tendencia ascendente con k. Esto indica que añadir más variables al subconjunto seleccionado mejora el rendimiento medio de forma sostenida hasta $k = 50$, donde se llega a estabilizar dicha subida. Sin embargo, ninguna de las dos estrategias logra superar el *baseline* NO-FS en términos de F1 medio, lo que revela que, al promediar sobre todas las combinaciones de selector y modelo,

usar un subconjunto reducido de variables no mejora el rendimiento global frente a emplear la totalidad de las variables disponibles.

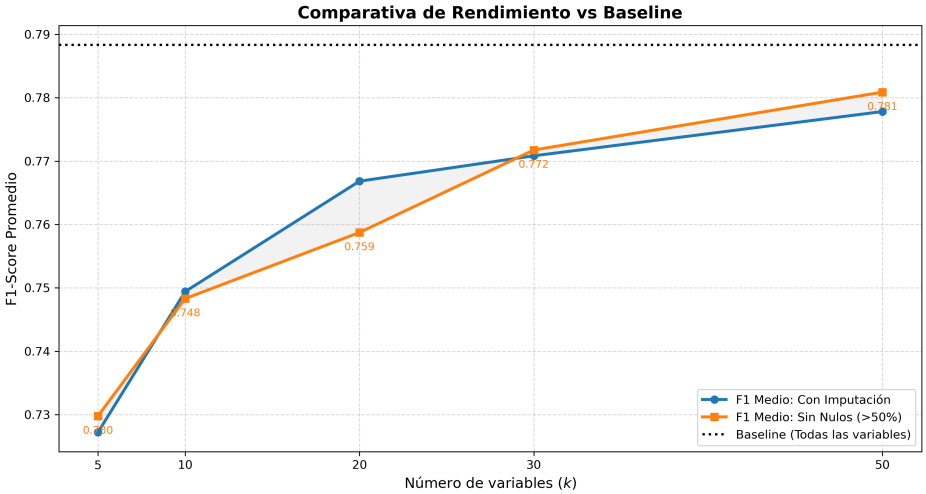


Figura 5.1: Evolución del F1 medio en función de k para las estrategias de preprocesamiento.

Este resultado no invalida la selección de características: como se verá en los apartados siguientes, las mejores configuraciones individuales sí superan al *baseline*, y la selección aporta valor en términos de interpretabilidad y reducción de la complejidad del modelo.

Cabe destacar además que las diferencias de F1 medio entre ambas estrategias para cada selector y modelo concreto son prácticamente despreciables, con variaciones inferiores a 0.01 puntos en todos los casos, lo que refuerza la idea de que la elección de estrategia no condiciona de forma significativa el rendimiento individual de ninguna combinación.

5.1.3 Impacto sobre la selección de características

Más allá del rendimiento, resulta relevante analizar si ambas estrategias seleccionan las mismas variables. Para ello se comparan los *rankings* de consenso para $k = 20$ —cuyo significado y método de cálculo se detallan en la subsección 5.4.3— obtenidos bajo cada estrategia, recogidos en la Tabla 5.2. El solapamiento es de 18 sobre 20 variables. Las dos variables que aparecen únicamente con imputación (*comunicq* y *serv_act2*) son precisamente variables con alta tasa de nulos que la eliminación descarta directamente, por lo que su ausencia en la segunda estrategia es esperable. Además, ambas se encuentran entre las últimas 5 del ranking, lo que indica que no son de gran importancia. Por su parte, *esperar_turno* e *intsocq* ganan peso en la estrategia de eliminación, probablemente al reducirse el ruido introducido por las variables con muchos nulos, y ocupan exactamente las mismas posiciones que dejaron las variables exclusivas de la estrategia de imputación. Esta alta coincidencia (un 90%) indica que ambas estrategias identifican esencialmente el mismo conjunto de variables discriminativas.

Tabla 5.2: Top-20 variables de mayor consenso ($k = 20$) para cada estrategia de preprocesamiento. Las celdas sombreadas indican variables que aparecen en una estrategia pero no en la otra.

Pos.	Variable (Imputación)	Score	Variable (Eliminación)	Score
1	*permanece_apartado*	95.00	*cuenta_historia*	93.33
2	*cuenta_historia*	93.33	*intercambia_objetos*	91.67
3	*Pais*	93.33	*Pais*	91.67
4	*intercambia_objetos*	90.00	*permanece_apartado*	90.00
5	*evita_contacto_ocular*	86.67	*evita_contacto_ocular*	86.67
6	*repite_sonidos_ininteligibles*	83.33	*repite_sonidos_ininteligibles*	81.67
7	*responde_negativamente_a_ordenes*	78.33	*responde_negativamente_a_ordenes*	80.83
8	*hacer_cosas_repetidamente*	73.67	*hacer_cosas_repetidamente*	76.67
9	*trabaja_ritmo_regular*	73.33	*Gravedad_retraimiento*	73.33
10	*Medicamentos*	70.83	*trabaja_ritmo_regular*	73.33
11	*Gravedad_retraimiento*	70.83	*Gravedad_no_colaboradora*	71.67
12	*Frecuencia_retraimiento*	68.33	*Frecuencia_retraimiento*	70.83
13	*Gravedad_no_colaboradora*	68.33	*Medicamentos*	68.33
14	*mira_lejos_cuando_se_lo_mira*	65.67	*Localiza_informacion*	63.67
15	*ofrece_ayuda*	63.33	*ofrece_ayuda*	63.33
16	*serv_act2*	61.67	*esperar_turno*	61.67
17	*Localiza_informacion*	61.67	*Retraimiento_atencion*	60.83
18	*Retraimiento_atencion*	60.83	*no_inicia_conversaciones*	60.83
19	*no_inicia_conversaciones*	60.83	*mira_lejos_cuando_se_lo_mira*	58.33
20	*comunicq*	58.33	*intsocq*	58.33

5.1.4 Estrategia seleccionada

Ante la ausencia de diferencias relevantes en rendimiento, la alta coincidencia en las variables seleccionadas y la mayor eficiencia computacional derivada de operar con un menor número de variables, se selecciona la estrategia de eliminación de variables con más del 50% de

nulos como configuración de preprocesamiento para el resto del análisis. Esta elección reduce la dimensionalidad del espacio de búsqueda, simplifica el pipeline al eliminar la necesidad de imputar variables con patrones MNAR, y produce resultados ligeramente superiores en la mayoría de los valores de k evaluados.

5.2 Impacto de la variable *País*

La variable *País* codifica el contexto geográfico de recogida de cada participante: 1 para Uruguay y 2 para Galicia. Como se analizó en el apartado 3.2.2, la distribución de diagnósticos entre ambas submuestras es apreciablemente asimétrica: la submuestra uruguaya proviene en su mayoría de centros de educación especial, de ahí los 58 casos TEA frente a solo 12 controles, mientras que la gallega incluye un número mayor de individuos de centros de educación ordinaria, con 86 controles frente a 53 TEA. Esta diferencia no refleja una mayor prevalencia real del trastorno en Uruguay, sino un sesgo de selección muestral directamente vinculado al país de procedencia.

En este contexto, incluir *País* como variable predictora crea un riesgo metodológico relevante: un modelo que aprenda a asociar Uruguay con TEA y Galicia con control no estaría detectando sintomatología clínica, sino reproduciendo el sesgo de recogida. Esto comprometería la validez clínica y la generalización del modelo a nuevas poblaciones. Por ello, se evalúa el impacto de eliminar *País* del conjunto de variables, comparando el rendimiento obtenido con y sin esta variable bajo el mismo protocolo experimental.

5.2.1 Impacto sobre el F1 medio por k

La Tabla 5.3 muestra el F1 medio —promediado sobre todos los selectores y modelos— para cada valor de k, en ambas configuraciones. Las diferencias son en todos los casos inferiores al punto porcentual, sin un patrón claro y consistente en ninguna dirección.

Para evaluar si estas diferencias son estadísticamente significativas, se aplica el test de Wilcoxon de rangos con signo sobre las distribuciones emparejadas de F1 (mismas combinaciones selector-modelo, dos condiciones). Los resultados confirman que las diferencias no son significativas para $k \in \{5, 10, 20, 30\}$, con p-valores muy superiores al umbral convencional $\alpha = 0.05$. La única excepción es $k = 50$, donde el test detecta una diferencia significativa ($p = 0.028$) favorable a la configuración con *País*, lo cual tiene sentido ya que al combinar dicha variable con un gran número de características se amplifica su efecto discriminativo artificial. En el resto del rango estudiado, eliminar *País* no degrada la capacidad discriminativa media del sistema, lo que confirma que la información clínica contenida en el resto de variables es suficiente para sostener el rendimiento.

Tabla 5.3: Comparativa de F1 medio global por k, con y sin la variable *País*. La diferencia es F1(Sin *País*) − F1(Con *País*).

k	F1 medio (Con *País*)	F1 medio (Sin *País*)	Diferencia	p-valor (Wilcoxon)
5	**0.7298**	0.7221	−0.0077	0.387
10	0.7483	**0.7485**	−0.0002	0.839
20	0.7587	**0.7623**	+0.0036	0.821
30	0.7718	**0.7731**	+0.0013	0.831
50	**0.7809**	0.7733	−0.0076	**0.028**

Negrita en F1: mayor valor entre ambas configuraciones por fila. **Negrita** en p-valor: diferencia estadísticamente significativa ($\alpha = 0.05$).

5.2.2 Impacto sobre la mejor combinación por k

Al analizar los resultados recogidos en la Tabla 5.4, se observa que la mejor combinación selector-modelo —identificada como aquella con mayor F1 medio sobre los 5 folds— muestra una pérdida de rendimiento consistente al eliminar *País* en todos los valores de k. La diferencia, nunca mayor de un 2%, llega a ser prácticamente nula para $k = 20$, lo que sugiere que con un número intermedio de variables el modelo es capaz de compensar la ausencia de *País* apoyándose en variables clínicas suficientemente informativas.

Tabla 5.4: Combinación selector-modelo con mayor F1 medio (promedio sobre 5 folds de CV) por valor de k, con y sin la variable *País*. La diferencia es F1(Con *País*) − F1(Sin *País*).

k	Mejor Comb. (Con *País*)	F1	Mejor Comb. (Sin *País*)	F1	Diferencia
5	RFE-SVM + RF	**0.7976**	E2EFS + LR	0.7782	−0.0193
10	RFE-SVM + LR	**0.8209**	mRMR + LR	0.8023	−0.0186
20	mRMR + LR	**0.8078**	mRMR + GB	0.8077	−0.0001
30	mRMR + LR	**0.8272**	ANOVA + GB	0.8175	−0.0096
50	RFE-SVM + GB	**0.8359**	ANOVA + GB	0.8175	−0.0184

Negrita: mayor F1-Score entre ambas configuraciones para cada valor de k.

Respecto a qué combinaciones resultan ganadoras, se aprecia que la eliminación de *País* modifica en varios casos tanto el selector como el modelo óptimo: por ejemplo, RFE-SVM domina con *País* en $k \in \{5, 10, 50\}$, mientras que sin ella emergen mRMR y ANOVA como

selectores más robustos. Esto apunta a que RFE-SVM tendía a seleccionar *País* como una de las variables más relevantes, beneficiándose artificialmente de su poder discriminativo engañoso. La Regresión Logística y *Gradient Boosting* se mantienen como los modelos más competitivos en ambas configuraciones, lo que indica que su rendimiento depende menos de la presencia de esta variable. En conjunto, estos resultados son coherentes con la hipótesis del sesgo: *País* concentra en sí misma el desequilibrio entre submuestras, por lo que los modelos que la incluyen pueden aprender un atajo estadístico que eleva el rendimiento medido en validación cruzada pero que no generalizaría a nuevas poblaciones de distinta procedencia.

5.2.3 Rendimiento por selector y modelo

La Figura 5.2 muestra el F1 medio desglosado por selector y por modelo para ambas configuraciones, junto con el *baseline* NO-FS como referencia. En cuanto a los selectores, el impacto de eliminar *País* es desigual: E2EFS y ReliefF son los más afectados, lo que sugiere que estos métodos tendían a seleccionar *País* con mayor frecuencia por su elevado poder discriminativo. Por el contrario, mRMR y MI muestran una ligera mejora, lo que indica que su criterio de selección dependía menos de esta variable. Respecto a los modelos, destaca que el árbol de decisión obtiene un rendimiento notablemente inferior al resto en ambas configuraciones, lo que anticipa que será el modelo menos competitivo en el análisis detallado. El impacto de eliminar la variable es bastante similar entre todos los modelos, produciéndose un ligero decrecimiento en el F1, a excepción de MLP que mejora levemente.

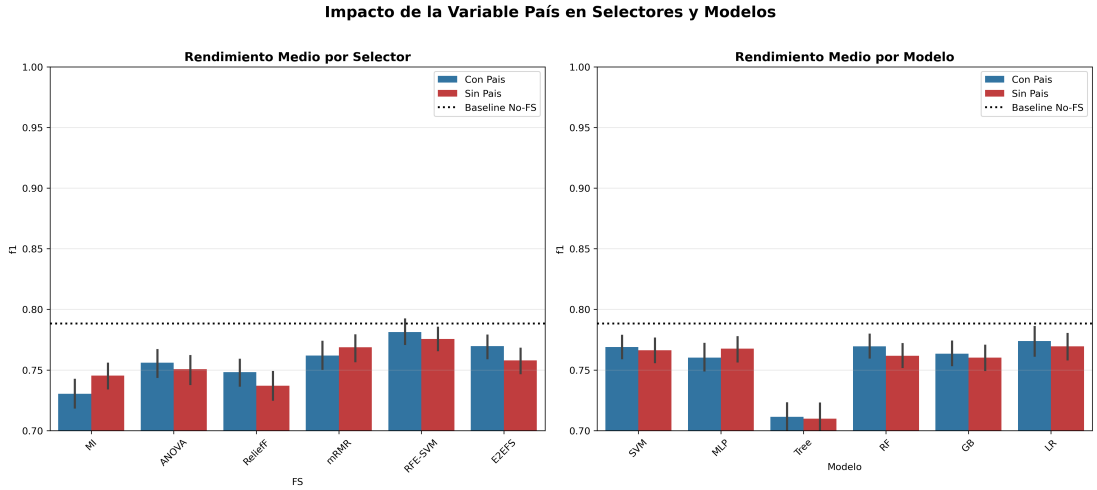


Figura 5.2: F1 medio por selector (izquierda) y por modelo (derecha), con y sin la variable *País*.

5.2.4 Evolución del F1 máximo por k

La Figura 5.3 muestra, para cada valor de k, el F1 máximo obtenido por la mejor configuración individual —es decir, el techo de rendimiento alcanzable— con y sin la variable *País*. A diferencia de las tablas anteriores, donde los F1 reflejaban promedios agregados por selector y modelo, estos valores corresponden al mejor resultado puntual observado en validación cruzada para cada k, lo que explica que sean considerablemente más altos.

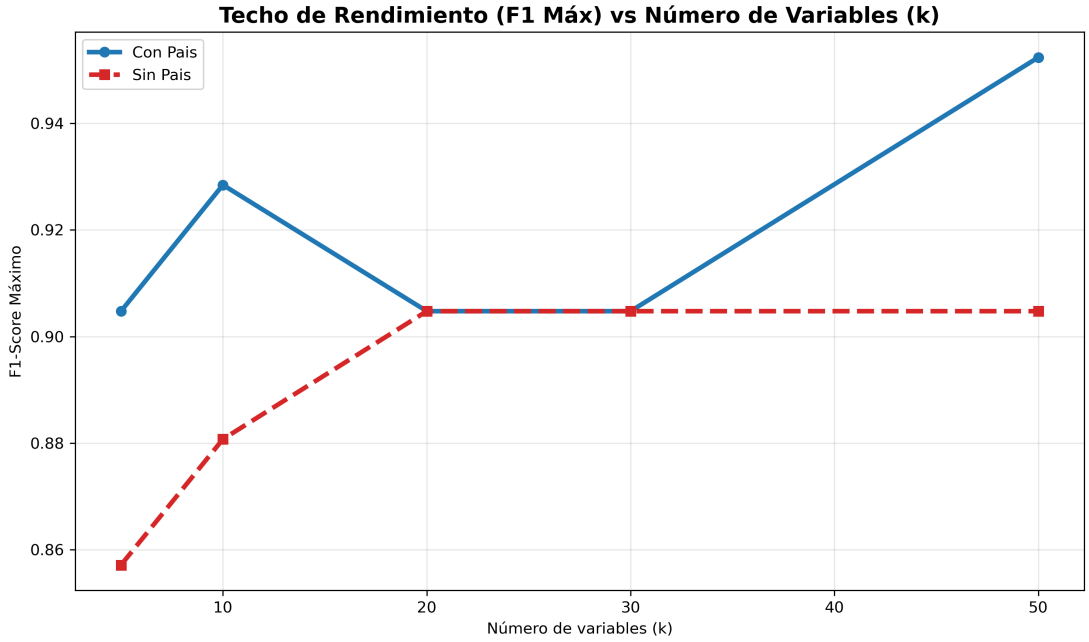


Figura 5.3: Evolución del F1 máximo alcanzable en función de k, con y sin la variable *País*.

La configuración con *País* muestra un comportamiento irregular: alcanza un pico en $k = 10$ antes de caer en $k = 20$, y dispararse de forma pronunciada hasta $k = 50$. Esta evolución apunta a que el modelo está aprovechando *País* como variable altamente discriminativa en combinación con un número elevado de características, reforzando la hipótesis del sesgo. Por su parte, la configuración sin *País* presenta una curva creciente que se estabiliza en torno a F1 ≈ 0.90 a partir de $k = 20$, sin experimentar las oscilaciones de la anterior. Ambas curvas coinciden en $k = 20$ y $k = 30$, siendo este el rango en que la eliminación de *País* tiene menor impacto sobre el techo de rendimiento.

5.2.5 Impacto sobre la selección de características

El análisis del top-20 de variables con mayor consenso para $k = 20$, reflejado en la Tabla 5.5, muestra que la eliminación de *País* produce cambios mínimos en el conjunto seleccionado: 18 de las 20 variables se mantienen robustas. Las dos variables que desaparecen del

top-20 al eliminar *País* son *País* en sí misma —que con su presencia ocupaba la segunda posición en cuanto a capacidad discriminativa, reforzando la hipótesis del sesgo— e *intsocq*, que se encontraba en el último puesto del ranking. En su lugar aparecen *barrio_curza_calles* y *fecuencia_estereotipias*, ambas con una interpretación clínica directa y más relevante que la procedencia geográfica.

Tabla 5.5: Top-20 de variables de mayor consenso con y sin la variable *País*. Las celdas sombreadas indican variables que aparecen en un ranking pero no en el otro.

Pos.	Variable (Con *País*)	Score	Variable (Sin *País*)	Score
1	*cuenta_historia*	93.33	*permanece_apartado*	98.33
2	*intercambia_objetos*	91.67	*cuenta_historia*	91.67
3	*Pais*	91.67	*intercambia_objetos*	91.67
4	*permanece_apartado*	90.00	*evita_contacto_ocular*	88.33
5	*evita_contacto_ocular*	86.67	*repite_sonidos_ininteligibles*	81.67
6	*repite_sonidos_ininteligibles*	81.67	*responde_negativamente_a_ordenes*	80.83
7	*responde_negativamente_a_ordenes*	80.83	*Medicamentos*	75.67
8	*hacer_cosas_repetidamente*	76.67	*Frecuencia_retraimiento*	73.33
9	*Gravedad_retraimiento*	73.33	*hacer_cosas_repetidamente*	71.67
10	*trabaja_ritmo_regular*	73.33	*trabaja_ritmo_regular*	70.83
11	*Gravedad_no_colaboradora*	71.67	*Localiza_informacion*	68.33
12	*Frecuencia_retraimiento*	70.83	*Gravedad_retraimiento*	68.33
13	*Medicamentos*	68.33	*Gravedad_no_colaboradora*	67.67
14	*Localiza_informacion*	63.67	*no_inicia_conversaciones*	65.83
15	*ofrece_ayuda*	63.33	*fecuencia_estereotipias*	63.67
16	*esperar_turno*	61.67	*ofrece_ayuda*	63.33
17	*Retraimiento_atencion*	60.83	*Retraimiento_atencion*	61.67
18	*no_inicia_conversaciones*	60.83	*barrio_curza_calles*	61.67
19	*mira_lejos_cuando_se_lo_mira*	58.33	*mira_lejos_cuando_se_lo_mira*	60.83
20	*intsocq*	58.33	*esperar_turno*	58.33

5.2.6 Estrategia seleccionada

En resumen, los resultados muestran que la variable País introduce un sesgo asociado a la procedencia geográfica de las submuestras, elevando artificialmente el rendimiento máximo sin aportar mejoras relevantes en el rendimiento medio. Además, su eliminación favorece la selección de variables más interpretables clínicamente y produce un comportamiento más estable entre configuraciones. Por ello, se opta por excluir *País* del análisis posterior, priorizando la robustez y la capacidad de generalización del modelo frente a ganancias de rendimiento potencialmente artificiales.

5.3 Análisis de rendimiento por selector, modelo y k

Esta sección analiza el rendimiento de las 180 configuraciones evaluadas —producto de combinar 6 selectores, 6 modelos y 5 valores de k—, agregadas de varias maneras, bajo la configuración de preprocesamiento definitiva (eliminación de variables con más del 50% de nulos, sin la variable *País*). El análisis se estructura progresivamente: primero se estudia el comportamiento individual de selectores y modelos, después su interacción conjunta, y finalmente la evolución en función de k para determinar el valor óptimo.

5.3.1 Rendimiento por selector

La Figura 5.4 muestra la distribución del F1 obtenido por cada selector, agregando sobre todos los modelos y valores de k, incluyendo el *baseline* NO-FS como referencia.

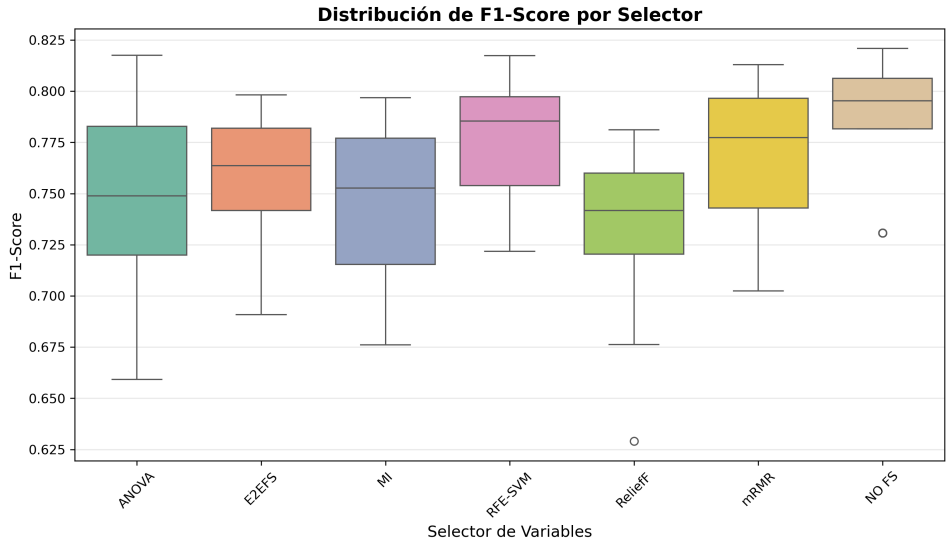


Figura 5.4: Distribución del F1-Score por selector de características sobre todas las combinaciones de modelo y k.

RFE-SVM es el selector con mayor mediana y menor dispersión, seguido de cerca por mRMR, lo que los convierte en los métodos más fiables de forma consistente. ANOVA, MI y E2EFS ocupan una posición intermedia con medianas similares, presentando este último una distribución más estrecha en comparación con los otros métodos, que tienen una variabilidad mayor. En cambio, ReliefF tiene la mediana más baja de todos y un *outlier* extremo en torno a 0.625, lo que apunta a que hay combinaciones concretas en las que falla notablemente. Respecto al *baseline*, ningún selector lo supera en mediana al agregar sobre todos los k y modelos, lo que es coherente con lo observado en el apartado anterior: la selección de características solo lo mejora en configuraciones específicas, no de forma generalizada.

La Tabla 5.6 detalla los valores medios de F1 por selector para cada valor de k. RFE-SVM y mRMR lideran en prácticamente todos los valores de k, siendo especialmente competitivos a partir de $k = 20$, donde ambos igualan e incluso superan el *baseline* (0.7883). ANOVA, E2EFS y MI parten de resultados cercanos a 0.7 para $k = 5$ que progresan hasta $k = 20$, donde se estabilizan en valores ligeramente inferiores a los dos mejores métodos. Por su parte, ReliefF es el selector más irregular, con valores bajos en $k = 20$ que no siguen la tendencia ascendente del resto, lo que sugiere que su criterio de selección es menos estable ante cambios en el número de variables.

Tabla 5.6: F1 medio por selector en función de k (promedio sobre los 6 modelos y los 5 folds de CV).

Selector	**k=5**	**k=10**	**k=20**	**k=30**	**k=50**
RFE-SVM	**0.7472**	**0.7752**	0.7820	**0.7901**	**0.7832**
mRMR	0.7254	0.7664	**0.7856**	0.7879	0.7785
ANOVA	0.7043	0.7366	0.7566	0.7783	0.7775
E2EFS	0.7461	0.7483	0.7542	0.7676	0.7733
MI	0.7143	0.7261	0.7611	0.7604	0.7645
ReliefF	0.6954	0.7382	0.7347	0.7543	0.7629
NO-FS (*baseline*)			0.7883		

Negrita: mayor F1 medio por valor de k.

La Figura 5.5 confirma que este comportamiento es coherente en las cinco métricas evaluadas, no solo en F1. RFE-SVM lidera en F1, Accuracy, Recall y Precision de forma sostenida, y es el único selector que alcanza o roza el baseline en $k = 30$. El resto de métodos mues-

tran también una tendencia ascendente para dichas métricas pero sin llegar a tales resultados. Por otro lado, en ROC-AUC la mayoría de selectores convergen hacia valores entre 0.84 y 0.85 para $k \geq 30$, indicando una buena capacidad discriminativa global. ReliefF presenta el comportamiento más irregular en todas las métricas, con una caída notable entre $k = 10$ y $k = 20$.

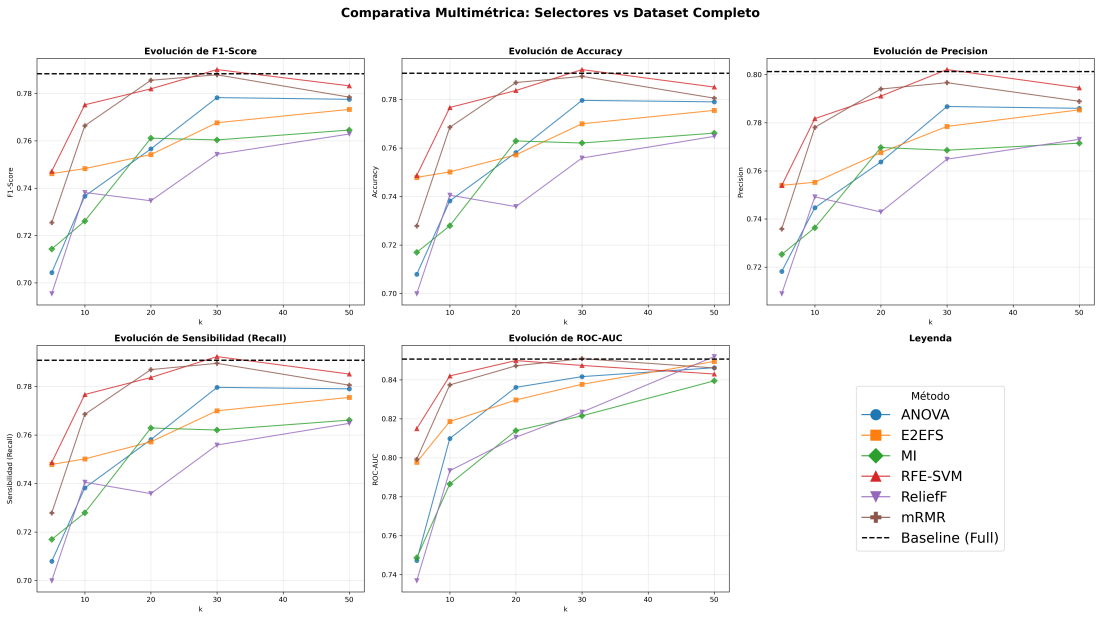


Figura 5.5: Evolución de F1, Accuracy, Precisión, Recall y ROC-AUC en función de k para cada selector.

5.3.2 Rendimiento por modelo

La Figura 5.6 muestra la distribución del F1 por modelo de clasificación, agregando sobre todos los selectores y valores de k. El resultado más llamativo es la clara separación del árbol de decisión (*Tree*) respecto al resto: su mediana se sitúa en torno a 0.72, casi 6 puntos por debajo de los demás modelos, y presenta los *outliers* más extremos. Este comportamiento era esperable dado su conocido riesgo de sobreajuste con subconjuntos reducidos de variables y tamaños muestrales pequeños.

El resto de modelos muestran un rendimiento muy homogéneo, con medianas entre 0.76 y 0.78: GB obtiene la caja más alta en su cuartil superior aunque con una mediana no necesariamente la más alta, LR destaca por tener una dispersión baja y la mediana más elevada, mientras que SVM, MLP y RF presentan distribuciones muy similares entre sí. Esta homogeneidad indica que, descartando el árbol de decisión, la elección del modelo tiene un impacto menor que la elección del selector sobre el rendimiento medio.

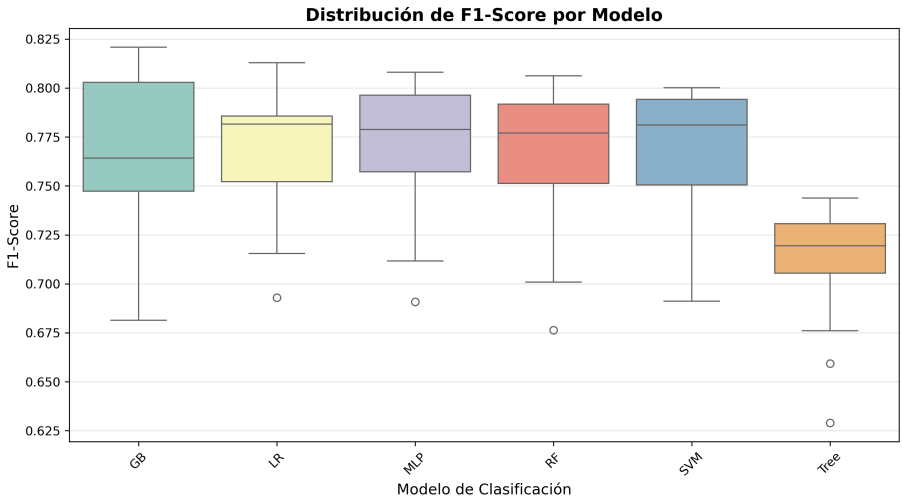


Figura 5.6: Distribución del F1-Score por modelo de clasificación sobre todas las combinaciones de selector y k.

La Tabla 5.7 detalla los valores por modelo y k. En general, todos los modelos muestran una progresión consistente con el aumento de k, lo que indica que son capaces de aprovechar la información adicional aportada por conjuntos más amplios de características. Se puede apreciar como a partir de $k = 20$ los valores se comienzan a estabilizar en torno a 0.78, llegando a un máximo de 0.7922 para GB en $k = 50$ y 0.7915 para MLP en $k = 30$. En contraste, el árbol de decisión es la opción menos eficaz y el único modelo que no mejora de forma sostenida con k, estancándose ya a partir de $k = 10$ y confirmando que no se beneficia de añadir más variables del mismo modo que los demás modelos. Estos resultados vuelven a reafirmar que la elección del modelo no tiene un gran impacto sobre el rendimiento.

Tabla 5.7: F1 medio por modelo en función de k (promedio sobre los 6 selectores y los 5 folds de CV).

Modelo	**k=5**	**k=10**	**k=20**	**k=30**	**k=50**
GB	0.7356	0.7508	0.7776	0.7885	**0.7922**
MLP	0.7371	0.7626	**0.7808**	**0.7915**	0.7866
SVM	**0.7449**	**0.7646**	0.7739	0.7837	0.7842
RF	0.7298	0.7611	0.7730	0.7874	0.7889
LR	0.7472	0.7638	0.7753	0.7879	0.7820
Tree	0.6949	0.7220	0.7158	0.7127	0.7189

Negrita: mayor F1 medio por valor de k entre los modelos de clasificación.

5.3.3 Interacción entre selectores y modelos

El heatmap de la Figura 5.7 muestra el F1 medio de cada combinación selector-modelo, promediado sobre todos los valores de k.

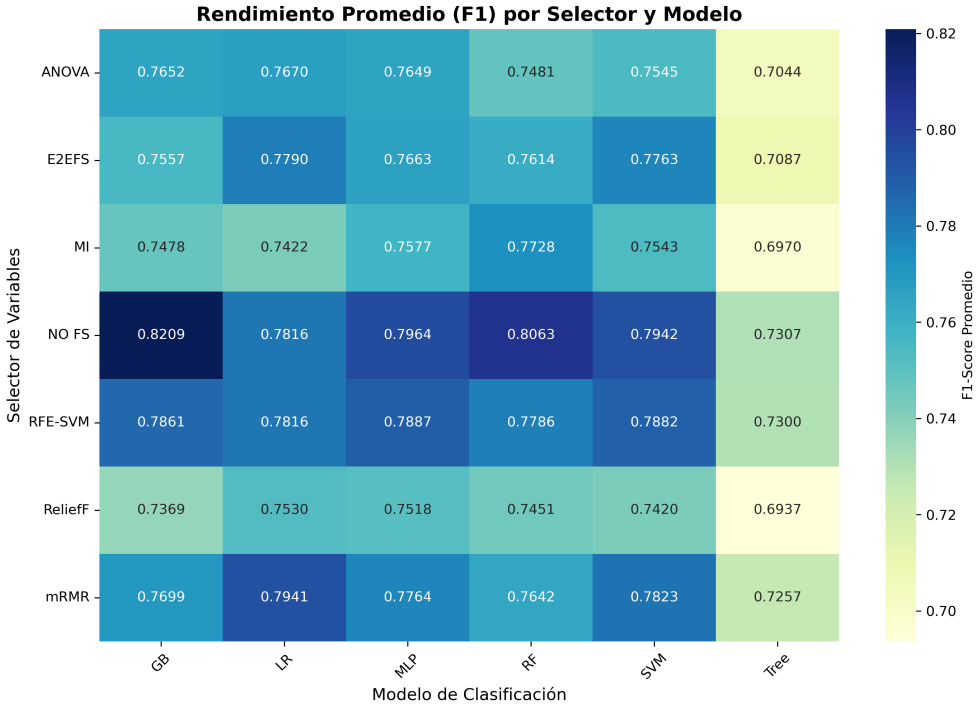


Figura 5.7: F1 medio por combinación selector-modelo, promediado sobre todos los valores de k. Se incluye la fila NO-FS como referencia del baseline.

La combinación más destacada entre los métodos de selección es mRMR + LR (F1 = 0.7941), seguida de RFE-SVM + MLP (0.7887) y RFE-SVM + SVM (0.7882). Estos dos selectores son los únicos que alcanzan valores próximos al *baseline* en algunas de sus combinaciones, mientras que ANOVA, ReliefF y MI se quedan consistentemente por debajo independientemente del modelo empleado.

Atendiendo al rendimiento por modelo, SVM y MLP son los más consistentes entre selectores: obtienen valores similares con cualquier método de selección, sin diferencias superiores a 3 puntos entre su mejor y peor combinación. LR destaca especialmente con E2EFS y mRMR —obteniendo con este último el mejor resultado de combinación excluyendo al *baseline*—, mientras que con MI cae hasta 0.7422, la segunda peor celda de toda la tabla excluyendo el árbol. RF presenta el patrón inverso: su mejor resultado es con RFE-SVM, mientras que con mRMR y ANOVA obtiene valores inferiores a la media. GB es el modelo con mayor rango de variación según el selector: alcanza 0.7861 con RFE-SVM pero cae a 0.7369 con ReliefF, lo que sugiere que es más sensible a la calidad del subconjunto seleccionado que el resto.

El árbol de decisión es el único modelo que no se beneficia de ningún selector de forma destacada: su rango va de 0.6937 (ReliefF) a 0.73 (RFE-SVM), siempre por debajo del resto de modelos en cualquier combinación. La fila NO-FS confirma además que GB (0.8209) y RF (0.8063) son los modelos que más se benefician del uso de todas las variables, lo que explica por qué la selección de características tiene más impacto en LR, MLP y SVM que en los modelos de *ensemble*.

La Figura 5.8 muestra el selector con mejor F1 medio para cada combinación modelo-k, lo que permite identificar qué método domina en cada escenario concreto.

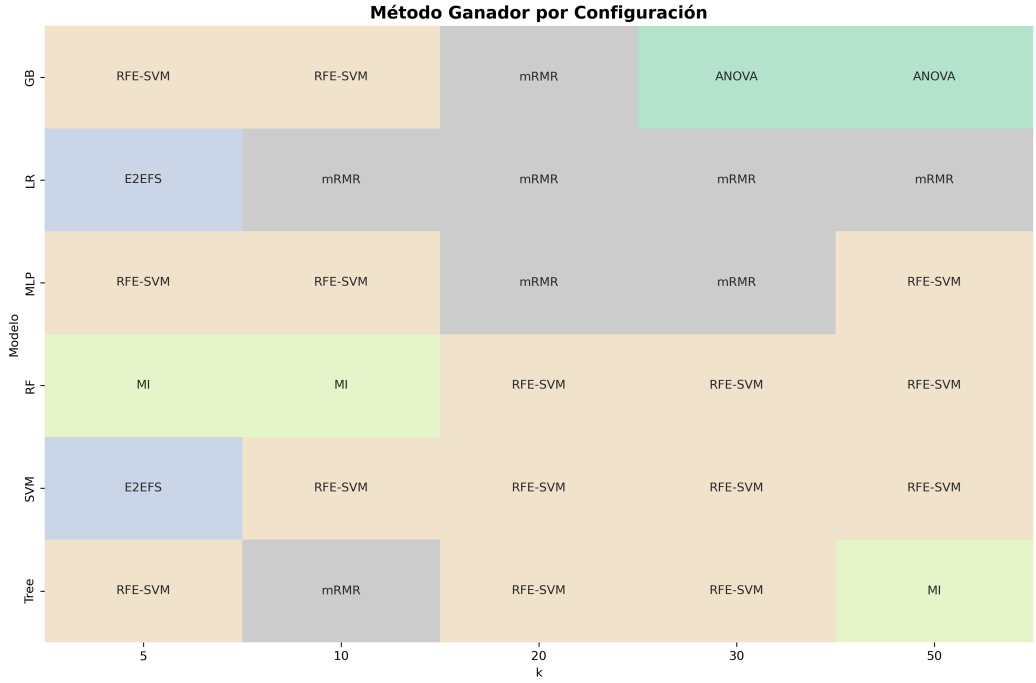


Figura 5.8: Selector con mayor F1 medio para cada combinación de modelo y valor de k.

RFE-SVM y mRMR dominan la gran mayoría de celdas: RFE-SVM es el selector ganador de forma consistente con SVM en casi todos los valores de k, y con MLP en los extremos del rango. mRMR domina claramente con LR a partir de $k = 10$ y se extiende también a MLP en valores intermedios, lo que refuerza la idea de que su criterio de mínima redundancia genera subconjuntos especialmente beneficiosos para modelos lineales y semiparamétricos. ANOVA presenta un comportamiento tardío pero sólido: es irrelevante para k pequeños pero emerge como ganador con GB en los valores más altos, coherente con la fuerte mejora de rendimiento que este selector mostraba al aumentar k en la Tabla 5.6 . Para $k = 5$ y $k = 10$, el mapa es notablemente más heterogéneo —con E2EFS ganando con LR y SVM, y MI siendo el mejor para RF—, lo que indica que con subconjuntos muy reducidos no hay un método dominante y la elección del selector tiene un impacto mayor sobre el resultado final.

5.3.4 Evolución del rendimiento en función de k y elección del valor óptimo

La Figura 5.9 muestra la evolución del techo de rendimiento —F1 de la mejor configuración individual— y del F1 medio sobre todas las combinaciones en función de k, junto con el rango de variabilidad, el *baseline* NO-FS y las anotaciones de ganancia marginal entre valores consecutivos de k.

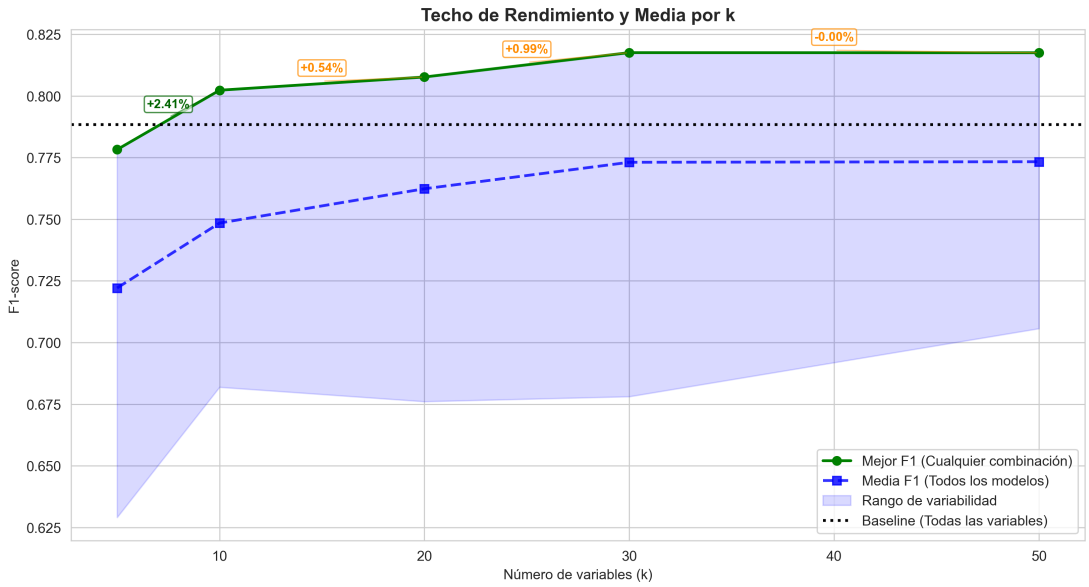


Figura 5.9: Evolución del techo de rendimiento, F1 medio y rango de variabilidad en función de k, con ganancia marginal anotada entre valores consecutivos (verde: $\geq$1%, naranja: $<$1%). Línea discontinua: *baseline* NO-FS.

El techo de rendimiento crece de forma pronunciada hasta $k = 20$ y se estabiliza a partir de ahí: la ganancia cae de +2.41% (de $k = 5$ a $k = 10$) a +0.54% (de $k = 10$ a $k = 20$), y prácticamente desaparece entre $k = 30$ y $k = 50$. El F1 medio sigue una tendencia similar aunque más suave, manteniéndose siempre por debajo del *baseline* y creciendo de 0.72 en $k = 5$ hasta estabilizarse en torno a 0.77 a partir de $k = 30$. El rango de variabilidad —diferencia entre el máximo y el mínimo— se estrecha progresivamente conforme aumenta k: en $k = 5$ es muy amplio, con configuraciones que van de 0.63 a 0.78, mientras que en $k = 30$ y $k = 50$ el intervalo se comprime notablemente, indicando que la elección concreta de selector y modelo tiene cada vez menos impacto sobre el resultado final. Este patrón se complementa con la evolución de la dispersión entre combinaciones, ilustrada en la Figura 5.10: en $k = 5$ el rango intercuartílico es amplio y aparecen *outliers* por debajo de 0.63, mientras que a partir de $k = 20$ las distribuciones son más compactas y con medianas más altas, lo que indica que el sistema gana robustez conforme aumenta el número de variables seleccionadas.

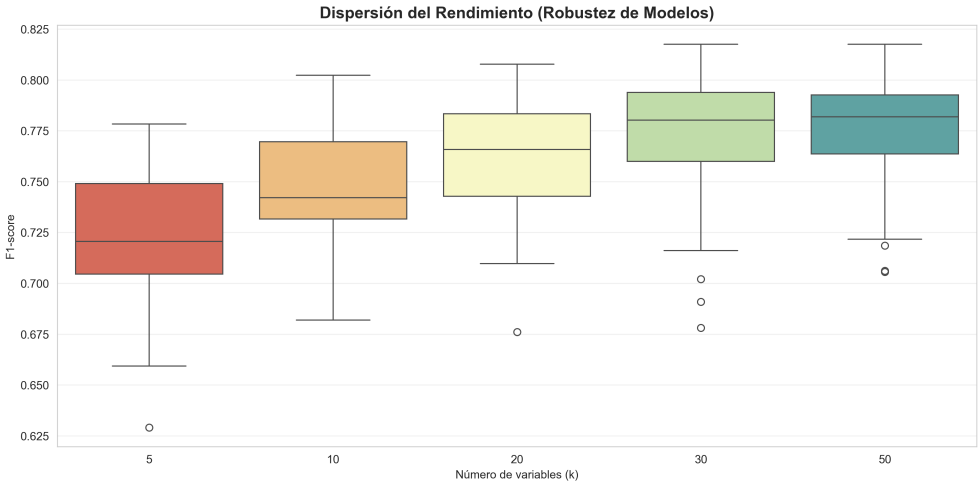


Figura 5.10: Dispersión del F1-Score entre todas las combinaciones selector-modelo para cada valor de k.

A partir de $k = 10$, el techo de rendimiento supera ya el *baseline*, pero la mejor configuración cambia con k, como detalla la Tabla 5.8: mRMR + LR lidera en $k = 10$, mRMR + GB en $k = 20$, y ANOVA + GB domina en $k = 30$ y $k = 50$ con idéntico F1 (0.8175), coherente con la fuerte mejora de ANOVA para k elevados observada anteriormente, mientras que mRMR es más competitivo cuando el subconjunto es reducido. El resto de métricas confirman la solidez de estas configuraciones: Accuracy y Recall coinciden en todos los casos, lo que refleja un clasificador bien calibrado sin sesgo hacia ninguna clase, y la Precision supera siempre al F1, indicando que los falsos positivos están bien controlados. En cuanto al ROC-AUC, el valor más alto corresponde a $k = 10$ con mRMR + LR (0.8835), lo que indica una capacidad discriminativa especialmente buena en ese punto independientemente del umbral de decisión. A partir de $k = 20$ se estabiliza en torno a valores inferiores.

Tabla 5.8: Mejor combinación selector-modelo y métricas completas por valor de k.

k	Selector	Modelo	F1	Acc.	Prec.	Recall	AUC
5	E2EFS	LR	0.7783	0.7799	0.7879	0.7799	0.8459
10	mRMR	LR	0.8023	0.8037	0.8152	0.8037	**0.8835**
20	mRMR	GB	0.8077	0.8086	0.8131	0.8086	0.8539
30	ANOVA	GB	**0.8175**	**0.8181**	**0.8242**	**0.8181**	0.8623
50	ANOVA	GB	**0.8175**	**0.8181**	0.8235	**0.8181**	0.8733

Negrita: mejor valor de cada métrica en la tabla.

Teniendo en cuenta la evolución de la ganancia marginal, robustez y equilibrio entre rendimiento e interpretabilidad, se establece $k = 20$ como el valor óptimo. Es el primer punto en que el rendimiento se estabiliza: la ganancia adicional hasta $k = 30$ no justifica añadir 10 variables más cuando la diferencia en F1 es inferior a un punto porcentual y las mejores combinaciones en $k = 30$ y $k = 50$ son idénticas. Además, en $k = 20$ la dispersión entre combinaciones ya muestra la compactación propia de los valores más altos de k, con una mediana cercana a 0.77 y *outliers* menos extremos que en valores inferiores. Por último, 20 variables representan un subconjunto suficientemente manejable para el análisis clínico de las características más relevantes, que se aborda en la sección 5.5.

5.4 Análisis de la selección de características

Una vez determinada la configuración de preprocesamiento definitiva y el valor óptimo de $k = 20$ variables, el objetivo de esta sección es estudiar en profundidad el comportamiento de los métodos de selección de características: qué tan consistentes son sus elecciones a lo largo de los distintos folds de validación cruzada, en qué medida coinciden entre sí y qué subconjunto de variables emerge como el más robusto y representativo. Este análisis no solo permite validar la fiabilidad del proceso de selección, sino que constituye el paso previo necesario para la interpretación clínica de las características más relevantes.

5.4.1 Estabilidad y acuerdo entre selectores

La estabilidad de un método de selección de características mide la frecuencia con la que una variable es seleccionada a lo largo de los 5 folds de validación cruzada. Un valor del 100% indica que la variable aparece en todos los folds, mientras que valores bajos reflejan una mayor sensibilidad a la partición de los datos. En datasets pequeños como el utilizado en este trabajo, donde pequeñas variaciones en el conjunto de entrenamiento pueden alterar el orden de importancia de las variables, esta métrica es un indicador clave de la fiabilidad del selector.

La Figura 5.11 muestra la evolución de la estabilidad promedio de cada selector en función de k. El patrón general es claro: todos los métodos mejoran su estabilidad al aumentar k, lo que es esperable, ya que con subconjuntos más grandes la probabilidad de que una variable concreta sea incluida crece. Sin embargo, el comportamiento difiere notablemente entre métodos. ANOVA y ReliefF presentan los valores más altos en todo el rango, alcanzando ambos una estabilidad del 76% para $k = 50$, lo que indica que sus criterios de selección son muy poco sensibles a la partición de los datos. mRMR parte de valores similares a los del resto ($\approx$38%) en $k = 5$ pero escala de forma pronunciada hasta el 66% en $k = 50$, superando a todos los métodos salvo ANOVA y ReliefF en los valores altos de k. Por el contrario, RFE-SVM presenta la estabilidad más baja y prácticamente plana en todo el rango —entre el 38% y el 40%—, lo

que resulta llamativo dado que, como se vio en la sección 5.3, es uno de los selectores con mayor rendimiento. Esto revela una diferencia relevante: RFE-SVM selecciona variables distintas en cada fold pero que son igual de discriminativas, lo que apunta a que existe un conjunto amplio de características con poder predictivo similar en el dataset. MI y E2EFS muestran un comportamiento intermedio, con estabilidades que convergen hacia el 45–49% para $k = 50$ sin destacar en ningún extremo del rango.

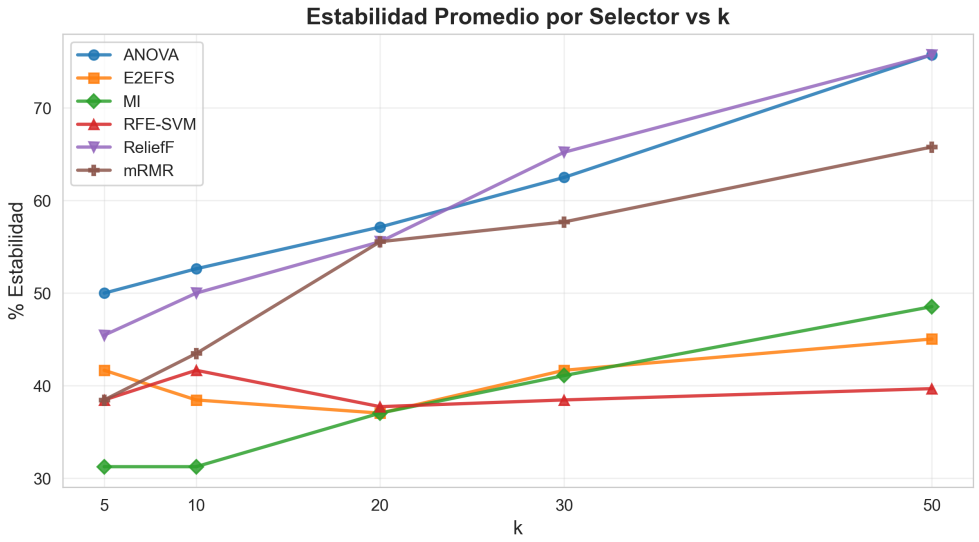


Figura 5.11: Estabilidad promedio por selector en función de k.

La similitud de Jaccard entre pares de selectores, representada en la Figura 5.12, complementa esta visión midiendo el solapamiento entre los conjuntos de variables seleccionados por cada par de métodos, promediado sobre todos los valores de k. Los valores oscilan entre 0.20 y 0.59, lo que indica que ningún par de selectores es intercambiable pero tampoco completamente independiente. El par con mayor acuerdo es ANOVA–ReliefF, coherente con la alta estabilidad de ambos métodos y con el hecho de que los dos son métodos de filtro que evalúan la relevancia individual de cada variable sin considerar redundancias entre ellas. Le sigue ANOVA–mRMR, lo que sugiere que el criterio de máxima relevancia de mRMR converge parcialmente con el criterio ANOVA. En el extremo opuesto, E2EFS–MI y E2EFS–ReliefF son los pares con menor coincidencia, lo que refleja que E2EFS, al optimizar la selección de forma conjunta con el entrenamiento de la red neuronal, explora un espacio de variables distinto al de los métodos de filtro clásicos. RFE-SVM muestra un patrón de acuerdo moderado y homogéneo con todos los demás métodos (entre 0.22 y 0.47), sin una asociación clara con ningún grupo. En conjunto, la diversidad de criterios entre selectores es una propiedad deseable: si los métodos coincidieran en elegir exactamente las mismas variables, el análisis de consenso que se presenta a continuación no añadiría información respecto a cualquier selector individual.

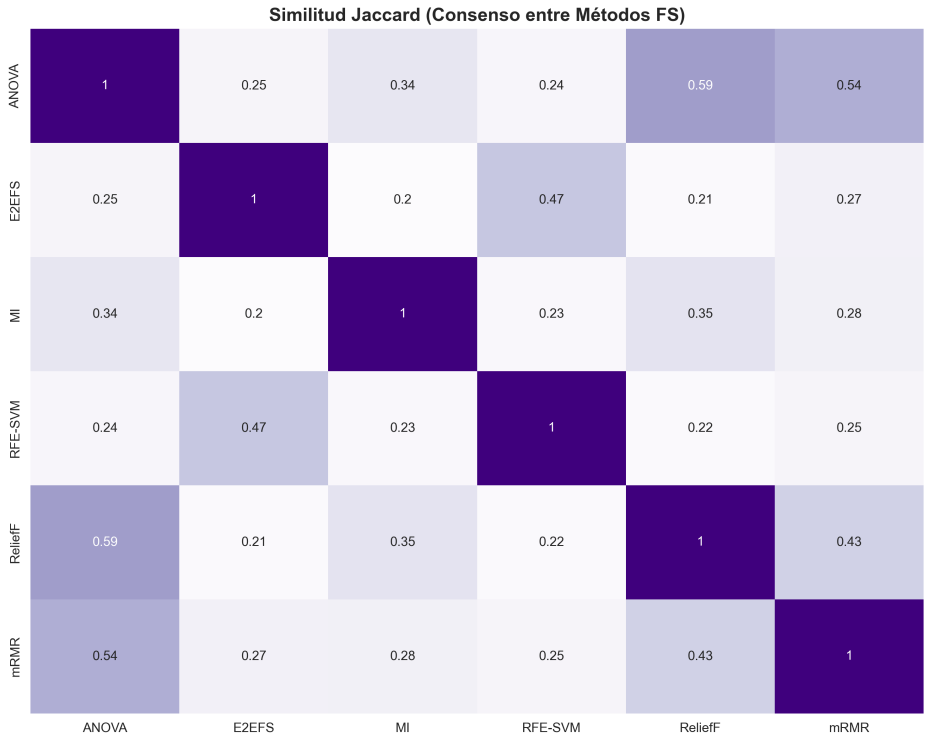


Figura 5.12: Similitud de Jaccard entre pares de selectores, promediada sobre todos los valores de k.

5.4.2 Variables robustas entre métodos y valores de k

Más allá de la estabilidad promedio de cada método y el grado de acuerdo entre ellos, resulta relevante identificar qué variables concretas son seleccionadas de forma robusta, tanto por diferentes métodos como ante distintos valores del número de características k. Para ello, se analizan dos propiedades complementarias: la consistencia, que mide cuántos selectores distintos coinciden en seleccionar una misma variable; y la persistencia, que identifica las variables que son seleccionadas por un mismo método independientemente del valor de k.

Se consideran consistentes aquellas variables seleccionadas con una estabilidad igual o superior al 60% por al menos dos métodos distintos. La Tabla 5.9 recoge las 13 variables que cumplen este criterio para el valor elegido como óptimo $k = 20$, ordenadas por número de selectores y estabilidad media. Las cuatro variables con mayor consistencia —*permanece_apartado*, *cuenta_historia*, *intercambia_objetos* y *evita_contacto_ocular*— son seleccionadas por cinco o seis de los métodos, con estabilidades superiores al 84%. Este alto acuerdo entre métodos de naturaleza muy distinta (filtro, envolvente y embebido) constituye una garantía sólida de que su relevancia no es fruto de un criterio de selección particular, sino que refleja una capacidad discriminativa real frente al diagnóstico de TEA.

Tabla 5.9: Variables consistentes para $k = 20$.

Variable	Sel.	Est.(%)	Variable	Sel.	Est.(%)
permanece_apartado	6	96.67	*Medicamentos*	3	100.00
cuenta_historia	5	92.00	*trabaja_ritmo_regular*	3	86.67
intercambia_objetos	5	92.00	*Retraimiento_atencion*	3	73.33
evita_contacto_ocular	5	84.00	*hacer_cosas_repetidamente*	3	73.33
responde_neg..._ordenes	4	95.00	*ofrece_ayuda*	3	73.33
repite_sonidos_ininteligibles	4	90.00	*mira_lejos_cuando_se_lo_mira*	3	60.00
Frecuencia_retraimiento	4	80.00			

Sel.: número de selectores (de 6) que incluyen la variable. **Est.**: estabilidad media en validación cruzada.

La persistencia complementa la consistencia desde una perspectiva longitudinal: una variable es persistente en un selector si aparece en su subconjunto seleccionado para todos los valores de k. La Figura 5.13 muestra las variables persistentes ordenadas por el número de selectores en los que lo son, con un punto de color por cada selector que las incluye de forma invariante. Tres variables destacan por su persistencia máxima: *cuenta_historia*, *evita_contacto_ocular* y *permanece_apartado* son seleccionadas de forma invariante por los seis métodos independientemente de k. A estas se suma *intercambia_objetos*, persistente en 5 selectores. No es casualidad que estas cuatro variables coincidan exactamente con las de mayor consistencia en la Tabla 5.9: son robustas tanto entre métodos como ante cambios en el tamaño del subconjunto, lo que las convierte en los candidatos más sólidos del conjunto final de características. Con persistencia en 4 selectores destacan además *Medicamentos* y *repite_sonidos_ininteligibles*, mientras que el resto de variables lo son únicamente en dos o tres selectores, lo que indica que su relevancia es más específica del criterio de ese método concreto y no generalizable al mismo nivel que el grupo anterior.

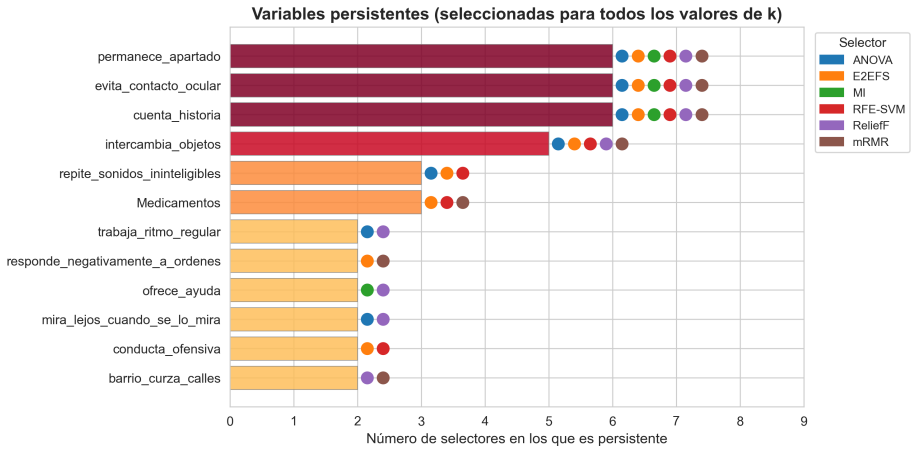


Figura 5.13: Variables persistentes en 2 o más selectores ante todos los valores de k.

5.4.3 Consenso y selección final de características

Los análisis de estabilidad, consistencia y persistencia de los apartados anteriores ofrecen evidencias parciales sobre la robustez de las variables, pero lo hacen de forma independiente. Con el fin de integrarlas en una única medida que permita ordenar las variables de forma global, se define el *score* de consenso, calculado para el valor óptimo $k = 20$ como la media aritmética de dos componentes: el porcentaje de métodos de selección que incluyen la variable en su subconjunto (acuerdo entre selectores) y la estabilidad media de la variable a lo largo de los 5 folds de validación cruzada. Ambos componentes se normalizan al intervalo $[0, 100]$, de forma que el *score* resultante es directamente interpretable como un porcentaje de robustez global:

$$\text{Consenso}(\text{X}_\text{j}) = 50 \cdot \frac{\text{Nº selectores que eligen } X_j}{6} + 50 \cdot \frac{\text{Estabilidad media de } X_j \text{ en CV}}{100} \quad (5.1)$$

La Tabla 5.10 muestra el Top 20 de variables ordenadas por su consenso. El podio lo forman *permanece_apartado*, *cuenta_historia* e *intercambia_objetos*, con puntuaciones superiores a 90, coherentes con los resultados de consistencia y persistencia ya descritos. Les siguen de cerca *evita_contacto_ocular* y *repite_sonidos_ininteligibles*. A partir de la séptima posición el *score* cae por debajo de 75, indicando una segunda franja de variables relevantes pero con menor unanimidad entre métodos. Las últimas posiciones presentan puntuaciones en torno a 60, lo que refleja que son seleccionadas de forma consistente por algunos métodos pero no de forma generalizada. La procedencia e interpretación clínica de estas variables se analiza en detalle en la sección 5.5.

Tabla 5.10: Top 20 variables ordenadas por *score* de consenso para $k = 20$.

Pos.	Variable	Score	Pos.	Variable	Score
1	*permanece_apartado*	98.33	11	*Localiza_informacion*	68.33
2	*cuenta_historia*	91.67	12	*Gravedad_retraimiento*	68.33
3	*intercambia_objetos*	91.67	13	*Gravedad_no_colaboradora*	67.67
4	*evita_contacto_ocular*	88.33	14	*no_inicia_conversaciones*	65.83
5	*repite_sonidos_ininteligibles*	81.67	15	*fecuencia_estereotipias*	63.67
6	*responde_neg_a_ordenes*	80.83	16	*ofrece_ayuda*	63.33
7	*Medicamentos*	75.67	17	*barrio_curza_calles*	61.67
8	*Frecuencia_retraimiento*	73.33	18	*Retraimiento_atencion*	61.67
9	*hacer_cosas_repetidamente*	71.67	19	*mira_lejos_se_lo_mira*	60.83
10	*trabaja_ritmo_regular*	70.83	20	*esperar_turno*	58.33

La Figura 5.14 muestra, para cada una de las 20 variables del ranking y cada valor de k, cuántos de los seis métodos la incluyen en su subconjunto. El patrón es especialmente revelador: las cuatro variables del núcleo duro —*permanece_apartado*, *cuenta_historia*, *intercambia_objetos* y *evita_contacto_ocular*— mantienen el acuerdo máximo de 6 métodos para prácticamente todos los valores de k, lo que confirma su robustez total ante el tamaño del subconjunto. En el extremo opuesto, variables como *Frecuencia_retraimiento* o *no_inicia_conversaciones* parten de acuerdo nulo o casi nulo en $k = 5$ y van ganando consenso progresivamente hasta alcanzar 4–6 métodos en $k = 50$, lo que indica que su relevancia emerge solo cuando el subconjunto tiene un tamaño suficiente. Este patrón diferenciado justifica la elección de $k = 20$ como punto de equilibrio: es el valor a partir del cual la mayoría de variables del Top 20 alcanzan un acuerdo de al menos 4 métodos, garantizando que el subconjunto seleccionado no depende de un único criterio.

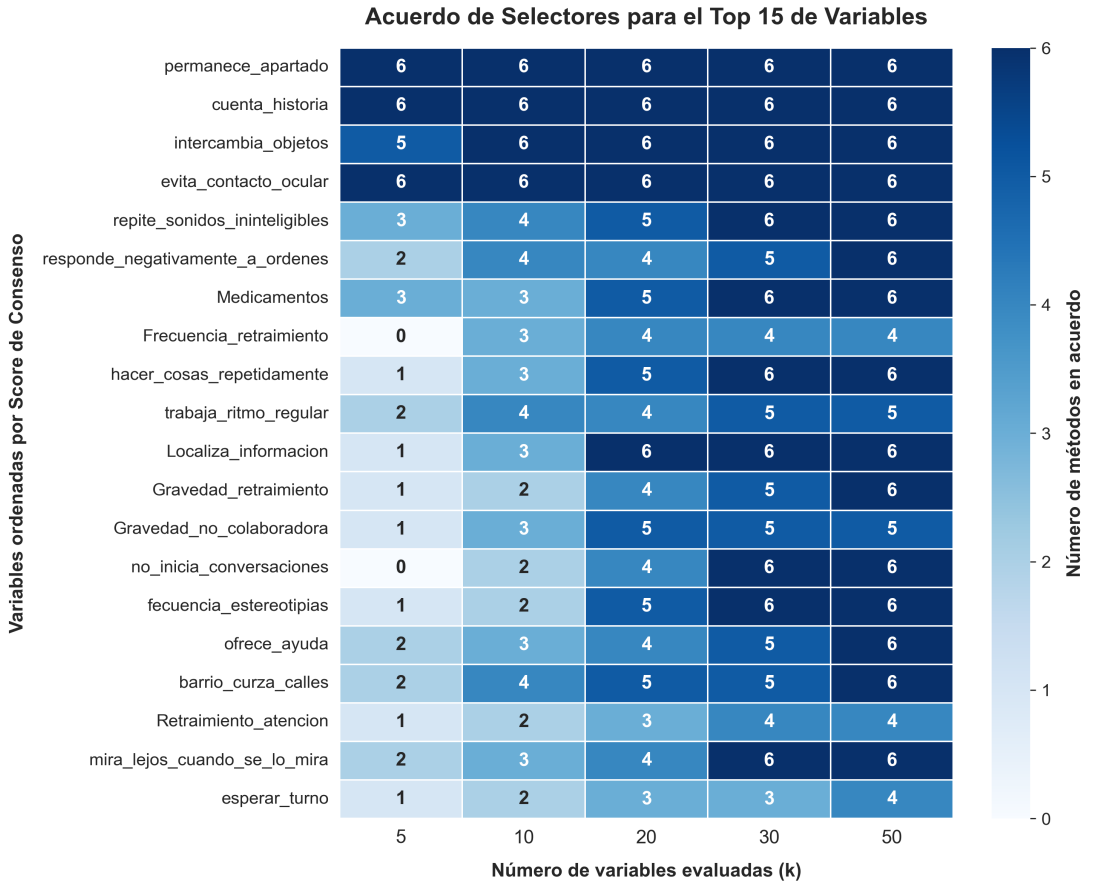
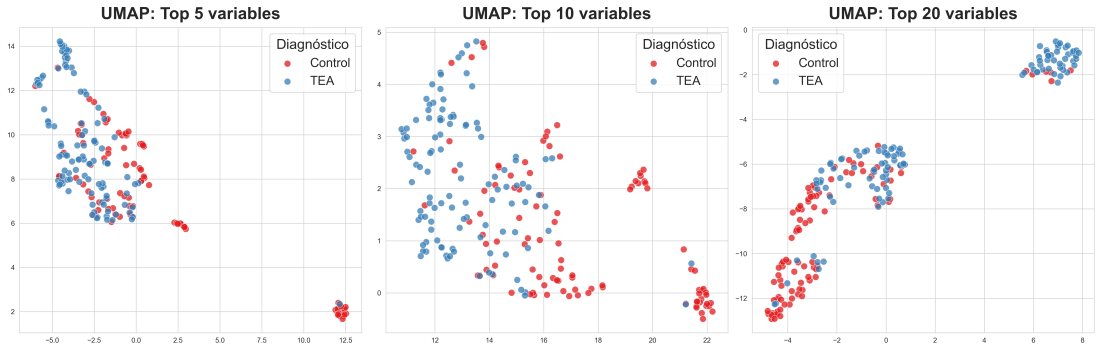


Figura 5.14: Número de selectores en acuerdo para las 20 variables de mayor consenso en función de k.

5.4.4 Separabilidad con las variables de consenso seleccionadas

Para evaluar si el subconjunto de variables identificado por el análisis de consenso mejora la separabilidad entre grupos respecto al espacio original, se aplica UMAP a los Top 5, 10 y 20 variables de consenso y se compara con la proyección sobre las 216 variables originales presentada en el Análisis Exploratorio (Figura 3.12).



Los resultados son notablemente más informativos que los obtenidos con las variables originales. Con tan solo el Top 5, la proyección ya muestra una cierta tendencia a la agrupación, aunque con solapamiento considerable. A partir del Top 10 comienza a apreciarse una separación más definida entre regiones del espacio ocupadas preferentemente por cada grupo. La mejora más llamativa se produce en el Top 20: la proyección UMAP revela dos agrupaciones claramente diferenciadas en los extremos del espacio reducido, con el grupo TEA concentrado en la región superior derecha y el grupo control en la inferior izquierda, y una zona de transición central con algunos solapamientos. Este contraste con la proyección sobre las 216 variables originales —donde ambos grupos aparecían completamente entremezclados sin estructura visible— confirma que el subconjunto de consenso no solo es estadísticamente robusto, sino que captura información genuinamente discriminativa que el espacio completo diluía entre cientos de variables ruidosas o redundantes.

5.5 Interpretación clínica de las características seleccionadas

El análisis de consenso identifica un subconjunto de 20 variables estadísticamente robustas. Sin embargo, que un algoritmo seleccione una variable no implica necesariamente que tenga sentido desde el punto de vista clínico: podría deberse a ruido, a correlaciones espurias o a patrones específicos de la muestra que no generalizarían a nuevos pacientes. Por ello, este apartado examina si las variables seleccionadas tienen una justificación clínica reconocida en el ámbito del TEA, lo que constituye una forma de validación cualitativa del sistema. Las 20

variables se agrupan en los tres bloques de afectación nuclear del trastorno según el DSM-5 [1] más un bloque funcional, y se analiza su origen —GARS-2, ICAP o variables clínicas— para entender qué tipo de información aporta cada una.

Alteraciones en la interacción social

Este bloque es el más representado en el ranking e incluye tanto ítems del GARS-2 como habilidades adaptativas del ICAP. Refleja las dificultades del individuo para relacionarse con los demás y para desenvolverse de forma independiente en su entorno.

- **Aislamiento y evitación** (*permanece_apartado*, *evita_contacto_ocular*, *mira_lejos_cuando_se_lo_mira*) [GARS-2]: estas tres variables describen un mismo patrón de desconexión social que se manifiesta de formas distintas. Aislarse en situaciones grupales y no sostener la mirada o mirar a lo lejos cuando alguien se dirige al individuo son señales que suelen aparecer desde edades tempranas y que dificultan la interacción con otras personas. Más que conductas aisladas, representan una menor atención hacia los estímulos sociales y una menor tendencia a participar en la comunicación con el entorno.

- **Conductas hacia los demás** (*ofrece_ayuda*, *esperar_turno*) [ICAP]: frente al grupo anterior, estas variables reflejan dificultades relacionadas con la participación activa en situaciones sociales. Ofrecer ayuda implica entender la situación y reaccionar ante las necesidades de otra persona, mientras que esperar el turno requiere controlar la propia respuesta y adaptarse a la dinámica del grupo. Esta forma de ver las cosas es algo que en el TEA está alterado desde etapas muy tempranas del desarrollo.

- **Autonomía fuera del hogar** (*trabaja_ritmo_regular*, *Localiza_informacion*, *barrio_curza_calles*) [ICAP]: aunque estas variables no miden directamente interacción social, sí reflejan la capacidad de desenvolverse de forma autónoma en entornos cotidianos. Estas tareas, que implican múltiples pasos y requieren integrar información del contexto, resultan especialmente difíciles para personas con TEA debido a las alteraciones en la coherencia central: la tendencia a procesar los detalles de forma fragmentada, sin construir una representación global de la situación, dificulta seguir secuencias de acciones, mantener la atención en la tarea relevante y adaptarse a imprevistos.

Alteraciones en la comunicación

Este bloque cubre desde las formas más básicas de comunicación preverbal hasta el uso social del lenguaje, con variables de ambos instrumentos que en su conjunto describen un perfil comunicativo característico del TEA.

- **Comunicación temprana** (*intercambia_objetos* [ICAP], *repite_sonidos_ininteligibles* - [GARS-2]): intercambiar objetos es una de las primeras formas de interacción social y requiere que exista intención de compartir atención con otra persona. Por el contrario, repetir sonidos sin significado refleja un uso poco funcional del lenguaje, donde las vocalizaciones no se utilizan para comunicarse.

- **Uso social del lenguaje** (*cuenta_historia* [ICAP], *no_inicia_conversaciones* [GARS-2]): estas variables reflejan problemas en el uso práctico del lenguaje en contextos sociales. Contar una historia de manera comprensible requiere organizar la información y adaptarla a quien escucha, mientras que no iniciar conversaciones, aun teniendo capacidad para ello, indica una menor tendencia a utilizar el lenguaje como herramienta de interacción. Este variables resultan especialmente útiles en personas con mayor nivel funcional, donde las dificultades básicas del lenguaje pueden no ser tan evidentes.

Comportamientos restrictivos y repetitivos

Este bloque combina ítems del GARS-2 con variables de conducta problemática del ICAP. La presencia tanto de medidas de frecuencia como de gravedad refleja que lo relevante no es solo que estas conductas aparezcan, sino el impacto que tienen en el entorno del individuo.

- **Rutinas y movimientos repetitivos** (*hacer_cosas_repetidamente* [GARS-2], *fecuencia_estereotipias* [ICAP]): las conductas repetitivas y las estereotipias motoras —balanceos, agitación de manos, movimientos repetitivos— son de los rasgos más visibles del TEA. Estos comportamientos suelen aparecer en situaciones de estrés, cambios de rutina o sobrecarga sensorial, y pueden funcionar como una forma de autorregulación. Su presencia entre las variables más relevantes coincide además con los resultados obtenidos en el análisis exploratorio de datos, donde el grupo TEA presentaba puntuaciones notablemente más altas en el bloque de hábitos atípicos del ICAP.

- **Resistencia y negativa** (*responde_negativamente_a_ordenes* [GARS-2], *Gravedad_no_colaboradora* [ICAP]): estas variables reflejan dificultades para adaptarse a cambios o responder de forma flexible ante demandas externas. La resistencia a colaborar o las respuestas negativas suelen aparecer cuando se interrumpe una rutina o se introduce una actividad nueva. Además, incluir la gravedad de estas conductas aporta información sobre el impacto que tienen en la vida diaria y en el entorno del individuo.

- **Retraimiento conductual** (*Frecuencia_retraimiento*, *Retraimiento_atencion*, *Gravedad_retraimiento*)[ICAP]: no solo indican con qué frecuencia aparece esta conducta, sino también cuánto apoyo externo requiere y hasta qué punto afecta al funcionamiento

cotidiano. Esto resulta coherente con los criterios del DSM-5, donde el nivel de apoyo necesario es un aspecto importante en la clasificación de la severidad trastorno.

Variable clínico-funcional

- **Medicación activa** (*Medicamentos*): registra si el individuo toma medicación para ansiedad, insomnio, o hiperactividad. Esta última categoría es especialmente relevante dado que entre el 30% y el 50% de las personas con TEA presentan comorbilidad con TDAH (Trastorno por Déficit de Atención e Hiperactividad) [52], circunstancia que puede aumentar la complejidad clínica y dificultar el diagnóstico. Esto explica la frecuente prescripción de medicación para la hiperactividad en esta población. Por ello, la necesidad de medicación actúa como un indicador indirecto del perfil clínico general del paciente y ayuda a diferenciar ambos grupos de la muestra.

La coherencia entre los hallazgos estadísticos y la descripción clínica del trastorno es, en sí misma, un resultado relevante. Las 20 variables seleccionadas se distribuyen de forma equilibrada entre los principales dominios diagnósticos del TEA, proceden de ambos instrumentos clínicos empleados y cuentan con respaldo en la literatura especializada. Esto sugiere que el modelo no solo alcanza un buen rendimiento predictivo, sino que lo hace sobre bases clínicamente consistentes, reforzando su potencial como herramienta de apoyo al cribado temprano en contextos clínicos reales.

5.6 Optimización y evaluación del modelo final

A lo largo de las secciones anteriores, todos los modelos de clasificación se han evaluado con hiperparámetros por defecto o fijados manualmente, lo que ha permitido comparar de forma justa la contribución relativa de cada selector y cada algoritmo. Sin embargo, esa exploración no garantiza que los modelos estén rindiendo cerca de su capacidad real. En esta sección, reducimos el número de variables a las del Top-20 de consenso y se busca, para cada modelo, la combinación de hiperparámetros que maximiza el F1-Score en validación cruzada. El objetivo no es solo mejorar los números, sino también identificar el sistema final que se recomendará como herramienta de cribado y entender en detalle cómo se comporta sobre la muestra.

5.6.1 Estrategia de búsqueda exhaustiva: *GridSearchCV*

Para la búsqueda de hiperparámetros se emplea el método de búsqueda exhaustiva *GridSearchCV* [53], que evalúa todas las combinaciones posibles dentro de una rejilla de valores predefinida. Con el fin de no introducir sesgos de selección, la búsqueda se ejecuta dentro del

mismo esquema de validación cruzada estratificada de 5 folds utilizado en la fase exploratoria: en cada fold, el ajuste de hiperparámetros se realiza exclusivamente sobre los datos de entrenamiento, y el fold de test permanece completamente aislado. El criterio de selección es el F1-Score, consistente con la métrica principal del trabajo. Se excluye el árbol de decisión por ser el modelo con peor rendimiento con diferencia en la fase anterior de forma consistente.

Se diseñan rejillas de tamaño comparable para los cinco modelos restantes, con 3 o 4 hiperparámetros por algoritmo y entre 3 y 4 valores por hiperparámetro, recogidos en la Tabla 5.11 junto con una descripción del efecto que controla cada uno.

Tabla 5.11: Hiperparámetros y valores explorados por modelo en la búsqueda *GridSearchCV*.

Modelo	Hiperparámetro	Valores	Descripción
SVM	*C*	0.1, 1, 10, 100	Inverso de la regularización.
	gamma	*scale*, *auto*, 0.01, 0.1	Radio efectivo del kernel RBF.
	kernel	*rbf*, *linear*	Tipo de función kernel que define el espacio de características.
Random Forest	*n_estimators*	100, 300, 500	Número de árboles del bosque.
	max_depth	*None*, 10, 20	Profundidad máxima de cada árbol.
	min_samples_leaf	1, 2, 4	Número mínimo de muestras requerido en cada hoja.
Reg. Logística	*C*	0.01, 0.1, 1, 10, 100	Inverso de la regularización.
	penalty	*l1*, *l2*	Tipo de norma del término de regularización.
	solver	*liblinear*, *saga*	Algoritmo de optimización.
Gradient Boosting	*n_estimators*	100, 300, 500	Número de árboles.
	learning_rate	0.01, 0.1, 0.2	Contribución de cada árbol.
	max_depth	3, 5, 7	Profundidad de los árboles base.
MLP	*hidden_layer_sizes*	(50,), (100,), (100,50)	Número de capas ocultas y neuronas por capa.
	activation	*relu*, *tanh*	Función de activación.
	alpha	0.0001, 0.001, 0.01	Regularización L2.
	learning_rate_init	0.001, 0.01	Tasa de aprendizaje inicial.

5.6.2 Mejor configuración por modelo

La Tabla 5.12 recoge, para cada modelo, la combinación de hiperparámetros que maximiza el F1-Score en validación cruzada, junto con el resto de métricas de evaluación. Como puede observarse, el modelo ganador es el MLP, con un F1 de 0.8726 y un ROC-AUC de 0.9204, lo que supone una mejora de casi 10 puntos porcentuales sobre su mejor resultado sin optimizar en la fase exploratoria (0.7915 para $k = 30$). La configuración óptima corresponde a una arquitectura reducida de una sola capa con 50 neuronas y función de activación *tanh*, con regularización L2 prácticamente nula ($\alpha = 0.0001$). Esta sencillez sugiere que el subconjunto de 20 variables ya proporciona una representación suficientemente limpia del problema, sin necesidad de capas adicionales ni de penalizar fuertemente los pesos para evitar el sobreajuste.

La Regresión Logística se sitúa en segunda posición con el ROC-AUC más alto de todos (0.9282), lo que indica una capacidad discriminativa global superior al MLP con independencia del umbral de decisión. Su configuración con penalización L1 produce una solución dispersa que, sobre un subconjunto ya reducido, equivale a una segunda selección implícita de variables. La SVM completa el podio con kernel lineal, lo que indica que las variables son lo suficientemente discriminativas como para que este problema sea separable linealmente. En último lugar, se encuentran los modelos *ensemble* (RF y GB), obteniendo rendimientos prácticamente iguales. En la fase exploratoria ambos lideraban sin selección de características, al aprovechar la totalidad de las variables disponibles; restringidos a 20, pierden parte de esa ventaja frente a los modelos lineales.

Tabla 5.12: Mejor configuración por modelo tras la búsqueda *GridSearchCV*.

Modelo	F1	Recall	Prec.	Acc.	AUC	Configuración óptima
MLP	**0.8726**	0.8674	**0.8895**	**0.8805**	0.9204	*activation* $= tanh$, *alpha* $= 0.0001$, *hidden_layer_sizes* $= (50,)$, *learning_rate_init* $= 0.001$
Reg. Logística	0.8640	**0.8779**	0.8585	0.8708	**0.9282**	$C = 1.0$, *penalty* $= l1$, *solver* $= liblinear$
SVM	0.8481	0.8568	0.8449	0.8564	0.9204	$C = 1.0$, *gamma* $= 0.01$, *kernel* $= linear$
Random Forest	0.8163	0.8068	0.8360	0.8325	0.8982	*min_samples_leaf* $= 2$, *n_estimators* $= 300$
Gradient Boosting	0.8106	0.7968	0.8457	0.8276	0.9030	*max_depth* $= 5$, *n_estimators* $= 300$, *learning_rate* $= 0.1$

Negrita: mejor valor de cada métrica de evaluación.

Analizando la distribución de errores, los tres modelos superiores presentan diferencias poco significativas entre precision y recall —de entre 1 y 3 puntos porcentuales— que indican un comportamiento equilibrado entre la detección de casos positivos y el control de falsos positivos. La Regresión Logística y la SVM muestran un recall ligeramente superior a la precision, mientras que en MLP ocurre lo contrario. Los modelos de *ensemble* muestran un mayor desequilibrio, con la precision superando al recall en 3–5 puntos, lo que se traduce en una mayor tendencia a generar falsos negativos y, por tanto, a dejar casos reales sin detectar.

La Figura 5.15 ilustra el impacto de los principales hiperparámetros sobre el F1-Score para cada modelo:

- **SVM**: el kernel lineal supera al RBF en todo el rango de C, alcanzando su máximo en $C = 1$ y decayendo suavemente para valores más altos. El kernel RBF parte de resultados notablemente inferiores en C pequeño y no llega a igualar al lineal en ningún punto. Esto se debe a que su complejidad adicional —modelar fronteras locales y no lineales— no aporta mejora y puede introducir sobreajuste.

- **Random Forest**: las tres curvas de *min_samples_leaf* discurren casi paralelas en un rango muy estrecho (0.795–0.815), con *min_samples_leaf* $= 2$ como la opción más consistente. La profundidad máxima tampoco condiciona de forma determinante el resultado, lo que indica que este modelo es poco sensible a ambos hiperparámetros en este subconjunto.

- **MLP**: la función de activación *tanh* supera a *relu* en las tres arquitecturas, con la mayor diferencia en la configuración más sencilla (50 neuronas). Aumentar la capacidad del modelo a dos capas o al doble de neuronas no aporta mejora, lo que refuerza que la arquitectura reducida es la más adecuada para este tamaño muestral.

- **Regresión Logística**: ambos *solvers* convergen rápidamente a partir de $C = 0.1$ y el rendimiento se estabiliza en $C = 1$, confirmando que regularizaciones más débiles no aportan mejora adicional. La caída pronunciada de *saga* para C muy pequeño se debe a su incompatibilidad con la penalización L1 a bajas tasas de regularización.

- **Gradient Boosting**: una tasa de aprendizaje de 0.01 produce resultados muy inferiores al resto con independencia del número de árboles, mientras que el punto óptimo se alcanza con una tasa de 0.1 y 300 estimadores. Aumentar a 500 árboles o a una tasa de 0.2 produce un leve sobreajuste que reduce ligeramente el rendimiento.

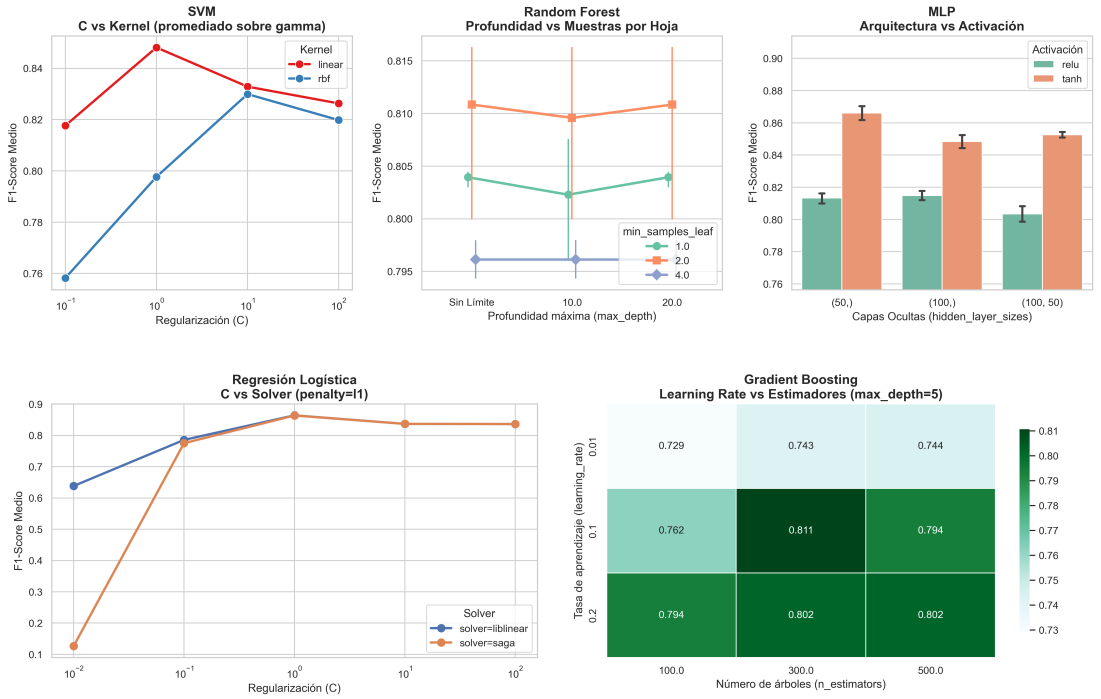


Figura 5.15: Análisis de sensibilidad a los hiperparámetros por modelo.

5.6.3 Análisis del modelo ganador

El MLP con la configuración óptima se evalúa mediante predicciones *out-of-fold*: en cada fold del esquema de validación cruzada estratificada, el modelo se entrena sobre los cuatro folds restantes y predice sobre el fold de test, de modo que cada individuo es clasificado exactamente una vez sin haber participado en el entrenamiento. La Figura 5.16 recoge los cuatro paneles de evaluación resultantes.

- La **matriz de confusión** muestra 85 verdaderos negativos y 99 verdaderos positivos, con tan solo 13 falsos positivos y 12 falsos negativos. El número de errores es prácticamente simétrico entre clases, confirmando el comportamiento ya observado en las métricas: el modelo no presenta sesgo sistemático hacia ninguno de los dos grupos y los pocos casos mal clasificados se distribuyen de forma homogénea.

- La **curva ROC** alcanza un AUC de 0.9145, con una subida muy pronunciada en la región de FPR bajo que indica que el modelo discrimina eficazmente incluso con umbrales conservadores. El umbral óptimo se sitúa en 0.59, ligeramente por encima del estándar de 0.5, lo que sugiere que en un escenario clínico real podría ajustarse hacia valores más bajos para maximizar la sensibilidad a costa de una leve reducción de precisión.

- La **curva *Precision-Recall*** presenta una precisión superior a 0.88 hasta un recall de

aproximadamente 0.85, y solo cae de forma pronunciada al forzar la recuperación de prácticamente todos los casos positivos. El área bajo la curva (AP = 0.9026) supera ampliamente el *baseline* de 0.53, correspondiente a un clasificador que simplemente predice siempre la clase mayoritaria.

- La **distribución de probabilidades predichas** es marcadamente bimodal: la gran mayoría de individuos recibe una probabilidad próxima a 0 o a 1, con muy pocos casos en la zona central (0.2–0.8), lo que indica que el modelo asigna sus predicciones con alta confianza. Los errores se concentran precisamente en ese solapamiento residual cerca del umbral, correspondiendo a los casos clínicamente más ambiguos de la muestra.

Además, la optimización aporta una mejora consistente respecto a la configuración por defecto: todas las métricas aumentan más de 3 puntos, con el recall como el indicador más beneficiado (subida de 6 puntos), lo que resulta especialmente relevante en un contexto clínico donde minimizar los falsos negativos es prioritario. La ganancia en ROC-AUC, más moderada, confirma que la mejora es global y no está orientada artificialmente a una única métrica.

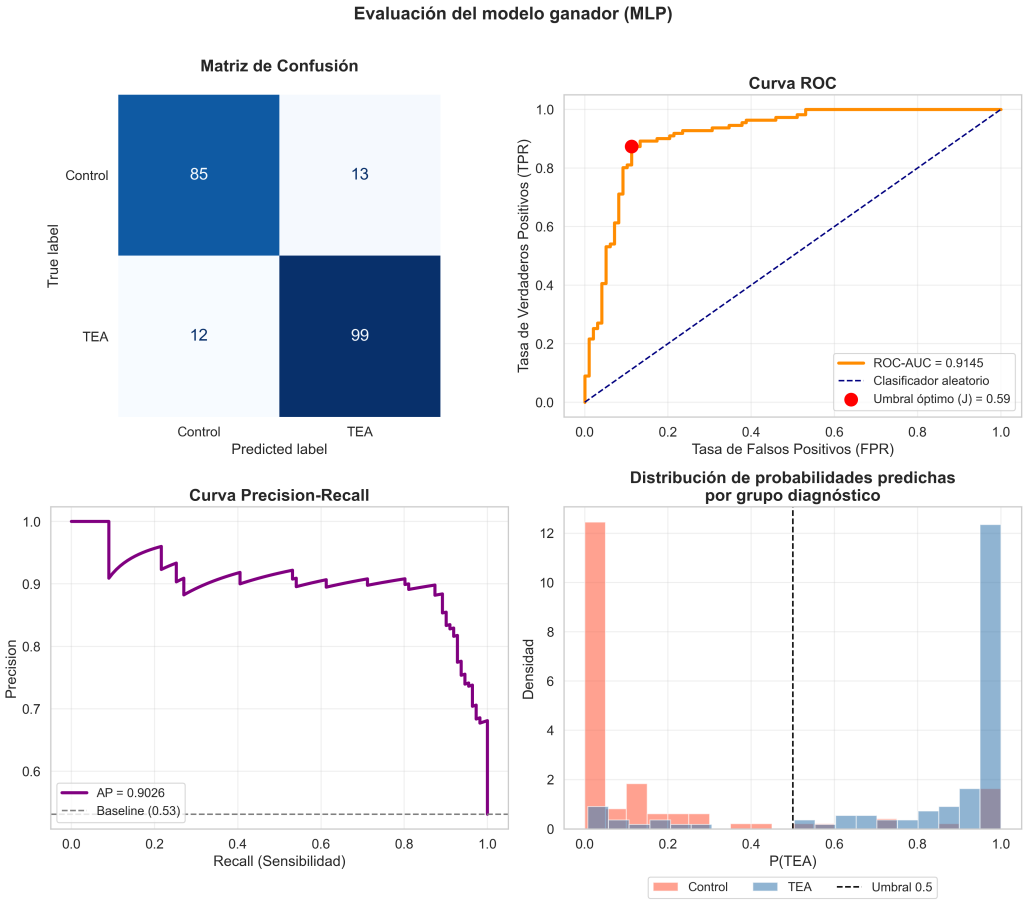


Figura 5.16: Evaluación del modelo ganador (MLP) mediante predicciones *out-of-fold*.

Capítulo 6

Conclusiones

Este capítulo cierra el trabajo recogiendo las conclusiones principales derivadas de los resultados obtenidos, resaltando las limitaciones que se encontraron a lo largo del proyecto y proponiendo líneas de trabajo futuro que podrían mejorar el sistema desarrollado.

6.1 Conclusiones principales

El objetivo fundamental de este trabajo era diseñar, implementar y validar un sistema de clasificación basado en Aprendizaje Automático para la detección temprana del TEA a partir de información clínica real: cuestionarios conductuales, historial médico y variables sociodemográficas. Los resultados conseguidos permiten afirmar que se ha alcanzado dicha meta.

En cuanto al preprocesamiento, a pesar de que la imputación por KNN fuera la que menos distorsión introducía, en la comparación posterior se observó que la eliminación de las variables con más del 50% de valores nulos resultó preferible. Produjo resultados ligeramente superiores, además de simplificar el *pipeline* y coincidir en un 90% de las variables de mayor consenso seleccionadas. Respecto a la variable *País*, su eliminación no degradó el rendimiento medio pero sí evitó un sesgo relevante, que podría haber llevado a los modelos a aprender la procedencia geográfica en vez de patrones clínicos propios del trastorno.

En la fase de selección de características, RFE-SVM y mRMR fueron los métodos con mayor rendimiento en prácticamente todas las combinaciones evaluadas. ANOVA resultó competitivo para valores altos de k, mientras que ReliefF fue más irregular, con caídas en ciertas configuraciones. E2EFS, a pesar de presentar una baja estabilidad, produjo resultados razonables con subconjuntos reducidos. En lo que respecta al número óptimo de variables, $k = 20$ demostró ser un punto intermedio entre rendimiento y complejidad. A partir de él, la ganancia de añadir más variables es inferior al 1% y el subconjunto resultante es lo suficientemente pequeño como para permitir una interpretación clínica directa.

El análisis de los modelos de clasificación mostró que el árbol de decisión es claramente el menos competitivo en todas las configuraciones probadas, mientras que el resto —SVM, RF, GB, MLP y LR— presentan medianas de F1 muy similares entre sí. Los modelos de *ensemble* (RF y GB) se aprovechan especialmente de disponer de todas las variables, a diferencia de MLP y LR, que sacan mejor partido a subconjuntos reducidos. Una vez realizada una búsqueda de hiperparámetros sobre solamente las 20 variables de mayor consenso, el MLP con una capa oculta de 50 neuronas y función de activación *tanh* resultó ser el modelo ganador con un F1 de 0.8726 y un ROC-AUC de 0.9204. Esto representa una mejora de casi 10 puntos sobre su rendimiento sin optimizar.

Más allá de resultados numéricos, el aspecto más relevante del trabajo es la concordancia entre los hallazgos estadísticos y la descripción clínica del trastorno. Las 20 variables de mayor consenso cubren de forma equilibrada los 3 dominios diagnósticos —alteraciones en la interacción social, en la comunicación y comportamientos restrictivos y repetitivos— y cada una de ellas cuenta con una justificación reconocida en la literatura clínica, reforzando la interpretabilidad y credibilidad.

Este sistema resulta de gran utilidad y una ayuda real en la práctica clínica diaria: al reducir cientos de variables a un subconjunto manejable con respaldo clínico, permite a pediatras, psicólogos y otros profesionales identificar de forma ágil qué pacientes requieren una evaluación diagnóstica en profundidad, sin depender de pruebas costosas ni de listas de espera prolongadas.

6.2 Limitaciones del estudio

A pesar de los resultados obtenidos, el trabajo presenta varias limitaciones que se deben tener en cuenta a la hora de interpretar y generalizar las conclusiones. La principal y más importante, mencionada recurrentemente a lo largo del trabajo, es el tamaño muestral. Con 209 individuos, el rendimiento tiene una varianza considerable incluso con la técnica de validación cruzada estratificada de 5 folds y los resultados podrían variar dependiendo de la composición de las muestras. Esta limitación se ve agravada por el sesgo de selección proveniente de la procedencia geográfica: la submuestra uruguaya proviene en su mayoría de centros de educación especial, mientras que la gallega incluye una proporción mayor de centros ordinarios. Esto refleja una distribución de perfiles clínicos que no es representativa de la población general con TEA y, por lo tanto, un modelo entrenado solamente sobre estas muestras podría no generalizar bien en contextos diferentes.

En cuanto a la naturaleza de los datos, la gran mayoría de las variables son ordinales o categóricas y proceden de cuestionarios realizados a padres u otros familiares del paciente, introduciendo subjetividad en el proceso de recogida: evaluadores distintos pueden asignar

puntuaciones distintas ante la misma conducta. Además, la realización de los cuestionarios y las preguntas respondidas no fue completamente homogénea entre submuestras, y las variables eliminadas por su alta presencia de nulos podría contener información clínica relevante que no es aprovechada. Por otra parte, al disponer de información de un momento concreto no es posible monitorizar al paciente a lo largo del tiempo, impidiendo un análisis más exhaustivo que reafirme o desmienta un cribado puntual.

En último lugar, el sistema fue evaluado únicamente sobre el propio dataset mediante validación cruzada. Esta ausencia de una cohorte independiente impide la validación del rendimiento real del sistema sobre datos completamente nuevos.

6.3 Trabajo Futuro

Los resultados de este trabajo abren varias líneas de desarrollo que podrían mejorar el sistema o ampliar su alcance. La más urgente es ampliar el conjunto de datos con muestras de diferentes centros clínicos, incluyendo más casos del grupo control procedentes de centros ordinarios, actualmente infrarrepresentados. Esto produciría modelos más robustos y abriría la puerta a técnicas de generación de datos sintéticos como SMOTE. En segundo lugar, la incorporación de nuevas modalidades de información (EEG, fMRI, análisis del lenguaje) o de medidas repetidas en el tiempo mejoraría la capacidad discriminativa y posibilitaría la detección de señales de riesgo en edades muy tempranas. Asimismo, la validación sobre una cohorte independiente en centros colaboradores es necesaria para obtener una estimación realista del rendimiento en condiciones de uso real. Por último, el paso natural sería materializar el sistema en una herramienta clínica —aplicación web o móvil— donde el profesional introduzca los datos del paciente y obtenga de forma inmediata una estimación del riesgo de TEA junto con los indicadores que más contribuyen a esa predicción.

Bibliografía

[1] American Psychiatric Association, *Diagnostic and Statistical Manual of Mental Disorders (DSM-5)*, 5th ed. Washington, DC: American Psychiatric Publishing, 2013, [En línea]. Disponible en: https://doi.org/10.1176/appi.books.9780890425596.

[2] World Health Organization, "Autism spectrum disorders: Key facts," 2023. [En línea]. Disponible en: https://www.who.int/news-room/fact-sheets/detail/autism-spectrum-disorders

[3] J. Zeidan, E. Fombonne, J. Scorah, A. Ibrahim, M. S. Durkin, S. Saxena, A. Yusuf, and M. Elsabbagh, "Global prevalence of autism: A systematic review update," *Autism Research*, 2022, [En línea]. Disponible en: https://doi.org/10.1002/aur.2696.

[4] C. Lord, T. Charman, A. Havdahl, P. Carbone, E. Anagnostou, B. Boyd *et al.*, "Autism spectrum disorder," *The Lancet*, 2022, [En línea]. Disponible en: https://doi.org/10.1016/S0140-6736(21)01541-5.

[5] S. S. Rajagopalan and K. Tammimies, "Predicting neurodevelopmental disorders using machine learning models and electronic health records – status of the field," *Journal of Neurodevelopmental Disorders*, 2024, [En línea]. Disponible en: https://doi.org/10.1186/s11689-024-09579-0.

[6] Python Software Foundation, "Python language reference," 2024. [En línea]. Disponible en: https://www.python.org/

[7] Microsoft, "Visual studio code," 2024. [En línea]. Disponible en: https://code.visualstudio.com/

[8] Project Jupyter, "Jupyter notebook," 2024. [En línea]. Disponible en: https://jupyter.org/

[9] The Pandas Development Team, "pandas: powerful Python data analysis toolkit," 2024. [En línea]. Disponible en: https://pandas.pydata.org/

[10] NumPy Developers, "NumPy: The fundamental package for scientific computing with Python," 2024. [En línea]. Disponible en: https://numpy.org/

[11] J. D. Hunter and M. Droettboom, "Matplotlib: A 2D graphics environment," 2024. [En línea]. Disponible en: https://matplotlib.org/

[12] M. Waskom, "Seaborn: statistical data visualization," 2024. [En línea]. Disponible en: https://seaborn.pydata.org/

[13] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," 2024. [En línea]. Disponible en: https://scikit-learn.org/

[14] J. Muñoz-Terol *et al.*, "A systematic review of machine learning techniques to address diagnosis and treatment of autism: challenges and opportunities," *Heliyon*, 2026, [En línea]. Disponible en: https://doi.org/10.1016/j.heliyon.2025.e44359.

[15] S. S. Rajagopalan, Y. Zhang, A. Yahia, and K. Tammimies, "Machine learning prediction of autism spectrum disorder from a minimal set of medical and background information," *JAMA Network Open*, 2024, [En línea]. Disponible en: https://doi.org/10.1001/jamanetworkopen.2024.29229.

[16] Simons Foundation Autism Research Initiative (SFARI), "SPARK dataset," 2024. [En línea]. Disponible en: https://base.sfari.org/

[17] N. Jamil *et al.*, "Recent advances in autism spectrum disorder diagnosis based on machine learning and deep learning," *Artificial Intelligence Review*, 2025, [En línea]. Disponible en: https://doi.org/10.1007/s10462-025-11302-x.

[18] M. Temiz *et al.*, "Machine learning-based prediction of autism spectrum disorder and discovery of related metagenomic biomarkers with explainable AI," *Applied Sciences*, 2025, [En línea]. Disponible en: https://doi.org/10.3390/app15169214.

[19] R. Ayub *et al.*, "Enhancing early detection of autistic spectrum disorder in children using machine learning approaches," *Journal of King Saud University – Science*, 2024, [En línea]. Disponible en: https://doi.org/10.1016/j.jksus.2024.103468.

[20] A. Santana *et al.*, "rs-fMRI and machine learning for ASD diagnosis: a systematic review and meta-analysis," *Scientific Reports*, 2022, [En línea]. Disponible en: https://doi.org/10.1038/s41598-022-09821-6.

[21] Autism Brain Imaging Data Exchange, "ABIDE dataset," 2024. [En línea]. Disponible en: http://fcon_1000.projects.nitrc.org/indi/abide/

[22] I. García García, "Indicadores tempranos de conducta adaptativa en niños con autismo," Tesis doctoral, Universidade da Coruña, 2024.

[23] R. H. Bruininks, B. K. Hill, R. F. Weatherman, and R. W. Woodcock, *Inventory for Client and Agency Planning*. Allen, TX: DLM Teaching Resources, 1986.

[24] J. E. Gilliam, *GARS-2: Gilliam Autism Rating Scale—Second Edition*. Austin, TX: PRO-ED, 2006.

[25] R. Loomes, L. Hull, and W. Mandy, "What is the male-to-female ratio in autism spectrum disorder? A systematic review and meta-analysis," *Journal of the American Academy of Child & Adolescent Psychiatry*, 2017, [En línea]. Disponible en: https://doi.org/10.1016/j.jaac.2017.03.013.

[26] R. J. A. Little and D. B. Rubin, *Statistical Analysis with Missing Data*. New York: John Wiley & Sons, 2002.

[27] K. Pearson, "On lines and planes of closest fit to systems of points in space," *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 1901, [En línea]. Disponible en: https://doi.org/10.1080/14786440109462720.

[28] L. van der Maaten and G. Hinton, "Visualizing data using t-SNE," *Journal of Machine Learning Research*, 2008, [En línea]. Disponible en: https://jmlr.org/papers/v9/vandermaaten08a.html.

[29] L. McInnes, J. Healy, and J. Melville, "UMAP: Uniform manifold approximation and projection for dimension reduction," *arXiv preprint arXiv:1802.03426*, 2018, [En línea]. Disponible en: https://arxiv.org/abs/1802.03426.

[30] O. Troyanskaya *et al.*, "Missing value estimation methods for DNA microarrays," *Bioinformatics*, 2001, [En línea]. Disponible en: https://doi.org/10.1093/bioinformatics/17.6.520.

[31] S. Van Buuren, *Flexible Imputation of Missing Data*, 2nd ed. CRC Press, 2018, [En línea]. Disponible en: https://stefvanbuuren.name/fimd/.

[32] J. Lin, "Divergence measures based on the Shannon entropy," *IEEE Transactions on Information Theory*, 1991, [En línea]. Disponible en: https://doi.org/10.1109/18.61115.

[33] S. Kullback and R. A. Leibler, "On information and sufficiency," *The Annals of Mathematical Statistics*, 1951, [En línea]. Disponible en: https://doi.org/10.1214/aoms/1177729694.

[34] D. M. Endres and J. E. Schindelin, "A new metric for probability distributions," *IEEE Transactions on Information Theory*, 2003, [En línea]. Disponible en: https://doi.org/10.1109/TIT.2003.813506.

[35] I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," *Journal of Machine Learning Research*, 2003, [En línea]. Disponible en: https://jmlr.org/papers/v3/guyon03a.html.

[36] R. Battiti, "Using mutual information for selecting features in supervised neural net learning," *IEEE Transactions on Neural Networks*, 1994, [En línea]. Disponible en: https://doi.org/10.1109/72.298224.

[37] R. A. Fisher, *Statistical Methods for Research Workers*. Edinburgh: Oliver and Boyd, 1925.

[38] K. Kira and L. A. Rendell, "The feature selection problem: Traditional methods and a new algorithm," in *Proceedings of the Tenth National Conference on Artificial Intelligence (AAAI-92)*. AAAI Press, 1992, pp. 129–134, [En línea]. Disponible en: https://cdn.aaai.org/AAAI/1992/AAAI92-020.pdf.

[39] I. Kononenko, "Estimating attributes: Analysis and extensions of RELIEF," in *Machine Learning: ECML-94*, ser. Lecture Notes in Computer Science. Springer, 1994, vol. 784, pp. 171–182, [En línea]. Disponible en: https://doi.org/10.1007/3-540-57868-4_57.

[40] H. Peng, F. Long, and C. Ding, "Feature selection based on mutual information: criteria of max-dependency, max-relevance, and min-redundancy," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2005, [En línea]. Disponible en: https://doi.org/10.1109/TPAMI.2005.159.

[41] D. Mancusi, "mrmr: Minimum redundancy maximum relevance feature selection," 2021. [En línea]. Disponible en: https://github.com/smazzanti/mrmr

[42] I. Guyon, J. Weston, S. Barnhill, and V. Vapnik, "Gene selection for cancer classification using support vector machines," *Machine Learning*, 2002, [En línea]. Disponible en: https://doi.org/10.1023/A:1012487302797.

[43] V. Bolon-Canedo, B. Cancela, and A. Alonso-Betanzos, "E2E-FS: An end-to-end feature selection method for neural networks," in *Proceedings of the International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2020, [En línea]. Disponible en: https://doi.org/10.1109/IJCNN48605.2020.9207319.

[44] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, 1995, [En línea]. Disponible en: https://doi.org/10.1007/BF00994018.

[45] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," *Nature*, 1986, [En línea]. Disponible en: https://doi.org/10.1038/323533a0.

[46] L. Breiman, J. Friedman, C. J. Stone, and R. A. Olshen, *Classification and Regression Trees*. Wadsworth, 1984.

[47] L. Breiman, "Random forests," *Machine Learning*, 2001, [En línea]. Disponible en: https://doi.org/10.1023/A:1010933404324.

[48] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *The Annals of Statistics*, 2001, [En línea]. Disponible en: https://doi.org/10.1214/aos/1013203451.

[49] D. R. Cox, "The regression analysis of binary sequences," *Journal of the Royal Statistical Society: Series B*, 1958, [En línea]. Disponible en: https://doi.org/10.1111/j.2517-6161.1958.tb00292.x.

[50] R. Kohavi, "A study of cross-validation and bootstrap for accuracy estimation and model selection," in *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 1995, pp. 1137–1143, [En línea]. Disponible en: https://dl.acm.org/doi/10.5555/1643031.1643047.

[51] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognition Letters*, 2006, [En línea]. Disponible en: https://doi.org/10.1016/j.patrec.2005.10.010.

[52] Y. Leitner, "The co-occurrence of autism and attention deficit hyperactivity disorder in children – what do we know?" *Frontiers in Human Neuroscience*, 2014, [En línea]. Disponible en: https://doi.org/10.3389/fnhum.2014.00268.

[53] scikit-learn developers, "GridSearchCV – scikit-learn 1.8.0 documentation," 2025, Último acceso: mayo de 2025. [En línea]. Disponible en: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html